

absolute frequency

Frequency and statistics

Definition

A quantitative measure representing the total number of occurrences of a specific item within a defined dataset. This concept is essential for statistical analysis, as it serves as a foundational element for calculating relative frequencies and comparing observed data against expected frequencies in various contexts. Absolute frequency contrasts with relative frequency, which expresses occurrences in relation to the total number of observations.

Frequency (EN corpus)

abs: 6 pmw: 4.72

Corpus evidence (EN)

"If we want to convert the absolute frequencies in Table 5.1 into relative frequencies, we first have to decide what the relevant total N is." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"This comparison between observed and expected frequencies also provides a foundation for inferential statistics." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"In determining the ratio, however, we used relative references for both parts of the equation." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term "absolute frequency" is widely used in corpus linguistics to provide a clear count of occurrences, serving as a basis for further statistical analysis. Its distinction from relative frequency is crucial for understanding data representation and analysis in linguistic research. El término "frecuencia absoluta" se utiliza ampliamente en la lingüística de corpus para proporcionar un conteo claro de ocurrencias, sirviendo como base para un a

Términos relacionados / Related terms

relative frequency / frecuencia relativa · frequency list / lista de frecuencias · absolute frequency / frecuencia absoluta · statistical significance / significancia estadística · statistical significance / significancia estadística

frecuencia absoluta

Frecuencia y estadística

Definición

Medida cuantitativa que representa el número total de ocurrencias de un elemento específico dentro de un conjunto de datos definido. Este concepto es fundamental para el análisis estadístico, ya que sirve como elemento base para calcular frecuencias relativas y comparar datos observados con frecuencias esperadas en diversos contextos. La frecuencia absoluta se contrasta con la frecuencia relativa, que expresa las ocurrencias en relación con el número total de observaciones.

Frecuencia (corpus ES)

abs: 35 pmw: 43.11

Evidencia en corpus (ES)

"Frecuencia absoluta Número de documentos Frecuencia normalizada (casos por millón) jugo 6161 2479 21,9 zumo 2673 9,5." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

"En un corpus adecuadamente codificado se puede encontrar información no solo sobre la frecuencia, sino también sobre la distribución de una palabra." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

"La explotación básica de los corpus peso que suponen los elementos más frecuentes sobre el total..." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

accuracy

Annotation and markup

Definition

A measure of the correctness of data annotation, defined as the proportion of true positive results among all instances identified by a query. This term is crucial in evaluating the quality of corpus data retrieval and annotation, contrasting with recall, which focuses on the completeness of identified instances. High accuracy indicates that the annotation scheme or retrieval method effectively distinguishes between correct and incorrect classifications.

Frequency (EN corpus)

abs: 165 pmw: 129.88

Corpus evidence (EN)

"Ideally, the value of both measures should be 1, i.e., our data should include all cases of the phenomenon under investigation (a recall rate of 100 percent) and it should include nothing that is not a case of this phenomenon (a precision of 100 percent)." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"In these more complex cases, we can, and should, assess the quality of the automatic annotation in the same way in which we would assess the quality of the results returned by a particular query, in terms of precision and recall." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"Although the degree of accuracy was higher than expected, especially in the earlier subperiods, we can see that the tagger is less precise with earlier texts." (2017_Fanego, T., Rodríguez-Puente, et al._The Corpus of Historical English Law Reports. A resource for analysis the development of English_ICAME)

Nota terminológica / Terminological note

The term "accuracy" is frequently used in the context of data annotation and retrieval, emphasizing the importance of correct classifications in corpus linguistics. Variations in accuracy can arise based on the complexity of the data being annotated and the methods employed, highlighting the need for careful evaluation of annotation schemes and retrieval processes. El término "precisión" se utiliza con frecuencia en el contexto de la anotación y

Términos relacionados / Related terms

accuracy / exactitud · **recall** / exhaustividad · **annotation scheme** / esquema de anotación · **tagger** / etiquetador · **corpus annotation** / anotación de corpus · **inter-annotator agreement** / acuerdo interanotador

exactitud

Anotación y marcado

Definición

Una medida de la corrección de la anotación de datos, definida como la proporción de resultados verdaderamente positivos entre todas las instancias identificadas por una consulta. Este término es fundamental para evaluar la calidad de la recuperación y anotación de datos en corpus, contrastando con el recall, que se centra en la exhaustividad de las instancias identificadas. Una alta precisión indica que el esquema de anotación o el método de recuperación distingue eficazmente entre clasificaciones correctas e incorrectas.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

"El análisis de errores gana en precisión y posibilidades de generalización si el corpus ha recibido ese tipo de codificación." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

"Los corpus generales permiten, en efecto, extraer datos acerca de las características relevantes de la L2 y hacerlo de forma selectiva en función de los diferentes tipos de texto." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

"El rasgo más habitualmente destacado de los corpus de aprendientes frente a otros es la posibilidad de indicar también, entre los rasgos incorporados en la codificación, el nivel de conocimientos de la L2." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

alignment

Language processing

Definition

The process of matching corresponding segments in source and target texts, typically at the sentence level, is essential in the creation of parallel corpora. This methodological approach often requires both automatic tools and manual verification to ensure high-quality alignments, as automatic alignment alone may not account for complexities such as sentence merging or splitting. The term is closely related to the concept of multilingual linguistic annotation, which raises questions about comparability across languages.

Frequency (EN corpus)

abs: 153 pmw: 120.44

Corpus evidence (EN)

"the performance of the individual alignment tools varies for different types of texts and language pairs and in order to guarantee high quality alignments, a manual verification step is needed." (2020_Lefer, M. A._Parallel corpora)

"Software tools can be used to align parallel texts automatically at paragraph, sentence and word level." (2020_Lefer, M. A._Parallel corpora)

"Sentence alignment is not a straightforward task, as translators often merge or split sentences when producing the target text." (2020_Lefer, M. A._Parallel corpora)

Nota terminológica / Terminological note

The term "alignment" is primarily used in the context of parallel corpora and translation studies, where it plays a critical role in ensuring the accuracy and reliability of linguistic comparisons across languages. Variations in alignment methods, such as automatic versus manual alignment, reflect ongoing debates about the best practices in corpus linguistics. El término "alineación" se utiliza principalmente en el contexto de los corpus paralelo

Términos relacionados / Related terms

parallel corpus / corpus paralelo · **annotation** / anotación · **corpus design** / diseño de corpus · **parallel corpus** / corpus paralelo · **multilingual corpus** / corpus multilingüe · **inter-annotator agreement** / acuerdo interanotador

alineación

Procesamiento del lenguaje

Definición

El proceso de emparejamiento de segmentos correspondientes en textos fuente y meta, generalmente a nivel de oración, es fundamental en la creación de corpus paralelos. Este enfoque metodológico a menudo requiere tanto herramientas automáticas como verificación manual para garantizar alineaciones de alta calidad, ya que la alineación automática por sí sola puede no considerar complejidades como la fusión o división de oraciones. El término está estrechamente relacionado con la anotación lingüística multilingüe, que plantea interrogantes sobre la comparabilidad entre lenguas.

Frecuencia (corpus ES)

abs: 15 pmw: 18.48

Evidencia en corpus (ES)

"una alineación incorrecta desvirtuaría los resultados del corpus en los estudios descriptivos realizados con él." (2018_Leiva Rojo, J._Diseño y compilación de corpus paralelos alineados. Dificultades y algunas soluciones)

"la alineación de corpus paralelos es un proceso demandante y laborioso." (2018_Leiva Rojo, J._Diseño y compilación de corpus paralelos alineados. Dificultades y algunas soluciones)

"la alineación cotejada por párrafos permite una alineación más fluida a nivel de oración." (2018_Leiva Rojo, J._Diseño y compilación de corpus paralelos alineados. Dificultades y algunas soluciones)

annotated corpus

Corpus design and compilation

Definition

A collection of texts that includes additional information beyond the raw text, such as linguistic or metalinguistic features. This additional information can encompass markup, part-of-speech tagging, and semantic tagging, which enhance the corpus's utility for linguistic analysis. The methodological approach to annotation varies, with part-of-speech tagging being the most common form, while other types of annotations may include pragmatic or syntactic information.

Frequency (EN corpus)

abs: 152 pmw: 119.65

Corpus evidence (EN)

A corpus is annotated when it consists of more than the actual words in the document (which is generally known as plain text). (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Annotation is a multilayered term that includes (but is not limited to) markup, POS-tagging, and semantic tagging. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Given the predominance of such applications, it comes as no surprise that the most commonly found kind of annotation is part-of-speech tagging. (source: 2017_Gries, S. T., Berez, A. L._Linguistic Annotation in or for Corpus Linguistics)

Nota terminológica / Terminological note

The term "annotated corpus" encompasses a variety of annotation types, reflecting the diverse applications in corpus linguistics. The methodological approaches to annotation are evolving, with increasing attention to pragmatic and semantic dimensions alongside traditional part-of-speech tagging. El término "corpus anotado" abarca una variedad de tipos de anotación, reflejando las diversas aplicaciones en la lingüística de corpus. Los enfoques met

Términos relacionados / Related terms

annotation / anotación · **part-of-speech tagging** / etiquetado morfosintáctico · **markup language** / lenguaje de marcado · **corpus design** / diseño de corpus · **metadata** / metadatos · **semantic annotation** / anotación semántica

corpus anotado

Diseño y compilación de corpus

Definición

Un conjunto de textos que incluye información adicional más allá del texto en bruto, como características lingüísticas o metalingüísticas. Esta información adicional puede abarcar etiquetado, etiquetado de partes del discurso y etiquetado semántico, lo que aumenta la utilidad del corpus para el análisis lingüístico. El enfoque metodológico para la anotación varía, siendo el etiquetado de partes del discurso la forma más común, mientras que otros tipos de anotaciones pueden incluir información pragmática o sintáctica.

Frecuencia (corpus ES)

abs: 44 pmw: 54.20

Evidencia en corpus (ES)

Se trata de un corpus de la lengua estándar de la variedad del español peninsular, anotado a distintos niveles: morfosintáctico (categoría gramatical y lema), sintáctico (constituyentes y funciones), semántico (sentidos de WordNet, estructura argumental, roles semánticos y entidades) y pragmático (relaciones de coreferencia). (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

El CE está parcialmente anotado y lematizado, lo que facilita la investigación lingüística. (fuente: 2022_Molina Plaza, S._Herramientas, recursos y metodologías de análisis para la traducción mediante corpus lingüísticos del español)

Entre los corpus anotados de español de libre distribución destacan los corpus ARTHUS asociado a la base de datos ADESSE. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

annotation

Annotation and markup

Definition

A systematic process of enriching linguistic data by adding interpretative information, distinguishing it from markup, which may refer to the physical act of marking text. This practice enhances the corpus's value by allowing for more comprehensive searches and research, as it provides explicit linguistic analysis rather than relying on implicit classifications. The design of annotation systems is often influenced by specific research interests, making it a critical methodological component in corpus linguistics.

Frequency (EN corpus)

abs: 1.517 pmw: 1194.12

Corpus evidence (EN)

Second, the annotation practices need to be documented. This can be done in the form of an annotation manual that outlines the conventions that have been applied in creating a set of annotations and at the same time serves as guidelines for users who intend to implement the annotations themselves on their own corpus data. (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Corpus annotation involves enormous amounts of work. This means that when we decide to use an annotation system or devise one ourselves, we need to make sure that the work is worthwhile, that is, the information we require cannot be extracted in some other way using data that is readily available, such as smarter ways of querying. (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

The specific design of annotation systems is codetermined by the specific research interests involved and therefore, we will need to refer to various research projects time and again. (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Nota terminológica / Terminological note

The term "annotation" encompasses various practices in corpus linguistics, often distinguished from markup by its emphasis on interpretative information. Its application is critical for enhancing the usability of linguistic data, and the methodologies surrounding it are continually evolving as new research interests emerge. El término "anotación" abarca diversas prácticas en la lingüística de corpus, a menudo diferenciándose del marcado por su énfasis.

Términos relacionados / Related terms

corpus / corpus · **tagset** / tagset · **POS tagging** / etiquetado morfosintáctico · **metadata** / metadatos · **inter-annotator agreement** / acuerdo interanotador · **annotation scheme** / esquema de anotación

anotación

Anotación y marcado

Definición

Un proceso sistemático de enriquecimiento de datos lingüísticos mediante la adición de información interpretativa, que se distingue del marcado, el cual puede referirse al acto físico de marcar un texto. Esta práctica aumenta el valor del corpus al permitir búsquedas y análisis más exhaustivos, ya que proporciona un análisis lingüístico explícito en lugar de depender de clasificaciones implícitas. El diseño de los sistemas de anotación suele estar influenciado por intereses de investigación específicos, lo que lo convierte en un componente metodológico crítico en la lingüística de corpus.

Frecuencia (corpus ES)

abs: 462 pmw: 569.12

Evidencia en corpus (ES)

La anotación de un corpus es un proceso iterativo/cíclico. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

Una vez realizado este proceso en el tiempo que se considere oportuno, es decir, cuando la guía ya no requiere modificaciones y se muestra estable, se pasa a la siguiente fase, la evaluación de la calidad de la anotación. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

Para evaluar la calidad de un corpus anotado el criterio fundamental es la consistencia de los datos anotados, es decir, que todos los anotadores han aplicado el mismo criterio para el mismo problema. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

annotation scheme

Annotation and markup

Definition

A structured framework for annotating linguistic data, which delineates specific categories and rules for marking entities, relations, and attributes within a text. This methodological tool is essential for ensuring consistency and clarity in the representation of linguistic phenomena, as evidenced by various systems like the ACE Pilot Format and the GNOME coding scheme. Unlike general annotation, an annotation scheme provides a systematic approach to capturing complex linguistic features, such as coreference and anaphoric relations.

Frequency (EN corpus)

abs: 129 pmw: 101.54

Corpus evidence (EN)

The annotation system has two basic facets: (1) it captures the identity of referents mentioned by different referring expressions, (2) it captures various aspects of the anaphoric relation. (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Anaphoric information in APF is organized around entities: all entities annotated in the document are identified with elements, and each mention of entity e is then recorded as a child element of the element for e. (source: 2016_Poesio, M., Pradhan, S., Recasens, M., Rodríguez, K., Versley, Y._Annotated Corpora and Annotation Tools)

Each mention is annotated with the attribute TYPE, with three possible values: NAM for named entities, NOM for NPs with a common noun as head, and PRO for pronouns. (source: 2016_Poesio, M., Pradhan, S., Recasens, M., Rodríguez, K., Versley, Y._Annotated Corpora and Annotation Tools)

Nota terminológica / Terminological note

The term "annotation scheme" is widely used in corpus linguistics to refer to structured frameworks that guide the annotation process, ensuring consistency and clarity in data representation. Variations in annotation schemes may arise based on the specific linguistic features being analyzed or the goals of the research. El término "esquema de anotación" se utiliza ampliamente en la lingüística de corpus para referirse a marcos estructurados que g

Términos relacionados / Related terms

annotation / anotación · **annotated corpus** / corpus anotado · **markup language** / lenguaje de marcado · **semantic annotation** / anotación semántica · **named entity recognition** / reconocimiento de entidades nombradas · **annotation scheme** / esquema de anotación

esquema de anotación

Anotación y marcado

Definición

Marco estructurado para la anotación de datos lingüísticos que delimita categorías específicas y reglas para marcar entidades, relaciones y atributos dentro de un texto. Este instrumento metodológico es esencial para garantizar la consistencia y la claridad en la representación de fenómenos lingüísticos, como evidencian sistemas como el formato ACE Pilot o el esquema de codificación GNOME. A diferencia de la anotación general, un esquema de anotación proporciona un enfoque sistemático para capturar rasgos lingüísticos complejos, tales como la coreferencia y las relaciones anafóricas.

Frecuencia (corpus ES)

abs: 7 pmw: 8.36

annotation tools

Annotation and markup

Definition

Software applications designed to facilitate the process of adding linguistic labels to textual data, enabling both automated and manual annotation. These tools support various annotation goals, such as parts-of-speech tagging and semantic annotation, and are essential for enhancing the analytical capabilities of corpus linguistics. The corpus indicates a trend towards integrating automated systems with manual annotation processes, highlighting their complementary roles in linguistic research.

Frequency (EN corpus)

abs: 51 pmw: 40.15

Corpus evidence (EN)

"Some packages help analysts introduce manual annotations, but these are fewer and less well developed, generally, than the automated systems." (2024_McEnery, T., Brookes, G.)

"All the annotation tools discussed here offer the flexibility for adapting to specific annotation goals, as well as the required interaction for making annotation efficient." (2016_Poesio, M., et al.)

"KorAP has some features that make it particularly suitable for use within the ICC." (2021_Cermakova, A., et al.)

Nota terminológica / Terminological note

The term "annotation tools" encompasses a variety of software applications that serve different purposes in the annotation process, from automated tagging to manual input. The integration of these tools into corpus linguistics reflects a growing emphasis on both quantitative and qualitative analysis, indicating a methodological evolution in the field. El término "herramientas de anotación" abarca una variedad de aplicaciones informáticas que sirven

Términos relacionados / Related terms

corpus / corpus · **annotation scheme** / esquema de anotación · **annotation tools** / herramientas de anotación · **annotation tools** / herramientas de anotación · **semantic annotation** / anotación semántica · **CQPweb** / CQPweb

herramientas de anotación

Anotación y marcado

Definición

Aplicaciones informáticas que facilitan el proceso de añadir etiquetas lingüísticas a datos textuales, permitiendo tanto la anotación automática como la manual. Estas herramientas apoyan diversos objetivos de anotación, como el etiquetado de partes del discurso y la anotación semántica, y son esenciales para mejorar las capacidades analíticas de la lingüística de corpus. El corpus indica una tendencia hacia la integración de sistemas automáticos con procesos de anotación manual, destacando sus roles complementarios en la investigación lingüística.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Evidencia en corpus (ES)

"La evaluación de la calidad de un corpus anotado el criterio fundamental es la consistencia de los datos anotados." (2022_Martí, M. A., Taulé, M.)

"Las herramientas de crowdsourcing permiten también la colaboración del público general en la anotación o análisis de los datos." (2022_de Benito Moreno, C.)

"La anotación es el proceso mediante el cual se explicitan categorías lingüísticas por medio de etiquetas que se añaden a los datos." (2018_Bernal Chávez, J. A., Hincapié Moreno, D. A.)

AntConc

Tools and software

Definition

A software tool designed for corpus analysis, facilitating tasks such as concordancing, frequency analysis, and collocation extraction. It allows users to manipulate and analyze text files, providing insights into linguistic patterns and structures. AntConc is often employed in corpus linguistics research, contrasting with other tools that may offer broader functionalities or different analytical approaches.

Frequency (EN corpus)

abs: 142 pmw: 111.78

Corpus evidence (EN)

"When you work with directories, you should probably set the file type option to 'ALL', as many of the files you may be analysing might contain additional markup and have a different extension, and therefore not automatically be made available by AntConc otherwise." (source)

"AntConc also allows us to see or sort by whether the results occur on left- or right-hand side of the node, and with which frequency." (source)

"To create additional configuration options – which also store information about the files you had open and your last searches, etc. – later, you can create separate configuration files and then load them via 'File→Import Settings from File...' as and when required for a particular research purpose." (source)

Nota terminológica / Terminological note

The term "AntConc" is widely recognized in the field of corpus linguistics as a specialized tool for text analysis. Its functionalities are often compared to other software, highlighting its specific strengths in concordancing and frequency analysis. El término "AntConc" es ampliamente reconocido en el campo de la lingüística de corpus como una herramienta especializada para el análisis de textos. Sus funcionalidades se comparan frecuentemente

Términos relacionados / Related terms

concordance / concordancia · **frequency** / frecuencia · **collocation** / colocación · **corpus** / corpus · **keyword analysis** / análisis de palabras clave · **text type** / tipo de texto · **annotation** / anotación

AntConc

Herramientas y software

Definición

Una herramienta de software destinada al análisis de corpus, que facilita tareas como la concordancia, el análisis de frecuencias y la extracción de colocaciones. Permite a los usuarios manipular y analizar archivos de texto, proporcionando información sobre patrones y estructuras lingüísticas. AntConc se utiliza frecuentemente en la investigación de lingüística de corpus, en contraste con otras herramientas que pueden ofrecer funcionalidades más amplias o enfoques analíticos diferentes.

Frecuencia (corpus ES)

abs: 36 pmw: 44.35

Evidencia en corpus (ES)

"Con el uso de AntConc hemos generado listados de frecuencias de palabras y sintagmas, hemos extraído concordancias y colocaciones, a raíz de las cuales hemos podido acceder a fragmentos más amplios que permiten aclarar conceptos clave." (fuente)

"Estas operaciones nos han ayudado a resolver cuestiones de tipo terminológico, conceptual, macrotextual y estilístico, aunque también es posible y útil realizar otras para afrontar aspectos morfosintácticos, ortotipográficos o discursivos." (fuente)

"Recurriremos de nuevo a AntConc 3.4.4w, esta vez para analizar nuestro corpus AGENCOR." (fuente)

association measures

Frequency and statistics

Definition

A statistical tool used to evaluate the strength and significance of the relationship between two variables, often represented in contingency tables. Common association measures include mutual information, Fisher's exact test, and chi-squared, which help determine noteworthy collocations in linguistic data. These measures are essential for corpus linguistics, as they provide a methodological framework for analyzing co-occurrence patterns.

Frequency (EN corpus)

abs: 105 pmw: 82.65

Corpus evidence (EN)

The inventory of association measures is vast. They are extensively reviewed in Church et al. (1991), Evert (2005, 2009), and Pecina (2010). (source)

The underlying assumption is that $W1$ and $W2$ are independent. $I(W1, W2) = 0$ if and only if $W1$ and $W2$ are independent. (source)

Although the example is hypothetical, the problem is not. It uncovers a mathematical weakness of many commonly used association measures. (source)

Nota terminológica / Terminological note

The term "association measures" encompasses various statistical techniques used in corpus linguistics to analyze relationships between words. While specific measures like mutual information and chi-squared are widely accepted, the choice of measure can depend on the research context and the nature of the data being analyzed. El término "medidas de asociación" abarca diversas técnicas estadísticas utilizadas en la lingüística de corpus para analiz

Términos relacionados / Related terms

collocation / colocación · **chi-squared** / test de chi-cuadrado · **mutual information** / información mutua · **association measures** / medidas de asociación · **statistical significance** / significancia estadística · **keyword analysis** / análisis de palabras clave

medidas de asociación

Frecuencia y estadística

Definición

Las medidas estadísticas que evalúan la fuerza y significancia de la relación entre dos variables, comúnmente representadas en tablas de contingencia. Ejemplos de medidas de asociación incluyen la información mutua, la prueba exacta de Fisher y el chi-cuadrado, que ayudan a determinar las colocaciones notables en los datos lingüísticos. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 2 pmw: 2.39

balanced corpus

Corpus design and compilation

Definition

A type of corpus that aims to include equal amounts of text from different sources, such as spoken or written language varieties. The concept is often associated with representativeness, although achieving true balance is considered practically and theoretically challenging, relying heavily on intuition rather than empirical measures. The notion of balance is frequently debated among corpus linguists, with some arguing that it is impossible to create a corpus that meets the criteria of both representativeness and balance.

Frequency (EN corpus)

abs: 39 pmw: 30.70

Corpus evidence (EN)

"equal amounts of text from different sources, say, spoken or written English." (Kennedy 1998: 63)

"While balance is often considered a sine qua non of corpus design, any claim of corpus balance is largely an act of faith rather than a statement of fact..." (McEnery et al. 2006: 16)

"it seems impossible to create a linguistic corpus meeting the criteria of representativeness and/or balance." (Stefanowitsch 2020: 30)

Nota terminológica / Terminological note

The term "balanced corpus" is often contested within the field of corpus linguistics, as achieving true balance is seen as an ideal rather than a practical reality. This ongoing debate highlights the complexities involved in corpus design and the challenges of representativeness in linguistic research. El término "corpus equilibrado" es a menudo objeto de controversia en el campo de la lingüística de corpus, ya que lograr un equilibrio verdadero

Términos relacionados / Related terms

representativeness / representatividad · **corpus design** / diseño de corpus · **general corpus** / corpus general · **sample** / muestra · **frequency** / frecuencia · **corpus compilation** / compilación de corpus

corpus equilibrado

Diseño y compilación de corpus

Definición

Un tipo de corpus que busca incluir cantidades iguales de texto de diferentes fuentes, como variedades del lenguaje hablado o escrito. Este concepto se asocia a menudo con la representatividad, aunque lograr un equilibrio verdadero se considera un desafío práctico y teórico, dependiendo en gran medida de la intuición en lugar de medidas empíricas. La noción de equilibrio es objeto de debate entre los lingüistas de corpus, con algunos argumentando que es imposible crear un corpus que cumpla con los criterios de representatividad y equilibrio.

Frecuencia (corpus ES)

abs: 9 pmw: 11.09

Evidencia en corpus (ES)

"el objetivo real es que esté equilibrado (es decir, que contenga textos con un volumen suficiente para cada uno de los corpus virtuales que se puedan obtener de forma dinámica mediante la selección de valores en los diferentes parámetros de consulta)." (Rojo, G. 2016)

"Un corpus equilibrado recoge el mismo número o una porción similar de muestras para representar las diferentes variedades, géneros, registros, fuentes, etc." (Bernal Chávez, J. A. 2018)

"Todo corpus es una muestra extraída de una población cuyas características desconocemos..." (Rojo, G. 2016)

Bank of English

Reference corpora

Definition

A large corpus of contemporary English texts, this resource consists of a carefully selected subset of 650 million words from various sources. It is designed to reflect the everyday use of English, providing authentic evidence for linguistic research and analysis. Unlike static corpora, it functions as a monitor corpus, allowing for the ongoing tracking of language change over time, although it has been critiqued for potential imbalances in its categories.

Frequency (EN corpus)

abs: 47 pmw: 37.00

Corpus evidence (EN)

"The Bank of English provides Digital Text Corpora (Part 2) the most authentic and objective evidence of English that people read, write, speak and hear every day." (2018_Sekhar Dash, N., Arulmozi, S.)

"The multifaceted variety of texts represented in Bank of English is kept under constant review as new texts are introduced in order to maintain balance." (2018_Sekhar Dash, N., Arulmozi, S.)

"By this definition, in fact, almost all the corpora discussed above are snapshot corpora. Even the diachronic ones are, because they've not been designed to be added to later... the Bank of English." (2016_Weisser, M.)

Bank of English

Corpus de referencia

Definición

Un corpus extenso de textos contemporáneos en inglés, que consiste en un subconjunto cuidadosamente seleccionado de 650 millones de palabras de diversas fuentes. Está diseñado para reflejar el uso cotidiano del inglés, proporcionando evidencia auténtica para la investigación y el análisis lingüístico. A diferencia de los corpus estáticos, funciona como un corpus monitor, permitiendo el seguimiento continuo de los cambios lingüísticos a lo largo del tiempo, aunque ha sido criticado por posibles desequilibrios en sus categorías.

Frecuencia (corpus ES)

abs: 7 pmw: 8.62

Evidencia en corpus (ES)

"Sinclair hace ya bastantes años. En la actualidad, sin embargo, el Bank of English 'is a subset of 650 million words from a carefully chosen selection of sources'." (2021_Rojo, G.)

"La referencia inicial está en Sinclair (1991, 24–26), aunque el concepto se complica bastante y a ello contribuyen también las dificultades de la traducción al español de la expresión inglesa." (2021_Rojo, G.)

"El Bank of English representa un corpus monitor que permite el seguimiento de cambios en el uso del lenguaje." (2021_Rojo, G.)

Nota terminológica / Terminological note

The term "Bank of English" is primarily used in the context of corpus linguistics to denote a specific resource for linguistic research. Its classification as a monitor corpus highlights its dynamic nature, although its effectiveness in representing language change has been debated. El término "Bank of English" se utiliza principalmente en el contexto de la lingüística de corpus para denotar un recurso específico para la investigación lingüística

Términos relacionados / Related terms

monitor corpus / corpus monitor · **BNC** / BNC · **corpus design** / diseño de corpus · **corpus compilation** / compilación de corpus · **frequency** / frecuencia

BNC

Reference corpora

Definition

A large-scale linguistic resource representing a wide range of modern British English, comprising both written and spoken texts. The written component accounts for 90% of the corpus, including diverse text types such as newspapers, academic publications, and fiction, while the spoken part captures informal conversations and various interactional contexts. Initially released in 1995, it serves as a foundational reference corpus for linguistic research and analysis.

Frequency (EN corpus)

abs: 942 pmw: 741.51

Corpus evidence (EN)

The BNC represents a wide range of modern British English. (2018_Sekhar Dash, N., Arulmozi, S.)

The written part covers 90% of the total text samples and includes extracts from regional and national newspapers, specialist periodicals and journals for all ages and interests, academic books and popular fiction, published and unpublished letters and memoranda, school and university essays, and many other kinds of written text. (2018_Sekhar Dash, N., Arulmozi, S.)

To date, the BNC contains 500 million words comprising more than 5,000 text types. (2018_Sekhar Dash, N., Arulmozi, S.)

Nota terminológica / Terminological note

The BNC has been a cornerstone in corpus linguistics since its release, serving as a benchmark for the development of other corpora and linguistic tools. Its comprehensive design allows for a variety of linguistic analyses, although its representativeness may be challenged by the emergence of larger, web-based corpora. El BNC ha sido un pilar en la lingüística de corpus desde su lanzamiento, sirviendo como un punto de referencia para el desarrollo

Términos relacionados / Related terms

corpus / corpus · **reference corpus** / corpus de referencia · **frequency** / frecuencia · **annotation** / anotación · **tagset** / tagset · **general corpus** / corpus general

BNC

Corpus de referencia

Definición

Recurso lingüístico de gran escala que representa una amplia gama del inglés británico moderno, compuesto por textos escritos y hablados. La parte escrita constituye el 90% del corpus, incluyendo diversos tipos de textos como periódicos, publicaciones académicas y ficción, mientras que la parte hablada captura conversaciones informales y varios contextos de interacción. Lanzado inicialmente en 1995, sirve como un corpus de referencia fundamental para la investigación y el análisis lingüístico.

Frecuencia (corpus ES)

abs: 40 pmw: 49.27

Evidencia en corpus (ES)

A pesar de ello, también podemos encontrar algunos problemas en la utilización de la web que tienen que ver con el "ruido" que se genera debido al material no lingüístico. (2017_González Fernández, A.)

BNCWeb

Reference corpora

Definition

A web-based interface designed for searching and processing data from the British National Corpus (BNC), offering functionalities such as collocation analysis and distribution sorting. This tool facilitates linguistic analysis through a user-friendly platform, contrasting with CQPweb, which supports multiple corpora and advanced query syntax. The methodological emphasis on accessibility and ease of use is evident in its development for researchers.

Frequency (EN corpus)

abs: 188 pmw: 147.99

Corpus evidence (EN)

BNCweb is a user-friendly web-based interface that was created to search and process the data contained in the BNC. (2021_Hoffmann, S., Arndt-Lappe, S.)

It provides easy access to a wide range of functions that make it possible to linguistically analyse the results of corpus queries (e.g. collocations, distribution across metatextual categories, sorting of query results). (2021_Hoffmann, S., Arndt-Lappe, S.)

BNCweb also lets you list the PoS categories that collocate with the node by selecting 'collocations on POS-tags' next to 'Information'. (2016_Weisser, M.)

BNCWeb

Corpus de referencia

Definición

Una interfaz web diseñada para la búsqueda y el procesamiento de datos del Corpus Nacional Británico (BNC), que ofrece funcionalidades como el análisis de colocaciones y la clasificación de resultados. Esta herramienta facilita el análisis lingüístico a través de una plataforma accesible, en contraste con CQPweb, que admite múltiples corpora y una sintaxis de consulta avanzada. La énfasis metodológica en la accesibilidad y la facilidad de uso es evidente en su desarrollo para investigadores.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Nota terminológica / Terminological note

The term BNCWeb is specifically associated with the British National Corpus and its functionalities, emphasizing user accessibility and linguistic analysis capabilities. Variations in usage may arise from the introduction of newer tools like CQPweb, which offer broader functionalities and support for multiple corpora. El término BNCWeb está asociado específicamente con el Corpus Nacional Británico y sus funcionalidades, enfatizando la accesibilidad

Términos relacionados / Related terms

British National Corpus / British National Corpus · **CQPweb** / CQPweb · **Corpus query language** / lenguaje de consulta de corpus · **Corpus linguistics** / lingüística de corpus · **Collocation** / colocación · **Annotation** / anotación

British National Corpus

Reference corpora

Definition

A large corpus of modern English texts, this resource contains hundreds of millions of words from representative samples of both written and spoken English across various text types and disciplines. It is scientifically designed to reflect a wide cross-section of contemporary British English, capturing the spoken and written practices of native speakers. The corpus was compiled through a collaborative effort between industry and academia, emphasizing its methodological rigor in corpus linguistics.

Frequency (EN corpus)

abs: 122 pmw: 96.03

Corpus evidence (EN)

"The British National Corpus (BNC) is a large corpus of modern English texts." (2018_Sekhar Dash, N., Arulmozi, S.)

"It contains hundreds of million of words of representative samples from both written and spoken English texts from a wide variety of text types and disciplines." (2018_Sekhar Dash, N., Arulmozi, S.)

"The corpus-building activities were carried out and managed by a consortium built from direct collaboration between industry and academics." (2018_Sekhar Dash, N., Arulmozi, S.)

Nota terminológica / Terminological note

The British National Corpus is a foundational resource in corpus linguistics, often cited for its methodological rigor and representativeness. Its ongoing relevance is evidenced by its continued use in linguistic research and the development of tools like BNCWeb, which enhance access to its data. El Corpus Nacional Británico es un recurso fundamental en la lingüística de corpus, a menudo citado por su rigor metodológico y representatividad. Su re

Términos relacionados / Related terms

reference corpus / corpus de referencia · **corpus design** / diseño de corpus · **spoken corpus** / corpus oral · **general corpus** / corpus general · **BNCWeb** / BNCWeb · **balanced corpus** / corpus equilibrado

British National Corpus

Corpus de referencia

Definición

Un corpus extenso de textos en inglés moderno, que incluye cientos de millones de palabras de muestras representativas de textos escritos y orales de diversos tipos y disciplinas. Diseñado científicamente para reflejar una amplia sección transversal del inglés británico contemporáneo, captura las prácticas habladas y escritas de los hablantes nativos. La elaboración del corpus se realizó mediante una colaboración entre la industria y la academia, lo que subraya su rigor metodológico en la lingüística de corpus.

Frecuencia (corpus ES)

abs: 19 pmw: 23.41

Evidencia en corpus (ES)

"El British National Corpus (BNC) es un corpus extenso de textos en inglés moderno." (2018_Bernal Chávez, J. A. . Hincapié Moreno, D. A.)

"Los textos naturales hacen referencia a textos producidos en situaciones comunicativas reales, es decir, conversaciones, emisiones de radio, artículos científicos, novelas, etc." (2018_Bernal Chávez, J. A. . Hincapié Moreno, D. A.)

"El BNC representa una colección de textos que caracterizan una variedad del inglés." (2016_Rojo, G.)

Brown Corpus

Reference corpora

Definition

A widely recognized digital text corpus, this collection consists of 1 million words of American English texts compiled in 1961 by Nelson Francis and Henry Ku $\blacksquare$ era. It serves as a foundational resource in linguistic research, influencing the design of subsequent corpora and methodologies in corpus linguistics. The Brown Corpus is notable for its balanced representation of various text types, contrasting with more specialized corpora that focus on specific genres or registers.

Frequency (EN corpus)

abs: 225 pmw: 177.11

Corpus evidence (EN)

The goal is to refer to some of the big digital corpora available today with a focus on the patterns of their formation, the type of content included in them, and the way these corpora are being used in various linguistic works. (source)

In the year 1961, two linguists of the Brown University, USA, namely, Nelson Francis and Henry Ku $\blacksquare$ era, first initiated an attempt to develop a text corpus of 1 million words from English texts written and used in America. (source)

This corpus is globally accepted as the first language corpus generated in digital form. (source)

Nota terminológica / Terminological note

The Brown Corpus is often regarded as a pioneering effort in corpus linguistics, setting a standard for future corpora in terms of size and representativeness. Its influence extends to various linguistic applications, including lexicography and language technology, although its specific methodologies may be contested in light of advancements in corpus design. El Corpus de Brown es considerado un esfuerzo pionero en la lingüística de corpus, estab

Términos relacionados / Related terms

reference corpus / corpus de referencia · **general corpus** / corpus general · **BNC** / BNC · **corpus design** / diseño de corpus · **frequency** / frecuencia · **text type** / tipo de texto

Brown Corpus

Corpus de referencia

Definición

Este corpus de texto digital, reconocido ampliamente, está constituido por 1 millón de palabras de textos en inglés americano, compilado en 1961 por Nelson Francis y Henry Ku $\blacksquare$ era. Sirve como un recurso fundamental en la investigación lingüística, influyendo en el diseño de corpora posteriores y en las metodologías de la lingüística de corpus. El Corpus de Brown es notable por su representación equilibrada de diversos tipos de texto, en contraste con corpora más especializados que se centran en géneros o registros específicos.

Frecuencia (corpus ES)

abs: 54 pmw: 66.52

Evidencia en corpus (ES)

En este sentido, el corpus de Brown es de rango amplio, a pesar de ser mucho más pequeño que los de noticias que se construyen en la actualidad. (fuente)

El SEU fue concebido como un corpus, pero sin el componente computacional, de modo que la extracción de la información se realizaba mediante la confección de fichas de papel que reflejaban los ejemplos de diferentes fenómenos contenidos en el corpus. (fuente)

La distribución de los tipos de texto del Brown Corpus está inspirada, sin duda, en la que se hace en el SEU. (fuente)

chi-squared

Frequency and statistics

Definition

A statistical measure used to assess the association between categorical variables by comparing observed and expected frequencies. The chi-squared statistic indicates the degree of deviation from independence, with higher values suggesting a stronger association between the variables. This test is commonly employed in corpus linguistics to analyze the significance of variable relationships, contrasting with correlation measures that assess linear relationships.

Frequency (EN corpus)

abs: 88 pmw: 69.27

Corpus evidence (EN)

R, you do not need to use a χ^2 distribution table anymore. > test <- chisq.test(data) > test Pearson's Chi-squared test data: data X-squared = 89.999, df = 6, p-value < 2.2e-16 (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

You test your observed χ^2 value for significance by comparing it to the critical χ^2 value observed at the intersection of the number of degrees of freedom in your data table and the desired level of significance. (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

A chi-squared test compares expected and observed frequencies; greater value of the chi-squared statistic indicates an overall greater difference. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Nota terminológica / Terminological note

The chi-squared test is a fundamental statistical tool in corpus linguistics, primarily used for analyzing categorical data relationships. Its application is crucial for determining the significance of associations, contrasting it with correlation measures that focus on linear relationships. El test de chi-cuadrado es una herramienta estadística fundamental en la lingüística de corpus, utilizada principalmente para analizar las relaciones en dato

Términos relacionados / Related terms

probability / probabilidad · **statistical significance** / significancia estadística · **statistical significance** / significancia estadística · **dataset** / conjunto de datos · **frequency** / frecuencia

test de chi-cuadrado

Frecuencia y estadística

Definición

El chi-cuadrado es una medida estadística utilizada para evaluar la asociación entre variables categóricas al comparar frecuencias observadas y esperadas. Este estadístico indica el grado de desviación de la independencia, siendo valores más altos indicativos de una asociación más fuerte entre las variables. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 2 pmw: 2.39

CLAWS

Tools and software

Definition

A software tool designed for part-of-speech tagging, which assigns grammatical categories to words in a text. The system is particularly optimized for written language, yet it exhibits limitations when applied to spoken language, as evidenced by its handling of distinct verb forms and pronouns in various contexts. CLAWS operates within a probabilistic framework, allowing for the disambiguation of tags based on contextual usage, which contrasts with simpler tagging methods that do not account for such complexities.

Frequency (EN corpus)

abs: 124 pmw: 97.61

Corpus evidence (EN)

"taggers like CLAWS are really optimised for written language, but often still have a number of problems when it comes to dealing with spoken language appropriately." (source)

"CLAWS has assigned two tags to a word form (e.g. VVB-NN1), even if you might think that definitely just one of the two can be correct." (source)

"In CLAWS by default second person singular verb forms are assigned the same tags as the equivalent uninflected form." (source)

Nota terminológica / Terminological note

The term CLAWS is primarily associated with part-of-speech tagging in corpus linguistics, emphasizing its role in enhancing the analysis of written texts. Its probabilistic approach to tagging distinguishes it from simpler methods, although its limitations in spoken language contexts are acknowledged. El término CLAWS se asocia principalmente con el etiquetado de partes del discurso en la lingüística de corpus, enfatizando su papel en la mejora d

Términos relacionados / Related terms

tagger / *etiquetador* · **POS tagging** / *etiquetado morfosintáctico* · **annotation** / *anotación* · **corpus annotation** / *anotación de corpus* · **grammar** / *gramática* · **concordance** / *concordancia*

CLAWS

Herramientas y software

Definición

CLAWS es una herramienta de software diseñada para el etiquetado de partes del discurso, que asigna categorías gramaticales a las palabras en un texto. El sistema está especialmente optimizado para el lenguaje escrito, aunque presenta limitaciones en su aplicación al lenguaje hablado, lo que se refleja en su tratamiento de determinadas formas verbales y pronombres en distintos contextos. CLAWS opera mediante un marco probabilístico que permite la desambiguación de etiquetas en función del uso contextual, lo que lo diferencia de métodos de etiquetado más simples que no contemplan dicha complejidad.

Frecuencia (corpus ES)

—

clustering

Language processing

Definition

A set of techniques that classify data points into groups based on their similarities, clustering operates without prior information about groupings. This unsupervised method is exploratory, allowing patterns to emerge from the data rather than imposing preconceived notions. Common types include partitioning and hierarchical clustering, which differ in whether the number of groups is specified in advance.

Frequency (EN corpus)

abs: 73 pmw: 57.46

Corpus evidence (EN)

"Clustering is done thanks to unsupervised clustering techniques." (source)

"The objective of these grouping methods is to create groups with high similarity within the same class and low similarity between different classes." (source)

"Two common types of clustering are partitioning and hierarchical clustering." (source)

Nota terminológica / Terminological note

The term "clustering" is widely used in corpus linguistics to describe methods that explore data without predefined categories, emphasizing its exploratory nature. Variations in usage may arise from different methodological approaches, such as partitioning versus hierarchical clustering, which can affect the interpretation of results. El término "análisis de grupos" se utiliza ampliamente en la lingüística de corpus para describir métodos que exp

Términos relacionados / Related terms

corpus / corpus · **statistical significance** / significancia estadística · **clustering** / análisis de grupos · **dataset** / conjunto de datos · **descriptive statistics** / estadísticas descriptivas

análisis de grupos

Procesamiento del lenguaje

Definición

Conjunto de técnicas que clasifican puntos de datos en grupos según sus similitudes, el análisis de grupos se realiza sin información previa sobre las agrupaciones. Este método no supervisado es exploratorio, permitiendo que surjan patrones en los datos en lugar de imponer nociones preconcebidas. Dos tipos comunes son la partición y la agrupación jerárquica, que difieren en si se especifica o no el número de grupos de antemano.

Frecuencia (corpus ES)

abs: 12 pmw: 14.78

Evidencia en corpus (ES)

"Una rama de creciente importancia dentro de los estudios de corpus es el análisis de grupos o clustering." (fuente)

"El análisis de grupos comprende de un conjunto de técnicas que clasifican, sin información previa, los puntos de datos en grupos." (fuente)

"El análisis de grupos sin supervisión puede ser particularmente útil para un enfoque de 'abajo hacia arriba'." (fuente)

COCA

Reference corpora

Definition

A large and representative corpus of American English, COCA is designed to reflect everyday language use across various genres, including spoken, fiction, and academic texts. Its balanced structure allows for comprehensive linguistic analysis, making it a preferred choice among researchers for examining contemporary language patterns. The methodological emphasis on representativeness distinguishes COCA from other corpora, such as the British National Corpus (BNC), which focuses on British English.

Frequency (EN corpus)

abs: 292 pmw: 229.85

Corpus evidence (EN)

"Representativeness that the corpus is 'representative' of American English, but researchers often refer to the 'representativeness' of COCA as a reason for using it in their research." (Egbert, J. Biber, D. y Gray, B.)

"Firstly, the COCA corpus is probably the largest and the most representative corpus of the English language (of use in the USA)." (Dobric 2013: 48)

"In COCA, there are six main 'sections' labelled 'tv/movies', 'spoken', 'fiction', 'magazines', 'news', and 'academic'." (Barth, D., Schnell, S.)

Nota terminológica / Terminological note

The term COCA is widely recognized in corpus linguistics as a benchmark for studying contemporary American English, particularly due to its methodological rigor and representativeness. Its design principles and extensive data make it a critical resource for linguistic analysis, contrasting with other corpora that may focus on different varieties or aspects of language. El término COCA es ampliamente reconocido en la lingüística de corpus como un

Términos relacionados / Related terms

BNC / BNC · **corpus** / corpus · **frequency** / frecuencia · **corpus design** / diseño de corpus · **general corpus** / corpus general · **corpus-based** / basado en corpus · **tagset** / tagset

Corpus de inglés americano contemporáneo

Corpus de referencia

Definición

Un corpus extenso y representativo del inglés americano, COCA está diseñado para reflejar el uso del lenguaje cotidiano en diversos géneros, incluyendo textos hablados, de ficción y académicos. Su estructura equilibrada permite un análisis lingüístico integral, convirtiéndolo en una opción preferida entre los investigadores para examinar patrones del lenguaje contemporáneo. El énfasis metodológico en la representatividad distingue a COCA de otros corpus, como el British National Corpus (BNC), que se centra en el inglés británico.

Frecuencia (corpus ES)

abs: 3 pmw: 3.70

Evidencia en corpus (ES)

"Los corpus generales permiten, en efecto, extraer datos acerca de las características relevantes de la L2 y hacerlo de forma selectiva en función de los diferentes tipos de texto." (Rojo, G.)

"Los corpus de aprendientes son 'colecciones electrónicas de textos de aprendices de una lengua extranjera o segunda'." (Rojo, G., Palacios, I.)

"Los corpus de aprendientes incorporan los textos tal como han sido producidos originalmente, con el mínimo de codificación necesario para la recuperación adecuada de datos." (Rojo, G., Palacios, I.)

COHA

Reference corpora

Definition

A historical corpus of English, this resource contains over 400 million words of text spanning from the 1810s to the 2000s, making it significantly larger than other comparable historical corpora. The corpus is designed to be balanced by genre across decades, which allows for comprehensive linguistic analysis over time. Its extensive size and genre balance facilitate a robust examination of language change and usage patterns.

Frequency (EN corpus)

abs: 67 pmw: 52.74

Corpus evidence (EN)

COHA contains more than 400 million words of text from the 1810s-2000s (which makes it 50-100 times as large as other comparable historical corpora of English). (source)

The corpus is balanced by genre decade by decade. (source)

The most salient characteristic of the descriptions of corpus design and sampling we encountered in this survey was a preoccupation with corpus size, particularly as measured in number of words. (source)

Nota terminológica / Terminological note

The term COHA is specifically used to refer to a large historical corpus, which is distinct from other types of corpora, such as contemporary or learner corpora. Its unique design and extensive size make it a valuable resource for linguistic research focused on historical language use and change. El término COHA se utiliza específicamente para referirse a un corpus histórico grande, que es distinto de otros tipos de corpus, como los contemporáneos

Términos relacionados / Related terms

corpus / corpus · **historical corpus** / corpus histórico · **corpus design** / diseño de corpus · **frequency** / frecuencia · **token** / token · **BNC** / BNC

COHA

Corpus de referencia

Definición

Este corpus histórico del inglés contiene más de 400 millones de palabras de texto desde la década de 1810 hasta la de 2000, lo que lo convierte en un recurso considerablemente más grande que otros corpus históricos comparables. Su diseño equilibrado por géneros a lo largo de las décadas permite un análisis lingüístico exhaustivo a lo largo del tiempo, facilitando el estudio de los cambios y patrones de uso del lenguaje.

Frecuencia (corpus ES)

abs: 5 pmw: 6.16

Evidencia en corpus (ES)

El corpus de hablantes nativos puede en casos de este tipo proporcionar un panorama de lo que se encuentra realmente en los textos (orales o escritos) frente a las descripciones habituales en los tratados gramaticales. (fuente)

El análisis de errores gana en precisión y posibilidades de generalización si el corpus ha recibido ese tipo de codificación. (fuente)

Una forma rápida y cómoda de ver algunos datos de interés consiste en buscar en el CAES casos de artículos masculinos seguidos inmediatamente por sustantivos femeninos. (fuente)

colligation

Lexicon and phraseology

Definition

The concept denotes the statistically significant co-occurrence of specific parts of speech, such as verbs, nouns, and adjectives, within a grammatical framework. Unlike collocation, which focuses on lexical co-occurrences, colligation emphasizes the grammatical relationships and patterns that emerge from these co-occurrences. This term is methodologically relevant in corpus-based studies, as it aids in understanding the structural tendencies of language use.

Frequency (EN corpus)

abs: 15 pmw: 11.81

Corpus evidence (EN)

Colligation is the co-occurrence of specific parts of speech (verbs, nouns, adjectives, etc.) with each other; for example, we can estimate that articles in English show different colligational patterns with nouns, adjectives, and adverbs. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Colligation is like collocation except that it has a grammatical component. It is therefore the statistically significant co-occurrence of a surface phenomenon (a linguistic form) with a deeper, grammatical phenomenon. (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

The term "colligation" is primarily used in the context of grammatical analysis within corpus linguistics, emphasizing the structural relationships between parts of speech. Its distinction from collocation highlights the importance of grammatical frameworks in understanding language patterns. El término "coligación" se utiliza principalmente en el contexto del análisis gramatical dentro de la lingüística de corpus, enfatizando las relaciones est

Términos relacionados / Related terms

collocation / colocación · **grammar** / gramática · **corpus-based** / basado en corpus · **association measures** / medidas de asociación · **collocate** / colocado

coligación

Léxico y fraseología

Definición

Este concepto se refiere a la co-ocurrencia estadísticamente significativa de partes del habla específicas, como verbos, sustantivos y adjetivos, dentro de un marco gramatical. A diferencia de la colocación, que se centra en las co-ocurrencias léxicas, la coligación enfatiza las relaciones y patrones gramaticales que surgen de estas co-ocurrencias. Este término es relevante metodológicamente en estudios basados en corpus, ya que ayuda a comprender las tendencias estructurales del uso del lenguaje.

Frecuencia (corpus ES)

abs: 3 pmw: 3.70

Evidencia en corpus (ES)

Los corpus generales permiten, en efecto, extraer datos acerca de las características relevantes de la L2 y hacerlo de forma selectiva en función de los diferentes tipos de texto. (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

Para que ese conjunto de textos comience a resultar verdaderamente útil en estudios sobre la adquisición de una segunda lengua es necesario ir añadiendo capas con información referente a las características externas o internas de esos textos. (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

collocate

Lexicon and phraseology

Definition

A word that co-occurs with a node word more frequently than expected within a specified span, indicating a significant association. The identification of collocates can vary among researchers, with some focusing on sequential co-occurrence while others consider structural relationships within grammatical constructions. This term is essential in corpus linguistics for analyzing lexical relations and semantic differences.

Frequency (EN corpus)

abs: 101 pmw: 79.50

Corpus evidence (EN)

"Some treat co-occurrence as a purely sequential phenomenon defining collocates as words that co-occur more frequently than expected within a given span." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"Researchers differ with respect to what types of co-occurrence they focus on when identifying collocations." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"The degree of collation between lexemes is measured in terms of the relative quantity of instances where lexemes cooccur compared to when they do not." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Nota terminológica / Terminological note

The term "collocate" is often used interchangeably with "collocation," though the former specifically refers to the individual words that form these patterns. Variations in definition can arise based on the methodological focus of different researchers, particularly regarding the span of co-occurrence considered significant. El término "colocalizador" se utiliza a menudo de manera intercambiable con "colocación", aunque el primero se refiere esp

Términos relacionados / Related terms

collocation / colocación · **colligation** / coligación · **association measures** / medidas de asociación · **keyword** / palabra clave · **corpus-based** / basado en corpus

colocado

Léxico y fraseología

Definición

Una palabra que coocurre con un término nodo con mayor frecuencia de lo esperado dentro de un intervalo específico, lo que indica una asociación significativa. La identificación de colocalizadores puede variar entre investigadores, algunos centrándose en la coocurrencia secuencial y otros considerando relaciones estructurales dentro de construcciones gramaticales. Este término es fundamental en la lingüística de corpus para analizar relaciones léxicas y diferencias semánticas.

Frecuencia (corpus ES)

abs: 3 pmw: 3.70

Evidencia en corpus (ES)

"Los corpus de español que incorporan información de esta naturaleza son muy limitados y de tamaño bastante reducido..." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

"La investigación con los corpus generales no consiste habitualmente en determinar la frecuencia de un cierto elemento léxico..." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

"La inclusión de estos metadatos en el lugar adecuado permite hacer luego la recuperación selectiva de los casos que interesen." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

collocation

Lexicon and phraseology

Definition

A specific type of lexical association, this term denotes the syntagmatic relationship between words, characterized by their co-occurrence within a defined proximity in text. The analysis of collocations is grounded in the principle that the meaning of a target word is influenced by the words surrounding it, as evidenced by the exploration of mutual expectations among collocates. This concept is methodologically significant in corpus linguistics, where it serves as a basis for quantitative research designs assessing word associations.

Frequency (EN corpus)

abs: 260 pmw: 204.66

Corpus evidence (EN)

"Collocation is the syntagmatic association of lexical items, quantifiable, textually, as the probability that there will occur, at n removes (a distance of n lexical items) from an item x, the items a, b, c..." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"The meaning of a target word is based on the meaning of the words that surround it." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

"This sort of collocation analysis works well when it comes to teasing apart homonymous lexemes..." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

The term "collocation" is widely used in corpus linguistics to describe specific lexical relationships, often analyzed quantitatively. However, its application may vary across different linguistic traditions, with some scholars advocating for alternative terms that better capture the nuances of these associations. El término "colocación" se utiliza ampliamente en la lingüística de corpus para describir relaciones léxicas específicas, a menudo an

Términos relacionados / Related terms

collocate / colocado · **phraseology** / fraseología · **concordance** / concordancia · **corpus** / corpus · **frequency** / frecuencia · **keyword analysis** / análisis de palabras clave

colocación

Léxico y fraseología

Definición

Este término designa una relación léxica específica que se caracteriza por la asociación sintagmática entre palabras, evidenciada por su coocurrencia en una proximidad definida dentro del texto. El análisis de colocaciones se fundamenta en el principio de que el significado de una palabra objetivo se ve influenciado por las palabras que la rodean, lo que se refleja en las expectativas mutuas entre los colocados. Este concepto tiene un estatus metodológico significativo en la lingüística de corpus, sirviendo como base para diseños de investigación cuantitativa que evalúan asociaciones entre pal

Frecuencia (corpus ES)

abs: 29 pmw: 35.72

Evidencia en corpus (ES)

"No existe una cantidad exacta para determinar que una frecuencia es alta, ya que este valor depende del tamaño del corpus..." (2018_Bernal Chávez, J. A. . Hincapié Moreno, D. A._Lingüística de corpus)

"La tarea de examinar la colocación de los intensificadores según el valor afectivo del adjetivo es una idea que se ha extendido del español hasta el portugués." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"El análisis de colocaciones se fundamenta en el principio de que el significado de una palabra objetivo se ve influenciado por las palabras que la rodean..." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

collocational strength

Lexicon and phraseology

Definition

The measure of the degree to which lexemes co-occur within a specific context, indicating their semantic relationship. Collocational strength is particularly relevant in corpus-based studies, as it highlights distinctions between synonyms by analyzing the relative frequency of co-occurrence compared to non-co-occurrence. This concept is essential for understanding lexical relations and is often assessed using statistical association measures.

Frequency (EN corpus)

abs: 6 pmw: 4.72

Corpus evidence (EN)

Collocational strength is particularly relevant in corpus-based studies of lexical relations, for example, where collocations point to semantic differences between lexemes that are often thought of as synonyms. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

The degree of collation between lexemes is measured in terms of the relative quantity of instances where lexemes cooccur compared to when they do not. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

To sum up, when doing collocational research, we should use the best association measures available. (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "collocational strength" is primarily used in the context of corpus linguistics to analyze lexical relationships and is often assessed through various statistical measures. Its application is crucial for distinguishing between nuanced meanings of words that may appear synonymous in isolation. El término "fuerza colacional" se utiliza principalmente en el contexto de la lingüística de corpus para analizar relaciones léxicas y se evalúa a

Términos relacionados / Related terms

collocation / colocación · **association measures** / medidas de asociación · **keyword analysis** / análisis de palabras clave · **colligation** / coligación · **corpus-based** / basado en corpus

fuerza colacional

Léxico y fraseología

Definición

La fuerza colacional es la medida de la relación entre lexemas basada en su co-ocurrencia en contextos específicos, lo que permite identificar diferencias semánticas. Este concepto es fundamental en los estudios de fraseología y léxico, ya que ayuda a distinguir entre términos que pueden parecer sinónimos a partir de su uso en corpus. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

—

comparable corpus

Corpus design and compilation

Definition

A collection of texts that are similar in type and content, potentially spanning one or more languages, distinguished from parallel corpora by not requiring direct translations. Comparable corpora are utilized in various linguistic applications, including translation studies, to achieve terminological and stylistic cohesion. They serve as valuable resources for researchers aiming to analyze language use across different contexts and genres.

Frequency (EN corpus)

abs: 72 pmw: 56.68

Corpus evidence (EN)

an 'aligned corpus' should be a kind of translation corpus where text samples from one language and their translations from other language are aligned... a 'comparable corpus' by definition should contain a pair of corpora from one language or from two or more languages, as the situation requires; (2018_Sekhar Dash, N., Arulmozi, S.)

In the last decades, parallel and comparable corpora have played an increasingly important role and parallel corpus linguistics has emerged as a distinct field of research within corpus linguistics. (2017_Doval, I.)

The chapter first outlines the key features of parallel corpora... and describes the main methods of parallel corpus analysis, including the combined use of parallel and comparable corpora. (2020_Lefer, M. A.)

Nota terminológica / Terminological note

The term "comparable corpus" has gained prominence in recent years, particularly in the context of translation studies and cross-linguistic research. Its usage reflects a methodological approach that emphasizes the analysis of similar texts rather than direct translations, which distinguishes it from parallel corpora. El término "corpus comparable" ha ganado prominencia en los últimos años, especialmente en el contexto de los estudios de traducc

Términos relacionados / Related terms

parallel corpus / corpus paralelo · **reference corpus** / corpus de referencia · **corpus compilation** / compilación de corpus · **multilingual corpus** / corpus multilingüe · **corpus design** / diseño de corpus · **corpus annotation** / anotación de corpus

corpus comparable

Diseño y compilación de corpus

Definición

Colección de textos que son similares en tipo y contenido, que pueden abarcar una o más lenguas, y que se diferencian de los corpus paralelos al no requerir traducciones directas. Los corpus comparables se utilizan en diversas aplicaciones lingüísticas, incluyendo los estudios de traducción, para lograr cohesión terminológica y estilística. Son recursos valiosos para investigadores que buscan analizar el uso del lenguaje en diferentes contextos y géneros.

Frecuencia (corpus ES)

abs: 23 pmw: 28.33

Evidencia en corpus (ES)

Los corpus comparables, conformados por un texto y su traducción a una o varias lenguas, consisten en compilaciones de textos similares mediante memorias de traducción, relevantes para conseguir una cohesión terminológica y estilística en la praxis traductológica. (2022_Molina Plaza, S.)

Un corpus comparable es una colección de textos originales en una lengua A que pertenecen al mismo ámbito de especialidad y tienen un contenido similar a los textos sometidos a traducción a una lengua B, con los que se suelen comparar. (2021_Rojo, G.)

En muchas ocasiones el investigador se ve obligado a diseñar y crear su propio corpus y dotarlo del formato adecuado para consultarlo... especialmente cuando se trata de corpus complejos de finalidades muy específicas como pueden ser los corpus paralelos o comparables utilizados en los estudios de traducción. (2016_Molés-Cases, T.)

computational linguistics

Related disciplines

Definition

A branch of linguistics that focuses on the development of algorithms and computational models for processing and analyzing human language. This field intersects with natural language processing and corpus linguistics, emphasizing the use of computational tools to enhance linguistic research and applications. The methodological advancements in computational linguistics have significantly influenced the empirical study of language, enabling more accurate analyses of linguistic phenomena.

Frequency (EN corpus)

abs: 138 pmw: 108.63

Corpus evidence (EN)

"In recent years, increased work has been carried out on 'Web As Corpus,' particularly in the areas of lexicography and computational linguistics." (source)

"Indeed, online tools like WebCorp, 'a suite of tools which allows access to the World Wide Web as a corpus - a large collection of texts from which facts about the language can be extracted,' are available." (source)

"The survey included journals from six different subdisciplines (general linguistics, applied linguistics, discourse analysis, sociolinguistics, computational linguistics, and corpus linguistics)." (source)

Nota terminológica / Terminological note

The term "computational linguistics" encompasses a variety of methodologies and applications, often overlapping with fields such as natural language processing and corpus linguistics. Its definitions can vary, with some scholars emphasizing its algorithmic aspects while others focus on its empirical applications in linguistic research. El término "lingüística computacional" abarca una variedad de metodologías y aplicaciones, a menudo superponiéndose.

Términos relacionados / Related terms

corpus linguistics / lingüística de corpus · **natural language processing** / procesamiento del lenguaje natural · **corpus-based** / basado en corpus · **annotation** / anotación · **statistical significance** / significancia estadística · **dataset** / conjunto de datos

lingüística computacional

Disciplinas afines

Definición

Una rama de la lingüística que se centra en el desarrollo de algoritmos y modelos computacionales para el procesamiento y análisis del lenguaje humano. Este campo se entrelaza con el procesamiento del lenguaje natural y la lingüística de corpus, destacando el uso de herramientas computacionales para mejorar la investigación y aplicaciones lingüísticas. Los avances metodológicos en la lingüística computacional han influido significativamente en el estudio empírico del lenguaje, permitiendo análisis más precisos de los fenómenos lingüísticos.

Frecuencia (corpus ES)

abs: 97 pmw: 119.49

Evidencia en corpus (ES)

"La lingüística computacional ha ampliado el ámbito de estudio del lenguaje, que actualmente se concibe en el marco más amplio de la comunicación humana y no como una simple álgebra formal." (fuente)

"Gracias a la revolución digital, ahora tenemos acceso a muestras de uso real del lenguaje por primera vez, lo que significa que la introspección ya no es la única forma de probar la adecuación de nuestros postulados teóricos." (fuente)

"Los corpus hacen posible una mirada profunda sobre las prácticas lingüísticas, ya que proporcionan grandes cantidades de observaciones del mundo real que abarcan varios registros, períodos, regiones y grupos sociales." (fuente)

concordance

Search and retrieval

Definition

A method for retrieving and displaying instances of a specific word or phrase within a text, highlighting its surrounding context. This technique allows researchers to analyze patterns of usage and semantic relationships, often employing software tools that facilitate the extraction of relevant data from corpora. The methodological significance of concordance is underscored by its application in both qualitative and quantitative linguistic studies.

Frequency (EN corpus)

abs: 161 pmw: 126.73

Corpus evidence (EN)

"Some concordance programs, such as the widely-used open-source Corpus Workbench... are able to 'understand' the structure of such annotations and offer a query syntax that allows the researcher to refer to this structure directly." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"First, let us make a concordance of words based on blood in Bram Stoker's Dracula: blood, bloody, bloodied, bleed, bleeding, etc." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

"The first approach is more useful if we are interested in metaphors involving any semantic domain... or by running a complex query for words from both semantic fields at the same time." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

concordancia

Búsqueda y consulta

Definición

Método para recuperar y mostrar instancias de una palabra o frase específica dentro de un texto, resaltando su contexto circundante. Esta técnica permite a los investigadores analizar patrones de uso y relaciones semánticas, utilizando a menudo herramientas informáticas que facilitan la extracción de datos relevantes de los corpus. La importancia metodológica de la concordancia se destaca por su aplicación en estudios lingüísticos tanto cualitativos como cuantitativos.

Frecuencia (corpus ES)

abs: 69 pmw: 85.00

Evidencia en corpus (ES)

"Las concordancias pueden traer el contexto sin modificaciones, esto es, con mayúsculas y minúsculas y con los signos de puntuación." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

"La ventana se define como la cantidad de texto que puede traerse acompañando a la palabra que se analiza en una concordancia." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

"La opción mayoritaria es la que establece la concordancia a partir del núcleo semántico..." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

Nota terminológica / Terminological note

The term "concordance" is widely used in corpus linguistics to denote a specific analytical method, with variations in its application depending on the corpus type and research focus. In Spanish, "concordancia" maintains the same methodological implications, emphasizing its role in linguistic analysis and teaching.

Términos relacionados / Related terms

corpus / corpus · **query** / consulta · **frequency** / frecuencia · **collocation** / colocación · **annotation** / anotación · **keyword** / palabra clave

concordance lines

Search and retrieval

Definition

A specific output format generated by concordancers, consisting of a sequence of text segments that display the context surrounding a target word or phrase. These lines typically present the node word in the center, flanked by its immediate left and right contexts, facilitating the analysis of word usage and patterns. This methodological tool is essential for corpus linguistics, allowing researchers to examine linguistic phenomena in situ.

Frequency (EN corpus)

abs: 16 pmw: 12.59

Corpus evidence (EN)

The results of these searches can usually also be saved to disk, together with additional information, such as the line number or file name where the occurrence was found. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Thus, words that actually occur on different lines in the text may still be presented as part of the context. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

A sample concordance of alphabetic and alphabetical in the BNC... (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

The term "concordance lines" is widely used in corpus linguistics to denote a specific output format that aids in the analysis of linguistic data. Variations in the presentation of these lines may occur based on the software used and the specific settings applied during the concordancing process. El término "líneas de concordancia" se utiliza ampliamente en la lingüística de corpus para denotar un formato de salida específico que ayuda en el análisis.

Términos relacionados / Related terms

concordance / concordancia · **KWIC** / KWIC · **corpus** / corpus · **query** / consulta · **collocation** / colocación · **annotation** / anotación

líneas de concordancia

Búsqueda y consulta

Definición

Las líneas de concordancia son un formato de salida generado por los concordadores, que consisten en una secuencia de segmentos de texto que muestran el contexto que rodea a una palabra o frase objetivo. Estas líneas presentan generalmente la palabra nodo en el centro, flanqueada por sus contextos inmediatos a la izquierda y a la derecha, facilitando el análisis del uso y los patrones lingüísticos. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 287 pmw: 342.63

confidence interval

Frequency and statistics

Definition

A statistical range that indicates the degree of uncertainty around a sample mean, allowing researchers to estimate the true population mean with a specified level of confidence. The width of the confidence interval is inversely related to the sample size, meaning larger samples yield more precise estimates. This concept is essential for understanding the tolerable error in estimating population parameters based on sample statistics.

Frequency (EN corpus)

abs: 46 pmw: 36.21

Corpus evidence (EN)

The confidence interval (ci) is a range of values around a mean score, related to the amount of error that a researcher is willing to tolerate in knowing the true mean in the operational domain. (source)

A bigger confidence interval means that the researcher is willing to tolerate more error and a less precise estimate of the mean score. (source)

The confidence interval is the window within which we can be 95% certain that the true population mean falls. (source)

Nota terminológica / Terminological note

The concept of confidence interval is crucial in statistical analysis, particularly in the context of estimating population parameters from sample data. Variations in its application may arise based on the chosen confidence level and the nature of the data being analyzed. El concepto de intervalo de confianza es crucial en el análisis estadístico, especialmente en el contexto de la estimación de parámetros poblacionales a partir de datos muestra

Términos relacionados / Related terms

sample size / tamaño de muestra · **standard deviation** / desviación estándar · **population** / población · **mean score** / puntuación media · **statistical significance** / significancia estadística

intervalo de confianza

Frecuencia y estadística

Definición

Un rango estadístico que indica el grado de incertidumbre alrededor de una media muestral, permitiendo a los investigadores estimar la verdadera media poblacional con un nivel de confianza especificado. El ancho del intervalo de confianza está inversamente relacionado con el tamaño de la muestra, lo que significa que muestras más grandes producen estimaciones más precisas. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

—

content words

Lexicon and phraseology

Definition

Lexical items that convey significant semantic meaning, distinguishing them from function words, which primarily serve grammatical purposes. Content words include proper nouns, common nouns, adjectives, and verbs, and are essential for conveying the core information of a text. Their identification is crucial in frequency analyses to explore semantically relevant vocabulary, as they significantly contribute to the overall meaning of language data.

Frequency (EN corpus)

abs: 39 pmw: 30.70

Corpus evidence (EN)

"none of the items in the list is a content word, the semantic information provided in Table 9.1 is essentially next to none." (Weisser, 2016)

"the majority of words MI identifies are content words, such as proper names, common nouns, adjectives and verbs." (Weisser, 2016)

"To be able to simplify the exploration of semantically relevant vocabulary in the data, it thus appears justified to remove such function words from our frequency analyses." (Weisser, 2016)

Nota terminológica / Terminological note

The term "content words" is widely accepted in corpus linguistics to denote words that carry semantic weight, essential for understanding the meaning of texts. Its usage is consistent across various linguistic studies, emphasizing the importance of distinguishing these words from function words in analyses. El término "palabras de contenido" es ampliamente aceptado en la lingüística de corpus para denotar palabras que llevan peso semántico, esenc

Términos relacionados / Related terms

function word / palabra funcional · **frequency** / frecuencia · **parts of speech** / categorías gramaticales · **keyword** / palabra clave · **collocation** / colocación · **corpus-based** / basado en corpus

palabras de contenido

Léxico y fraseología

Definición

Las palabras que aportan un significado semántico significativo, diferenciándose de las palabras funcionales, que cumplen principalmente funciones gramaticales. Las palabras de contenido incluyen nombres propios, sustantivos comunes, adjetivos y verbos, y son esenciales para transmitir la información central de un texto. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 3 pmw: 3.58

corpus

Foundational concepts

Definition

A large, principled sample of texts designed to represent a target domain of language use. This foundational concept in corpus linguistics serves as the basis for empirical research, allowing for generalizations about linguistic patterns within a specific context. The methodological status of a corpus is critical, as it influences the representativeness and validity of linguistic analyses derived from it.

Frequency (EN corpus)

abs: 18.125 pmw: 14267.29

Corpus evidence (EN)

A corpus is a large, principled sample of texts designed to represent a target domain of language use. (2022_Egbert J. Biber D. y Gray B.)

Most corpus research aims to generalize results from a corpus to the target domain. (2022_Egbert J. Biber D. y Gray B.)

Corpus representativeness is the extent to which a corpus permits accurate and meaningful generalizations about linguistic patterns that are typical in a domain. (2022_Egbert J. Biber D. y Gray B.)

Nota terminológica / Terminological note

The term "corpus" is foundational in the field of corpus linguistics, with its definition evolving alongside advancements in digital technology and linguistic research methodologies. Variations in corpus types, such as monolingual, multilingual, and specialized corpora, reflect the diverse applications and contexts in which corpora are utilized. El término "corpus" es fundamental en el campo de la lingüística de corpus, y su definición ha evolucionado.

Términos relacionados / Related terms

corpus linguistics / lingüística de corpus · **representativeness** / representatividad · **sample** / muestra · **corpus design** / diseño de corpus · **general corpus** / corpus general · **annotated corpus** / corpus anotado · **corpus compilation** / compilación de corpus

corpus

Conceptos fundacionales

Definición

Conjunto amplio y sistemático de textos que busca representar un dominio específico del uso del lenguaje. Este concepto fundamental en la lingüística de corpus es esencial para la investigación empírica, ya que permite realizar generalizaciones sobre patrones lingüísticos en contextos determinados. La calidad metodológica de un corpus es crucial, ya que afecta la representatividad y validez de los análisis lingüísticos que se derivan de él.

Frecuencia (corpus ES)

abs: 11.750 pmw: 14474.28

Evidencia en corpus (ES)

Corpus constituido por textos pertenecientes a una única lengua. (2021_Rojo, G.)

Se trata de un corpus de una variedad específica de lengua que incluye exclusivamente materiales pertenecientes a la mencionada variedad. (2023_Hernández García, V.)

Un corpus de propósito general, diseñado para que pueda ser utilizado en estudios de tipos muy diferentes. (2021_Rojo, G.)

corpus annotation

Annotation and markup

Definition

A systematic process that involves adding interpretative information to linguistic data within a corpus, enhancing its usability for various research questions. This process captures different types of information pertaining to linguistic representation, such as part-of-speech tagging and lemmatization, which are essential for accurate linguistic analysis. The design of annotation systems is influenced by specific research interests, making it a critical methodological component in corpus linguistics.

Frequency (EN corpus)

abs: 138 pmw: 108.63

Corpus evidence (EN)

"Corpus annotations capture different types of information pertaining to different levels of linguistic representation." (source)

"The specific design of annotation systems is codetermined by the specific research interests involved." (source)

"This enables users of the corpus to plan the construction of their queries targeting these annotations." (source)

Nota terminológica / Terminological note

The term "corpus annotation" is widely recognized in corpus linguistics as a foundational practice that enhances the analytical capabilities of linguistic data. Variations in annotation practices may arise due to differing research objectives or linguistic frameworks, which can lead to debates about the best methodologies for specific types of analysis. El término "anotación de corpus" es ampliamente reconocido en la lingüística de corpus como u

Términos relacionados / Related terms

part-of-speech tagging / etiquetado morfosintáctico · **annotation scheme** / esquema de anotación · **annotated corpus** / corpus anotado · **corpus design** / diseño de corpus · **morphological annotation** / anotación morfológica · **corpus compilation** / compilación de corpus

anotación de corpus

Anotación y marcado

Definición

Proceso sistemático que consiste en añadir información interpretativa a los datos lingüísticos dentro de un corpus, mejorando su utilidad para diversas preguntas de investigación. Esta práctica captura diferentes tipos de información relacionada con la representación lingüística, como el etiquetado de partes del discurso y la lematización, que son esenciales para un análisis lingüístico preciso. El diseño de los sistemas de anotación está influenciado por intereses de investigación específicos, lo que lo convierte en un componente metodológico crítico en la lingüística de corpus.

Frecuencia (corpus ES)

abs: 10 pmw: 12.32

Evidencia en corpus (ES)

"En este capítulo, se discutirán algunos problemas básicos de anotación para estos grandes corpus, principalmente el etiquetado de partes del discurso y la lematización, así como la precisión de la anotación en los diferentes corpus." (fuente)

"La característica distintiva de esta rama de la lingüística es pues la utilización de corpus textuales como fuente primaria de datos." (fuente)

"A lo largo del texto se intenta mostrar la relevancia de este tipo de datos para la teoría lingüística, en particular, para los modelos basados en el uso." (fuente)

corpus building

Corpus design and compilation

Definition

The process of assembling a collection of texts designed to represent a specific domain of language use, emphasizing the inclusion of a wide variety of linguistic data. This methodology aims to enhance the representativeness and reliability of the corpus, allowing for meaningful generalizations about linguistic patterns. The term is often contrasted with corpus design, which focuses more on the theoretical framework guiding the selection and organization of texts.

Frequency (EN corpus)

abs: 108 pmw: 85.01

Corpus evidence (EN)

"the primary goal of a corpus building project is to include as many words that are used in sentences as possible." (2022_Egbert J. Biber y Gray)

"the framework laid out in the book is intended to provide a practical solution to the difficult challenge of building highly representative corpora." (2022_Egbert J. Biber y Gray)

"the main point of this chapter is to understand the tensions between the principles of corpus design, as discussed in Chapter 3, and specific considerations of actual corpus building." (2023_Barth y Schnell)

construcción de corpus

Diseño y compilación de corpus

Definición

El proceso de reunir un conjunto de textos con el objetivo de representar un dominio específico del uso del lenguaje, priorizando la inclusión de una amplia variedad de datos lingüísticos. Esta metodología busca mejorar la representatividad y la fiabilidad del corpus, permitiendo generalizaciones significativas sobre los patrones lingüísticos. Se contrasta frecuentemente con el diseño de corpus, que se centra más en el marco teórico que guía la selección y organización de los textos.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"la construcción de un corpus textual implica fijar unos objetivos generales, establecer un diseño, seleccionar los textos adecuados." (2015_Rojo)

"la idea general, pues, es que un corpus consiste en un conjunto de objetos (casi siempre textos) reunidos con la intención de facilitar el análisis de su contenido." (2015_Rojo)

"un corpus constituido por textos pertenecientes a una única lengua." (2021_Rojo)

Nota terminológica / Terminological note

The term "corpus building" encompasses various methodologies and practices aimed at assembling linguistic data, which can vary significantly based on the intended research goals and the types of texts included. In Spanish, "construcción de corpus" is commonly used, reflecting similar practices and considerations in corpus linguistics. El término "construcción de corpus" abarca diversas metodologías y prácticas destinadas a reunir datos lingüísticos

Términos relacionados / Related terms

corpus design / diseño de corpus · **representativeness** / representatividad · **corpus compilation** / compilación de corpus · **sample** / muestra · **metadata** / metadatos

corpus compilation

Corpus design and compilation

Definition

The process of gathering and organizing a set of texts to create a representative sample for linguistic analysis. This involves making decisions about corpus design, structure, and the publication of the corpus, which is essential for ensuring accessibility and usability for researchers. The methodological considerations in corpus compilation are crucial for achieving representativeness and facilitating meaningful generalizations about language use.

Frequency (EN corpus)

abs: 44 pmw: 34.64

Corpus evidence (EN)

"The final step in corpus compilation is publication." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"Considerations of corpus design will also apply to compilations of small, focused research corpora." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"Corpus representativeness is the extent to which a corpus permits accurate and meaningful generalizations about linguistic patterns." (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

Nota terminológica / Terminological note

The term "corpus compilation" is widely used in corpus linguistics to denote the methodological process of assembling texts for analysis. Variations in its application may arise based on the specific goals of the research and the types of texts being compiled. El término "compilación de corpus" se utiliza ampliamente en la lingüística de corpus para denotar el proceso metodológico de reunir textos para su análisis. Las variaciones en su aplicaci

Términos relacionados / Related terms

corpus design / diseño de corpus · **representativeness** / representatividad · **metadata** / metadatos · **corpus compilation** / compilación de corpus · **corpus annotation** / anotación de corpus · **sample** / muestra

compilación de corpus

Diseño y compilación de corpus

Definición

El proceso de reunir y organizar un conjunto de textos con el fin de crear una muestra representativa para el análisis lingüístico. Esto implica tomar decisiones sobre el diseño y la estructura del corpus, así como sobre su publicación, lo cual es esencial para garantizar la accesibilidad y la usabilidad para los investigadores. Las consideraciones metodológicas en la compilación de corpus son cruciales para lograr la representatividad y facilitar generalizaciones significativas sobre el uso del lenguaje.

Frecuencia (corpus ES)

abs: 5 pmw: 6.16

Evidencia en corpus (ES)

"The exploitation of this corpus will help us translate more confidently a legal agreement from Italian into Spanish." (2022_Flores Acuña, E._Compilación de un corpus de especialidad con BootCat para la traducción jurídica italiano-español. El caso de un contrato de agencia_Onomázein)

"La compilación semiautomática del corpus especializado ad-hoc reduce significativamente el tiempo y esfuerzo de la compilación manual." (2022_Flores Acuña, E._Compilación de un corpus de especialidad con BootCat para la traducción jurídica italiano-español. El caso de un contrato de agencia_Onomázein)

"Construir un corpus textual implica fijar unos objetivos generales, establecer un diseño, seleccionar los textos adecuados." (2015_Rojo, G._Sobre los antecedentes de la lingüística de corpus_Studium Gramaticae)

corpus design

Corpus design and compilation

Definition

A systematic approach to creating a corpus that ensures it accurately represents a specific domain of language use. This involves careful selection and organization of texts based on explicit linguistic criteria, which distinguishes it from mere collections of texts. The methodological framework for corpus design is crucial for achieving representativeness and facilitating meaningful generalizations about linguistic patterns.

Frequency (EN corpus)

abs: 325 pmw: 255.83

Corpus evidence (EN)

"articles are able to provide much more detail about the process of corpus design and compilation undertaken by the researchers." (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

"the framework can be applied to existing corpora, demonstrating how the framework can be applied to existing corpora." (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

"the goal of this book is to apply the concept concretely to the design and evaluation of language corpora." (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

Nota terminológica / Terminological note

The term "corpus design" is widely recognized in the field of corpus linguistics, emphasizing the importance of systematic planning in corpus creation. Variations in its application may arise based on specific linguistic goals or the types of texts involved, reflecting ongoing developments in the methodology of corpus compilation. El término "diseño de corpus" es ampliamente reconocido en el ámbito de la lingüística de corpus, enfatizando la impo

Términos relacionados / Related terms

corpus / corpus · **representativeness** / representatividad · **annotation** / anotación · **corpus compilation** / compilación de corpus · **corpus-driven** / dirigido por corpus · **text type** / tipo de texto · **sampling frame** / marco de muestreo

diseño de corpus

Diseño y compilación de corpus

Definición

Un enfoque sistemático para la creación de un corpus que garantiza su representación precisa de un dominio específico del uso del lenguaje. Esto implica la selección y organización cuidadosa de textos según criterios lingüísticos explícitos, lo que lo distingue de meras colecciones de textos. El marco metodológico para el diseño de corpus es crucial para lograr la representatividad y facilitar generalizaciones significativas sobre los patrones lingüísticos.

Frecuencia (corpus ES)

abs: 35 pmw: 43.11

Evidencia en corpus (ES)

"the design is, as we have seen, the trait that differentiates textual corpora from any other aggregations of texts." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

"los textos forman parte de un todo que se ha construido en función de unas determinadas características, que son, por supuesto, las que corresponden al diseño previo." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

"el diseño y los objetivos con los que se construye el corpus hacen que exija, admita o rechace ciertos (tipos de) documentos." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

corpus linguistics

Foundational concepts

Definition

The study of linguistic data derived from a specific language or set of languages, characterized by its empirical approach to analyzing real language use. This methodology contrasts with traditional linguistic analysis that often relies on constructed examples or intuitions. Corpus linguistics is recognized for its distinctive methodological orientation, focusing on the compilation and exploitation of corpora as primary data sources.

Frequency (EN corpus)

abs: 2.297 pmw: 1808.11

Corpus evidence (EN)

Corpus linguistics is the study of linguistic data from a particular language or set of languages. (2022_McEnery_ T., Brezina, V._Fundamental Principles of Corpus Linguistics)

This makes corpus texts different from the constructed examples abundant in many other strands of linguistics. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

In a broad sense, the limitations of a corpus may be schematically marked according to the following diagram. (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

lingüística de corpus

Conceptos fundacionales

Definición

El estudio de datos lingüísticos obtenidos de una lengua o conjunto de lenguas, caracterizado por su enfoque empírico en el análisis del uso real del lenguaje. Esta metodología se distingue de los análisis lingüísticos tradicionales que suelen basarse en ejemplos contruídos o intuiciones. La lingüística de corpus se reconoce por su orientación metodológica distintiva, centrada en la compilación y explotación de corpus como fuentes primarias de datos.

Frecuencia (corpus ES)

abs: 684 pmw: 842.59

Evidencia en corpus (ES)

Se definen así tres áreas o campos de actuación dentro de la lingüística de corpus: la compilación y organización de corpus; el desarrollo de herramientas y recursos digitales para el trabajo con corpus, y el uso de dichos corpus y recursos para el estudio descriptivo y empírico de las lenguas y el lenguaje. (2025_Moyano Moreno, I._Antecedentes de la lingüística de corpus y algunas apreciaciones terminológicas)

La lingüística de corpus es un conjunto de metodologías relacionadas con la compilación y explotación de corpus en los estudios lingüísticos tanto teóricos como aplicados. (2022_García Miguel J. M._Linguística de corpus De los datos textuales a la teoría lingüística_Estudios de Lingüística del Español)

Un corpus puede definirse como una colección de textos orales o escritos producidos en un contexto comunicativo natural, representativos de una lengua o variedad de lengua. (2022_García Miguel J. M._Linguística de corpus De los datos textuales a la teoría lingüística_Estudios de Lingüística del Español)

Nota terminológica / Terminological note

The term "corpus linguistics" has evolved to encompass various methodologies and approaches, reflecting a growing emphasis on empirical data in linguistic research. This evolution is marked by the increasing integration of computational tools and digital resources in the analysis of language use. El término "lingüística de corpus" ha evolucionado para abarcar diversas metodologías y enfoques, reflejando un creciente énfasis en los datos empírico

Términos relacionados / Related terms

corpus / corpus · **corpus design** / diseño de corpus · **annotation** / anotación · **frequency** / frecuencia · **token** / token · **general corpus** / corpus general · **concordance** / concordancia

Corpus of Contemporary American English

Reference corpora

Definition

A comprehensive linguistic resource, this corpus encompasses a billion words of contemporary American English, representing various registers such as fiction, academic writing, and broadcast speech. Its design aims to provide unparalleled insights into language variation and track recent changes in English usage. Unlike specialized corpora, which may focus on narrow domains, this corpus is characterized by its broad representativeness and extensive sampling from freely available online sources.

Frequency (EN corpus)

abs: 50 pmw: 39.36

Corpus evidence (EN)

COCA is representative of North American usage. (source)

Firstly, the COCA corpus is probably the largest and the most representative corpus of the English language (of use in the USA). (source)

The research presented here is based on the British National Corpus (BNC) World Edition. This corpus was chosen because it is a representative corpus of British English that serves as a standard reference for this particular variety. (source)

Corpus of Contemporary American English

Corpus de referencia

Definición

Un recurso lingüístico integral que abarca mil millones de palabras del inglés americano contemporáneo, representando diversos registros como ficción, escritura académica y discurso transmitido. Su diseño tiene como objetivo proporcionar una visión sin precedentes sobre la variación del lenguaje y rastrear cambios recientes en el uso del inglés. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 3 pmw: 3.58

Evidencia en corpus (ES)

Término no documentado en el subcorpus español.

Nota terminológica / Terminological note

The Corpus of Contemporary American English is widely recognized for its methodological rigor and extensive coverage of contemporary language, making it a vital resource for researchers in corpus linguistics. Its representativeness and balanced design distinguish it from specialized corpora, which may not capture the full spectrum of language use. El Corpus de inglés americano contemporáneo es ampliamente reconocido por su rigor metodológico y su

Términos relacionados / Related terms

reference corpus / corpus de referencia · **balanced corpus** / corpus equilibrado · **corpus design** / diseño de corpus · **general corpus** / corpus general · **monitor corpus** / corpus monitor · **subcorpus** / subcorpus

corpus queries

Search and retrieval

Definition

A method for retrieving specific linguistic data from a corpus, utilizing defined parameters or syntax to identify tokens or sequences of tokens based on various levels of annotation. This approach allows researchers to conduct detailed analyses of language patterns and structures, facilitating reproducibility and transparency in corpus linguistics. The complexity of the queries can vary, reflecting the intricacies of the linguistic phenomena being investigated.

Frequency (EN corpus)

abs: 46 pmw: 36.21

Corpus evidence (EN)

The syntax is very powerful, allowing us to query the corpus for tokens or sequences of tokens at any level of annotation. (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

For example, a query for the different forms of the word synthesize would look as shown in (5a), or, if the corpus contains information about the lemma of each word form, as shown in (5b). (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

We can also combine two or more attribute-value pairs inside a pair of square brackets to search for tokens satisfying particular conditions at different levels of annotation. (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "corpus queries" is essential in corpus linguistics, as it underpins the methodological framework for data retrieval and analysis. Its usage reflects a growing emphasis on transparency and reproducibility in linguistic research, highlighting the need for clear documentation of query syntax and corpus design. El término "consultas de corpus" es fundamental en la lingüística de corpus, ya que sustenta el marco metodológico para la recuperación

Términos relacionados / Related terms

query / consulta · **annotation** / anotación · **concordance** / concordancia · **corpus design** / diseño de corpus · **regular expression** / expresión regular · **token** / token

consultas de corpus

Búsqueda y consulta

Definición

Las consultas de corpus son un método para recuperar datos lingüísticos específicos de un corpus, utilizando parámetros o sintaxis definidos para identificar tokens o secuencias de tokens en función de diferentes niveles de anotación. Este enfoque permite a los investigadores realizar análisis detallados de patrones y estructuras lingüísticas, facilitando la reproducibilidad y la transparencia en la lingüística de corpus. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 8 pmw: 9.55

corpus query language

Search and retrieval

Definition

A formal system that allows users to retrieve specific linguistic data from a corpus based on defined criteria. This system employs a syntax that can include regular expressions and attribute-value pairs to specify the desired tokens or sequences of tokens. The methodological transparency of this language is crucial for reproducibility in corpus linguistics research, as it enables researchers to document and share their queries effectively.

Frequency (EN corpus)

abs: 1 pmw: 0.79

Corpus evidence (EN)

"syntax is very powerful, allowing us to query the corpus for tokens or sequences of tokens at any level of annotation."
(2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"we can use regular expressions inside the values for the attributes, and we can use the asterisk, question mark and plus outside the token to indicate that the query should match 'zero or more', 'zero or one' and 'one or more' tokens with the specified properties."
(2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"the more complex the phenomenon, the more difficult it will be to guess what query or queries a researcher has used if they do not tell us." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "corpus query language" is primarily used in the context of corpus linguistics to denote a structured approach to data retrieval. Its usage is consistent across various studies, emphasizing the importance of methodological transparency and reproducibility in research. El término "lenguaje de consulta de corpus" se utiliza principalmente en el contexto de la lingüística de corpus para denotar un enfoque estructurado para la recuperación

Términos relacionados / Related terms

query / consulta · **annotation** / anotación · **concordance** / concordancia · **regular expression** / expresión regular · **token** / token · **corpus compilation** / compilación de corpus

lenguaje de consulta de corpus

Búsqueda y consulta

Definición

Un sistema formal que permite a los usuarios recuperar datos lingüísticos específicos de un corpus según criterios definidos. Este sistema emplea una sintaxis que puede incluir expresiones regulares y pares de atributos y valores para especificar los tokens o secuencias de tokens deseados. La transparencia metodológica de este lenguaje es crucial para la reproducibilidad en la investigación de la lingüística de corpus, ya que permite a los investigadores documentar y compartir sus consultas de manera efectiva.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Evidencia en corpus (ES)

"la lingüística de corpus ha ampliado el ámbito de estudio del lenguaje, que actualmente se concibe en el marco más amplio de la comunicación humana." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"gracias a la revolución digital, ahora tenemos acceso a muestras de uso real del lenguaje para la investigación." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"la definición aportada por Sinclair (2005) resulta suficientemente esclarecedora: 'un corpus es una colección de piezas de texto lingüístico en forma electrónica'." (2022_Sánchez Lancis, C._Corpus diacrónicos del español de España)

corpus size

Corpus design and compilation

Definition

The total number of words included in a collection of texts, which influences its representativeness and the validity of quantitative analyses. While there is no fixed requirement for corpus size, larger corpora are generally preferred for capturing linguistic patterns and ensuring reliable frequency estimates. The concept of size is relative and depends on various factors, including the type of linguistic features being studied and the corpus's intended purpose.

Frequency (EN corpus)

abs: 109 pmw: 85.80

Corpus evidence (EN)

"the issue of size is directly related to the issue of representativeness." (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

"the number of words included in a corpus actually determines its largeness." (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

"the question of quantity or size is best addressed with reference to components." (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

Nota terminológica / Terminological note

The term "corpus size" is often debated among researchers, with varying opinions on the ideal size for effective linguistic analysis. While larger corpora are generally favored for their ability to provide more comprehensive data, the specific needs of a research project may dictate the appropriateness of smaller, well-designed corpora. El término "tamaño del corpus" es a menudo objeto de debate entre los investigadores, con opiniones diversas s

Términos relacionados / Related terms

representativeness / representatividad · **sample size** / tamaño de muestra · **frequency** / frecuencia · **corpus design** / diseño de corpus · **balanced corpus** / corpus equilibrado

tamaño del corpus

Diseño y compilación de corpus

Definición

El número total de palabras que contiene una colección de textos, lo que influye en su representatividad y en la validez de los análisis cuantitativos. Aunque no existe un requisito fijo para el tamaño de un corpus, generalmente se prefieren los corpus más grandes para captar patrones lingüísticos y asegurar estimaciones de frecuencia fiables. El concepto de tamaño es relativo y depende de diversos factores, como el tipo de características lingüísticas que se estudian y el propósito del corpus.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

"la idoneidad o la conveniencia de grandes corpus también han sido extensamente debatidas." (2017_González Fernández, A._La web como corpus. Un esbozo LENGUA Y HABLA)

"no hay reglas estrictas que se puedan seguir para determinar el tamaño ideal de un corpus." (2017_González Fernández, A._La web como corpus. Un esbozo LENGUA Y HABLA)

"es importante no asumir que más grande siempre es mejor." (2017_González Fernández, A._La web como corpus. Un esbozo LENGUA Y HABLA)

corpus-based

Foundational concepts

Definition

Research that primarily utilizes corpora to validate the researcher's hypotheses and intuitions. This approach contrasts with corpus-driven research, which relies on the data from the corpus to generate new insights without prior assumptions. The methodological status of corpus-based analysis is recognized across various subdisciplines of linguistics, indicating its widespread acceptance and application.

Frequency (EN corpus)

abs: 471 pmw: 370.75

Corpus evidence (EN)

"corpus-based analysis was employed in more than 50 percent of the 410 surveyed articles." (2016_Egbert J. Biber D. y Gray B.)

"the term 'corpus' has been used in linguistics for many decades to refer to a body or collection of language." (2016_Egbert J. Biber D. y Gray B.)

"Corpus-based linguistics is the kind exemplified in Sect. 1.2.3.1." (2017_Desagulier, G.)

Nota terminológica / Terminological note

The term "corpus-based" is widely used in contemporary linguistic research, indicating a methodological approach that emphasizes empirical data derived from corpora. Its distinction from "corpus-driven" highlights different epistemological stances within corpus linguistics, with ongoing discussions about the implications of each approach for linguistic theory and practice. El término "basado en corpus" se utiliza ampliamente en la investigación.

Términos relacionados / Related terms

corpus linguistics / *lingüística de corpus* · **corpus-driven** / *dirigido por corpus* · **frequency** / *frecuencia* · **annotation** / *anotación* · **concordance** / *concordancia* · **collocation** / *colocación* · **general corpus** / *corpus general*

basado en corpus

Conceptos fundacionales

Definición

Investigación que utiliza principalmente corpora para validar las hipótesis e intuiciones del investigador. Este enfoque contrasta con la investigación basada en corpus, que se apoya en los datos del corpus para generar nuevos conocimientos sin suposiciones previas. El estatus metodológico del análisis basado en corpus es reconocido en diversas subdisciplinas de la lingüística, lo que indica su amplia aceptación y aplicación.

Frecuencia (corpus ES)

abs: 28 pmw: 34.49

Evidencia en corpus (ES)

"la lingüística de corpus sería el estudio del lenguaje basado en datos de corpus." (2016_Zulaica Hernández, I.)

"los lingüistas basan sus investigaciones sobre aspectos gramaticales en la evidencia empírica que suministran los datos extraídos de dichos corpus." (2016_Zulaica Hernández, I.)

"la lingüística de corpus como metodología se trata de una manera de hacer lingüística, de orientación claramente empírica." (2016_Zulaica Hernández, I.)

corpus-driven

Foundational concepts

Definition

Research characterized as corpus-driven relies on the analysis of linguistic data with minimal prior hypotheses, allowing the findings to directly inform new insights and theories. This approach contrasts with corpus-based research, which typically starts with pre-existing intuitions that the corpus is used to verify. The methodology emphasizes the corpus as the primary source of linguistic knowledge, rather than a tool for testing assumptions.

Frequency (EN corpus)

abs: 34 pmw: 26.76

Corpus evidence (EN)

Corpus-driven linguistics is the radical extension of corpus-based linguistics: the corpus is not part of a method but our sole access to language competence. (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Studies in this tradition typically focus on collocations and discourse effects. (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

According to McEnery and Hardie (2012), this idea has its roots in the works of scholars inspired by J.R. Firth, such as John Sinclair, Susan Hunston, Bill Louw, Michael Stubbs, or Wolfgang Teubert. (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

The term "corpus-driven" is primarily used to describe a methodological stance in corpus linguistics that prioritizes data analysis over pre-existing hypotheses. This approach is often contrasted with corpus-based research, which relies on prior intuitions. El término "corpus guiado" se utiliza principalmente para describir una postura metodológica en la lingüística de corpus que prioriza el análisis de datos sobre hipótesis preexistentes. Este

Términos relacionados / Related terms

corpus-based / basado en corpus · **collocation** / colocación · **frequency** / frecuencia · **annotation** / anotación · **concordance** / concordancia

dirigido por corpus

Conceptos fundacionales

Definición

La investigación caracterizada como corpus guiado se basa en el análisis de datos lingüísticos con pocas o ninguna hipótesis previa, permitiendo que los hallazgos informen directamente nuevas ideas y teorías. Este enfoque contrasta con la investigación basada en corpus, que generalmente comienza con intuiciones preexistentes que el corpus se utiliza para verificar. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 11 pmw: 13.13

CQPweb

Tools and software

Definition

A software tool designed for querying linguistic corpora, facilitating the analysis of language data through a user-friendly interface. It allows researchers to perform complex searches and retrieve linguistic information efficiently, thus supporting corpus-based studies. This tool is particularly relevant in the context of computational linguistics and corpus linguistics methodologies.

Frequency (EN corpus)

abs: 21 pmw: 16.53

Corpus evidence (EN)

"CQPweb is a powerful tool for querying linguistic corpora, allowing researchers to perform complex searches." (source)

"The software facilitates the analysis of language data through a user-friendly interface." (source)

"CQPweb supports corpus-based studies by enabling efficient retrieval of linguistic information." (source)

Nota terminológica / Terminological note

The term "CQPweb" is consistently used in the context of tools for linguistic analysis, highlighting its role in facilitating complex queries and enhancing the research process in corpus linguistics. Variations in usage may arise based on the specific linguistic focus or the type of corpus being analyzed. El término "CQPweb" se utiliza de manera consistente en el contexto de herramientas para el análisis lingüístico, destacando su papel en la fac

Términos relacionados / Related terms

corpus / *corpus* · **query** / *consulta* · **annotation** / *anotación* · **corpus-based** / *basado en corpus* · **computational linguistics** / *lingüística computacional* · **concordance** / *concordancia*

CQPweb

Herramientas y software

Definición

Una herramienta de software destinada a la consulta de corpora lingüísticos, que facilita el análisis de datos lingüísticos a través de una interfaz amigable. Permite a los investigadores realizar búsquedas complejas y recuperar información lingüística de manera eficiente, apoyando así los estudios basados en corpus. Esta herramienta es especialmente relevante en el contexto de la lingüística computacional y las metodologías de lingüística de corpus.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Evidencia en corpus (ES)

"El uso de CQPweb permite a los investigadores realizar búsquedas complejas en corpora lingüísticos." (fuente)

"La herramienta facilita el análisis de datos lingüísticos mediante una interfaz amigable." (fuente)

"CQPweb apoya los estudios basados en corpus al permitir la recuperación eficiente de información lingüística." (fuente)

CWB

Tools and software

Definition

A software tool designed for corpus management that facilitates the indexing and querying of linguistic data. It requires users to possess technical knowledge of programming languages, particularly Unix, to effectively utilize its functionalities. The tool is noted for its ability to perform complex searches and provide precise data, making it essential for rigorous linguistic analysis.

Frequency (EN corpus)

abs: 6 pmw: 4.72

Corpus Workbench

Herramientas y software

Definición

Una herramienta de software destinada a la gestión de corpus que permite la indexación y consulta de datos lingüísticos. Su uso requiere que los usuarios tengan conocimientos técnicos en lenguajes de programación, especialmente Unix, para aprovechar eficazmente sus funcionalidades. Este programa es reconocido por su capacidad para realizar búsquedas complejas y proporcionar datos precisos, lo que lo convierte en esencial para un análisis lingüístico riguroso.

Frecuencia (corpus ES)

abs: 42 pmw: 51.74

Evidencia en corpus (ES)

"La selección de una u otra vía estará condicionada fundamentalmente por los conocimientos del usuario en lenguaje de programación Unix." (source)

"El proceso de indexación con CWB puede resultar laborioso, ya que requiere una adquisición paulatina de conocimientos técnicos de programación." (source)

"A pesar del esfuerzo inicial, es muy recomendable indexar un corpus con CWB, puesto que éste ofrece datos exactos acordes con la rigurosidad de su proceso de indexación." (source)

Nota terminológica / Terminological note

The term CWB is primarily used in the context of corpus linguistics and may vary in its application depending on the user's technical expertise. Its reliance on Unix programming can pose a barrier for some users, but its capabilities in managing and analyzing linguistic data are widely recognized in the field. El término CWB se utiliza principalmente en el contexto de la lingüística de corpus y puede variar en su aplicación dependiendo de la exp

Términos relacionados / Related terms

corpus / *corpus* · **annotation** / *anotación* · **query** / *consulta* · **tokenisation** / *tokenización* · **concordance** / *concordancia* · **corpus compilation** / *compilación de corpus*

dataset

Language processing

Definition

A collection of data that can encompass various forms, including images, articles, or other objects, organized in a tabulated manner. Unlike a corpus, which contains a wide range of linguistic texts for analysis, a dataset is typically structured to represent specific variables in a defined format, often resembling a single database table. This distinction highlights the methodological differences between datasets and corpora, with the former being a subset of data that can be derived from the latter.

Frequency (EN corpus)

abs: 122 pmw: 96.03

Corpus evidence (EN)

A dataset, on the other hand, is a collection of data of any kind either from language or from any other domain for that matter.

(2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

In simple terms, a dataset is nothing but a collection of data in the table format. (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

A corpus is not a dataset because it carries not only large sets of lexical data, but also a whole range of linguistic texts that can be further processed and analyzed to generate datasets of different types and patterns. (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

Nota terminológica / Terminological note

The term "dataset" is often used interchangeably with other terms in computational contexts, leading to potential confusion regarding its precise definition. In corpus linguistics, it is essential to distinguish between datasets and corpora, as the former represents a more specific and structured collection of data derived from the latter. El término "conjunto de datos" se utiliza a menudo de manera intercambiable con otros términos en contextos

Términos relacionados / Related terms

corpus / corpus · **dataset** / conjunto de datos · **annotation** / anotación · **metadata** / metadatos · **corpus compilation** / compilación de corpus · **natural language processing** / procesamiento del lenguaje natural · **training corpus** / corpus de entrenamiento

conjunto de datos

Procesamiento del lenguaje

Definición

Un conjunto de datos que puede incluir diversas formas, como imágenes, artículos u otros objetos, organizados de manera tabulada. A diferencia de un corpus, que contiene una amplia gama de textos lingüísticos para su análisis, un dataset suele estar estructurado para representar variables específicas en un formato definido, asemejándose a una única tabla de base de datos. Esta distinción resalta las diferencias metodológicas entre los conjuntos de datos y los corpora, siendo el primero un subconjunto de datos que puede derivarse del segundo.

Frecuencia (corpus ES)

abs: 5 pmw: 6.16

Evidencia en corpus (ES)

In comparison with other domains, such as affective computing, the analysis focuses more directly and effectively, as no complete comprehension methods of the texts are proposed, but rather these are treated as lexical sets that include semantic characteristics. (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

En cuanto a los enfoques basados en léxico, que funcionan mediante la identificación de palabras de opinión contenidas en un diccionario, también requieren de corpus para la obtención de esos diccionarios de sentimiento. (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

La atención suscitada por el análisis de sentimiento justifica el rápido paso de disciplina meramente científica, hacia una enorme variedad de aplicaciones. (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

dependency parsing

Language processing

Definition

A method within natural language processing that involves the syntactic analysis of a sentence by establishing relationships between words, specifically identifying the dependencies between a head word and its dependents. This approach is essential for tasks such as semantic analysis and machine translation, as it provides a structured representation of sentence syntax. Dependency parsing contrasts with constituency parsing, which focuses on the hierarchical structure of phrases rather than the relationships between individual words.

Frequency (EN corpus)

abs: 5 pmw: 3.94

Corpus evidence (EN)

The Prague dependency treebank: a three-level annotation scenario. (source)

The sum dependency distances will be 31 words in (2a) and 27 in (2b). (source)

In the Universal Dependencies annotation style, there is one line per token, and the different layers of annotation for each token are displayed across multiple tabular-separated columns. (source)

análisis de dependencias

Procesamiento del lenguaje

Definición

El análisis de dependencias es un método de procesamiento del lenguaje natural que se centra en la identificación de las relaciones sintácticas entre las palabras de una oración, estableciendo qué palabras dependen de otras. Este enfoque es fundamental para tareas como el análisis semántico y la traducción automática, ya que ofrece una representación estructurada de la sintaxis de la oración. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 6 pmw: 7.16

Evidencia en corpus (ES)

Término no documentado en el subcorpus español.

Nota terminológica / Terminological note

Dependency parsing is a widely used technique in computational linguistics, particularly for its efficiency in representing syntactic structures. It has gained prominence with the development of various annotation schemes, such as Universal Dependencies, which standardize the representation of syntactic relations across languages. En el ámbito de la lingüística computacional, el análisis de dependencias ha cobrado relevancia debido a su eficacia

Términos relacionados / Related terms

parsing / análisis sintáctico · **parsing** / análisis sintáctico · **annotation** / anotación · **treebank** / treebank · **natural language processing** / procesamiento del lenguaje natural

Frequency and statistics

A branch of statistics that summarizes and describes the characteristics of a dataset, focusing on measures such as means, medians, and frequencies. This methodology is essential for interpreting nominal, ordinal, and cardinal data, as evidenced by its application in various statistical analyses within corpus linguistics. Descriptive statistics differ from inferential statistics, which aim to make predictions or inferences about a population based on sample data.

abs: 58 pmw: 45.66

5.2 Descriptive statistics for nominal data 5.2.1

Percentages

frequency / frecuencia · **mean score** / puntuación media · **standard deviation** / desviación estándar · **inferential statistics** / estadísticas inferenciales · **occurrence** / ocurrencia · **sample size** / tamaño de muestra · **dataset** / conjunto de datos

Frecuencia y estadística

Una rama de la estadística que resume y describe las características de un conjunto de datos, centrándose en medidas como medias, medianas y frecuencias. Esta metodología es esencial para interpretar datos nominales, ordinales y cardinales, como se evidencia en su aplicación en diversos análisis estadísticos dentro de la lingüística de corpus. Las estadísticas descriptivas se diferencian de las estadísticas inferenciales, que buscan hacer predicciones o inferencias sobre una población a partir de datos de muestra.

abs: 2 pmw: 2.46

diachronic corpus

Corpus design and compilation

Definition

A specialized collection of texts that captures linguistic changes over time, allowing for the analysis of language evolution. This type of corpus is distinguished from synchronic corpora by its ability to reflect chronological changes in form and content, thus providing insights into the dynamics of language as it develops. The methodological significance of diachronic corpora lies in their role in diachronic studies, which investigate how language properties evolve in relation to societal changes.

Frequency (EN corpus)

abs: 60 pmw: 47.23

Corpus evidence (EN)

A corpus should continue to grow with time to register linguistic changes noted in a language. (2018_Sekhar Dash, N., Arulmozi, S.)

The referential importance of a diachronic corpus in the study of chronological change of language is immense. (2018_Sekhar Dash, N., Arulmozi, S.)

Such a feature has several indirect effects on the works of both mainstream linguistics and language technology. (2018_Sekhar Dash, N., Arulmozi, S.)

corpus diacrónico

Diseño y compilación de corpus

Definición

Colección especializada de textos que registra los cambios lingüísticos a lo largo del tiempo, permitiendo el análisis de la evolución del lenguaje. Este tipo de corpus se distingue de los corpus sincrónicos por su capacidad de reflejar cambios cronológicos en la forma y el contenido, proporcionando así información sobre la dinámica del lenguaje a medida que se desarrolla. La importancia metodológica de los corpus diacrónicos radica en su papel en los estudios diacrónicos, que investigan cómo evolucionan las propiedades del lenguaje en relación con los cambios sociales.

Frecuencia (corpus ES)

abs: 3 pmw: 3.70

Evidencia en corpus (ES)

Un corpus diacrónico se define como una colección de textos que permite el análisis de la evolución del lenguaje a través del tiempo. (2022_Sánchez Lancis, C.)

La importancia de los corpus diacrónicos radica en su capacidad para reflejar cambios en las propiedades lingüísticas en relación con la sociedad. (2022_Sánchez Lancis, C.)

Estos corpus son fundamentales para los estudios que investigan la evolución del lenguaje en contextos históricos. (2021_Rojo, G.)

Nota terminológica / Terminological note

The term "diachronic corpus" is widely accepted in corpus linguistics, though its application may vary depending on the specific linguistic context or research focus. Researchers often emphasize the importance of text diversity and chronological representation in the compilation of such corpora to ensure comprehensive analysis. El término "corpus diacrónico" es ampliamente aceptado en la lingüística de corpus, aunque su aplicación puede variar se

Términos relacionados / Related terms

synchronic / sincrónico · **corpus** / corpus · **corpus design** / diseño de corpus · **historical corpus** / corpus histórico · **monitor corpus** / corpus monitor

dispersion

Frequency and statistics

Definition

A statistical measure that quantifies the distribution of a linguistic feature within a corpus, indicating the degree to which occurrences are spread across different texts or contexts. This concept encompasses two primary aspects: pervasiveness, which assesses how widely an item is used, and evenness of distribution, which evaluates the balance of occurrence rates across contexts. The term is significant in corpus linguistics methodology, particularly in analyzing the uniformity of linguistic features across a dataset.

Frequency (EN corpus)

abs: 330 pmw: 259.76

Corpus evidence (EN)

"The aim of this paper is to contribute to our ongoing efforts to understand dispersion and its measurement, and to support an informed and constructive discourse on this area of corpus-linguistic methodology." (source)

"In its second sense, the word dispersion denotes 'evenness' of distribution (i.e., whether the item's occurrence rate is balanced across contexts of language use)." (source)

"High entropy therefore reflects high dispersion." (source)

dispersión

Frecuencia y estadística

Definición

Medida estadística que cuantifica la distribución de un rasgo lingüístico dentro de un corpus, indicando el grado en que las ocurrencias están repartidas entre diferentes textos o contextos. Este concepto abarca dos aspectos principales: la pervasividad, que evalúa cuán ampliamente se utiliza un ítem, y la uniformidad de la distribución, que examina el equilibrio de las tasas de ocurrencia en diferentes contextos. La dispersión es un término relevante en la metodología de la lingüística de corpus, especialmente en el análisis de la uniformidad de los rasgos lingüísticos en un conjunto de datos

Frecuencia (corpus ES)

abs: 30 pmw: 36.96

Evidencia en corpus (ES)

"La dispersión captura la distribución de un rasgo lingüístico dentro de un corpus, la cual puede variar desde una distribución muy grumosa, en la que dicho rasgo solamente aparece en una pequeña parte de los documentos, hasta una distribución completamente uniforme." (fuente)

"Hay muchos tipos de medidas de dispersión." (fuente)

"El D de Julliland ha sido utilizado extensamente en la investigación de vocabulario basado en corpus; sin embargo, Gries (2008) presenta un DP alternativo." (fuente)

Nota terminológica / Terminological note

The term "dispersion" has evolved within corpus linguistics to encompass both the breadth of usage and the balance of occurrences across texts. This duality highlights its importance in methodological discussions, particularly as researchers seek to refine their analyses of linguistic features. El término "dispersión" ha evolucionado dentro de la lingüística de corpus para abarcar tanto la amplitud de uso como el equilibrio de las ocurrencias en

Términos relacionados / Related terms

frequency / frecuencia · corpus design / diseño de corpus · keyword / palabra clave · collocation / colocación · statistical significance / significancia estadística · text type / tipo de texto

effect size

Frequency and statistics

Definition

A quantitative measure that reflects the magnitude of a phenomenon, often used in statistical analyses to assess the strength of relationships or differences between groups. This term is crucial in the context of inferential statistics, as it provides insight beyond mere significance testing, indicating the practical significance of findings. Different effect size measures, such as Cohen's *d*, are employed depending on the statistical method used, highlighting the need for careful interpretation of their assumptions.

Frequency (EN corpus)

abs: 61 pmw: 48.02

Corpus evidence (EN)

*The most widely-used effect size for data analyzed with a t-test is Cohen's *d*, also referred to as the standardized mean difference. (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)*

For example, the range of effect sizes we may use are as many as the range of inferential statistics we may use and our guide in using them is quite similar. (2022_McEnery_ T., Brezina, V._Fundamental Principles of Corpus Linguistics)

This study has shown that length has a moderate, statistically significant influence on the choice of possessive constructions... (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "effect size" is widely used in statistical analysis to convey the strength of relationships or differences, often complementing significance testing. Its interpretation can vary based on the statistical methods employed, and it is essential for researchers to understand the underlying assumptions of different effect size measures. El término "tamaño del efecto" se utiliza ampliamente en el análisis estadístico para transmitir la fuerza

Términos relacionados / Related terms

statistical significance / significancia estadística · **inferential statistics** / estadísticas inferenciales · **standard deviation** / desviación estándar · **confidence interval** / intervalo de confianza · **mean score** / puntuación media · **t-score** / puntuación t

tamaño del efecto

Frecuencia y estadística

Definición

El tamaño del efecto es una medida cuantitativa que refleja la magnitud de un fenómeno, utilizada en análisis estadísticos para evaluar la fuerza de las relaciones o diferencias entre grupos. Este término es fundamental en el contexto de la estadística inferencial, ya que proporciona información más allá de las pruebas de significancia, indicando la relevancia práctica de los hallazgos. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 2 pmw: 2.39

encoding

Metadata and formats

Definition

A process involving the transformation of data into a specific format for efficient storage and retrieval. This term is crucial in corpus linguistics, as it pertains to the representation of textual information in a structured manner, enabling accurate data analysis and retrieval. Encoding is often contrasted with decoding, which refers to the interpretation of encoded data back into its original form.

Frequency (EN corpus)

abs: 143 pmw: 112.56

Corpus evidence (EN)

If you encounter an encoding issue when you open the file in your text editor, please refer to Sect. 3.3.2. (source: 2017_Desagulier, G.)

In order to solve the discrepancy between character sets, first additional double-byte character sets were introduced, but eventually the notion of one single character set for all processing needs was put forth and implemented. (source: 2016_Weisser, M.)

This 'umbrella' character set is referred to as Unicode, which, despite the unifying attempts, still exists in a number of different flavours that use fixed or variable byte length to encode thousands of characters. (source: 2016_Weisser, M.)

Nota terminológica / Terminological note

The term "encoding" is widely used in various fields, including computer science and linguistics, with specific implications in corpus linguistics regarding data representation. Variations in encoding standards, such as UTF-8 and XML, reflect the evolving needs for data interoperability and accessibility. El término "codificación" se utiliza ampliamente en diversos campos, incluida la informática y la lingüística, con implicaciones específicas en

Términos relacionados / Related terms

metadata / metadatos · **annotation** / anotación · **markup language** / lenguaje de marcado · **XML** / XML · **TEI** / TEI · **plain text** / texto plano · **UTF-8** / UTF-8

codificación

Metadatos y formatos

Definición

Proceso que implica la transformación de datos en un formato específico para su almacenamiento y recuperación eficientes. Este término es fundamental en la lingüística de corpus, ya que se refiere a la representación de la información textual de manera estructurada, lo que permite un análisis y recuperación de datos precisos. La codificación se contrasta a menudo con la decodificación, que se refiere a la interpretación de datos codificados de vuelta a su forma original.

Frecuencia (corpus ES)

abs: 26 pmw: 32.03

Evidencia en corpus (ES)

La inserción de estas etiquetas y un mayor número de datos externos registrados facilitan las búsquedas cruzadas y con una cobertura de más variables. (fuente: 2018_Bernal Chávez, J. A. · Hincapié Moreno, D. A.)

La codificación de los rasgos presentes en el diseño del corpus: la L1 de la persona que ha producido el texto y su nivel de conocimientos de la L2 son los más básicos. (fuente: 2022_Rojo, G., Palacios, I.)

A partir de estas tres fases en el tratamiento de los corpus se pueden llevar a cabo tareas sencillas que sirven de base para casi todas las categorías de datos en un diccionario. (fuente: 2023_Lázaro, J.)

frequency

Frequency and statistics

Definition

A statistical measure quantifying the number of occurrences of a linguistic unit within a specified corpus. This concept is essential in corpus linguistics for analyzing patterns of language use, distinguishing between raw frequency and normalized frequency to account for varying corpus sizes. It serves as a fundamental metric in various analyses, including keyword analysis and collocation studies, where understanding the distribution of terms is crucial.

Frequency (EN corpus)

abs: 1.668 pmw: 1312.98

Corpus evidence (EN)

"Corpus linguists report frequencies of occurrence (raw, normalized, and/or adjusted) and of co-occurrence, association measures quantifying co-occurrence patterns, dispersion scores, keyness scores, etc." (2021_Gries, S. T.)

"The raw frequency only tells us whether the contribution is larger than that of other types, but not to which extent this is actually significant regarding the data." (2016_Weisser, M.)

"It is risky to argue that dispersion can replace frequency because the two are correlated when that very correlation actually breaks down exactly in the frequency bins." (2021_Gries, S. T.)

Nota terminológica / Terminological note

The term "frequency" is widely used in corpus linguistics to denote various types of frequency measurements, including raw and normalized frequencies, each serving different analytical purposes. Its application can vary depending on the research focus, such as lexical studies or syntactic analyses, highlighting the need for clarity in its usage. El término "frecuencia" se utiliza ampliamente en la lingüística de corpus para denotar varios tipos d

Términos relacionados / Related terms

raw frequency / frecuencia bruta · **normalized frequency** / frecuencia normalizada · **keyword** / palabra clave · **collocation** / colocación · **occurrence** / ocurrencia · **corpus design** / diseño de corpus · **concordance** / concordancia

frecuencia

Frecuencia y estadística

Definición

Medida estadística que cuantifica el número de ocurrencias de una unidad lingüística dentro de un corpus específico. Este concepto es fundamental en la lingüística de corpus para analizar patrones de uso del lenguaje, diferenciando entre frecuencia de uso y frecuencia de inventario, lo que permite una comprensión más precisa de la distribución de términos en diferentes contextos textuales.

Frecuencia (corpus ES)

abs: 1.015 pmw: 1250.33

Evidencia en corpus (ES)

"La diferencia entre frecuencia de inventario y frecuencia de uso que utilizo aquí es relativamente próxima a la propuesta por Bybee (2007) entre type frequency y token frequency." (2021_Rojo, G.)

"Obtener la frecuencia de uso de un elemento requiere el análisis del contenido de un conjunto más o menos amplio de textos reales." (2021_Rojo, G.)

"Frecuencia de uso y porcentajes de algunas clases de palabras en diferentes corpus textuales." (2021_Rojo, G.)

frequency list

Lexicon and phraseology

Definition

A structured compilation that enumerates the occurrences of words or phrases within a corpus, typically sorted by their frequency. This methodological tool is essential for analyzing language patterns and understanding lexical usage, as it allows researchers to identify the most common items and their distribution across different text types. Frequency lists can be generated from raw or annotated texts, facilitating comparisons and insights into language use.

Frequency (EN corpus)

abs: 208 pmw: 163.73

Corpus evidence (EN)

"Creating frequency lists of all words in the BNC, or even of individual words or word classes, rarely makes sense because this would simply give us a wrong impression of how frequent particular items may be in a heavily skewed selection." (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"Lists in spreadsheet format can, for instance, be filtered quite easily, cells colour-coded to indicate interesting features, or even comments or new category labels added to classify different types of words." (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"Making a frequency list is to see the most frequent items." (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

The term "frequency list" is widely used in corpus linguistics to facilitate the analysis of language patterns and usage. Variations in its application may arise depending on the corpus type and the specific research objectives, such as distinguishing between raw and normalized frequencies. El término "lista de frecuencias" se utiliza ampliamente en la lingüística de corpus para facilitar el análisis de patrones y usos del lenguaje. Las variacio

Términos relacionados / Related terms

corpus / corpus · **token** / token · **word frequency** / frecuencia de palabras · **annotation** / anotación · **collocation** / colocación · **concordance** / concordancia · **normalized frequency** / frecuencia normalizada

lista de frecuencias

Léxico y fraseología

Definición

Una recopilación estructurada que enumera las ocurrencias de palabras o frases dentro de un corpus, generalmente ordenadas por su frecuencia. Esta herramienta metodológica es esencial para analizar patrones lingüísticos y comprender el uso léxico, ya que permite a los investigadores identificar los elementos más comunes y su distribución en diferentes tipos de texto. Las listas de frecuencias pueden generarse a partir de textos en bruto o anotados, facilitando comparaciones y conocimientos sobre el uso del lenguaje.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"Los diccionarios de frecuencias pretenden obtener los datos de uso y, aunque se enfocan fundamentalmente a las frecuencias léxicas, hemos visto ya que nos permiten obtener los datos correspondientes a las clases de palabras si, como es habitual, incluyen ese rasgo." (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

"La diferencia entre frecuencia de inventario y frecuencia de uso que utilizo aquí es relativamente próxima a la propuesta por Bybee (2007) entre type frequency y token frequency." (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

"Obtener la frecuencia de uso de un elemento requiere el análisis del contenido de un conjunto más o menos amplio de textos reales." (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

function word

Lexicon and phraseology

Definition

A category of words that primarily serve grammatical purposes rather than conveying lexical meaning, function words include articles, prepositions, pronouns, and conjunctions. These words often occur with high frequency in texts, making them significant for corpus analysis, particularly in understanding language structure and variation. Their exclusion from frequency analyses can be justified, as they do not contribute semantic content in the same way that content words do.

Frequency (EN corpus)

abs: 91 pmw: 71.63

Corpus evidence (EN)

"none of the items in the list is a content word, the semantic information provided in Table 9.1 is essentially next to none."
(source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"function words (grammatical words) do occur often and regularly and are thus often put on a stop list." (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"In a list of the ten most frequent words of a large English corpus, all of the words will be function words." (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

palabra funcional

Léxico y fraseología

Definición

Una categoría de palabras que cumplen principalmente funciones gramaticales en lugar de transmitir significado léxico, incluyendo artículos, preposiciones, pronombres y conjunciones. Estas palabras suelen aparecer con alta frecuencia en los textos, lo que las convierte en elementos significativos para el análisis de corpus, especialmente en la comprensión de la estructura y variación del lenguaje. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 11 pmw: 13.13

Nota terminológica / Terminological note

The term "function word" is widely accepted in linguistic studies, particularly in corpus linguistics, where it plays a crucial role in analyzing grammatical structures and language patterns. Its definition is stable, though the classification of specific words may vary across different languages and linguistic frameworks. El término "palabra funcional" es ampliamente aceptado en los estudios lingüísticos, especialmente en la lingüística de corpus.

Términos relacionados / Related terms

content words / palabras de contenido · **frequency** / frecuencia · **stopword** / palabra vacía · **parts of speech** / categorías gramaticales · **corpus linguistics** / lingüística de corpus

general corpus

Corpus design and compilation

Definition

A type of linguistic corpus that encompasses a wide range of texts produced in typical communicative situations, allowing for the general description of a language variety. This corpus is characterized by its default features, which include representativeness and the inclusion of diverse text types, distinguishing it from specialized corpora that focus on specific language varieties or domains. The methodological approach to designing a general corpus aims to ensure accurate generalizations about language use across various contexts.

Frequency (EN corpus)

abs: 132 pmw: 103.91

Corpus evidence (EN)

"A general corpus is assumed to have certain default features." (2018_Sekhar Dash, N., Arulmozi, S.)

"A corpus that does not possess one or more default features of a general corpus... should be designated as a special corpus." (2018_Sekhar Dash, N., Arulmozi, S.)

"Designing a corpus for such research goals requires attention to multiple considerations." (2022_Egbert, J. Biber, D. y Gray, B.)

corpus general

Diseño y compilación de corpus

Definición

Un tipo de corpus lingüístico que abarca una amplia gama de textos producidos en situaciones comunicativas habituales, permitiendo la descripción general de una variedad lingüística. Este corpus se caracteriza por sus características predeterminadas, que incluyen la representatividad y la inclusión de diversos tipos de textos, lo que lo distingue de los corpus especializados que se centran en variedades o dominios específicos del lenguaje.

Frecuencia (corpus ES)

abs: 25 pmw: 30.80

Evidencia en corpus (ES)

"El corpus general permite la descripción general de una variedad lingüística o lengua." (2023_Hernández García, V.)

"Consiste en un corpus de la lengua común que alberga multitud de materiales producidos en situaciones comunicativas habituales." (2023_Hernández García, V.)

"Los corpus, así vistos, son hoy herramientas masivas... si se trata de un corpus de lengua general se intentará que tenga la mayor variedad posible." (2023_Lázaro, J.)

Nota terminológica / Terminological note

The term "general corpus" is widely accepted in corpus linguistics, though its definition may vary slightly among scholars, particularly regarding the specific features that qualify a corpus as "general." This variation reflects ongoing discussions in the field about the best practices for corpus design and the importance of representativeness in linguistic research. El término "corpus general" es ampliamente aceptado en la lingüística de corpus,

Términos relacionados / Related terms

specialized corpus / corpus especializado · **representativeness** / representatividad · **corpus design** / diseño de corpus · **text type** / tipo de texto · **frequency** / frecuencia · **annotation** / anotación

genre

Corpus design and compilation

Definition

A classification system that distinguishes texts based on their formal and content-related characteristics, allowing for the identification of specific text types within a corpus. This term is methodologically significant as it informs the analysis of linguistic structures and their functionality in various contexts, contrasting with the broader concept of "register," which focuses on situational language use rather than text classification.

Frequency (EN corpus)

abs: 297 pmw: 233.79

Corpus evidence (EN)

"Genre classification was carried out on three levels... The most basic, formal level of distinction is text form, where we distinguish between prose and verse." (source)

"Content-wise, a second level was assigned of prototypical text categories loosely inspired on a similar distinction used by the compilers of the Helsinki Corpus." (source)

"Our Early Modern Multiloquent Authors (EMMA) goal was to provide EMMA users with a maximally informative label, which allows for an in-depth analysis of specific genres." (source)

Nota terminológica / Terminological note

The term "genre" encompasses a variety of classifications that can evolve over time, reflecting changes in textual forms and societal contexts. Its application can vary significantly across different linguistic and cultural frameworks, necessitating careful consideration in corpus design and analysis. El término "género" abarca una variedad de clasificaciones que pueden evolucionar con el tiempo, reflejando cambios en las formas textuales y en lo

Términos relacionados / Related terms

text type / tipo de texto · **corpus design** / diseño de corpus · **annotation** / anotación · **corpus compilation** / compilación de corpus · **genre** / género · **metadata** / metadatos

género

Diseño y compilación de corpus

Definición

Un sistema de clasificación que distingue los textos según sus características formales y de contenido, permitiendo la identificación de tipos textuales específicos dentro de un corpus. Este término es metodológicamente relevante, ya que informa el análisis de las estructuras lingüísticas y su funcionalidad en diversos contextos, en contraste con el concepto más amplio de "registro", que se centra en el uso del lenguaje en situaciones específicas en lugar de en la clasificación de textos.

Frecuencia (corpus ES)

abs: 198 pmw: 243.91

Evidencia en corpus (ES)

"El carácter híbrido (entre modos textuales ya conocidos) de la CMC se ve también en los estudios que demuestran la ineptitud de algunos usuarios para seguir las reglas de un entorno digital dado." (fuente)

"Alcántara (2014), por su parte, emplea un corpus de 32 conversaciones de WhatsApp para estudiar el género y proponer que estas 'conversaciones' no son equiparables a las orales." (fuente)

"COTECA fue concebido como un corpus multidisciplinar especializado, mixto, discursivo y multigénero, que seleccionó para su diseño géneros escritos y orales de la actividad científico-académica." (fuente)

GloWbE

Reference corpora

Definition

A reference corpus that encompasses a wide range of web-based texts, GloWbE is characterized by its reliance on simple (pseudo-) random sampling from the entire domain of the searchable Web. This methodological approach contrasts with other corpora that utilize stratified random sampling, highlighting the unique challenges and considerations in corpus design and representativeness. The corpus is particularly noted for its extensive size, which is a common focal point in discussions of corpus compilation.

Frequency (EN corpus)

abs: 37 pmw: 29.12

Corpus evidence (EN)

Brown, CORE, GloWbE, MICASE, and ARCHER. The compilers of the Brown, ARCHER, and MICASE corpora used stratified random sampling methods to the extent possible and practical. (source)

On the other hand, the compilers of GloWbE and CORE (a subsample of GloWbE) relied on simple (pseudo-) random sampling, in this case from the entire domain of the searchable Web. (source)

It is probable that the corpora that relied on nonrandom sampling relied instead on compiler intuition, and text accessibility and convenience in order to make decisions about which texts to include or exclude from the sample. (source)

Nota terminológica / Terminological note

The term GloWbE is primarily used in discussions surrounding corpus design and representativeness, with its unique sampling methodology often contrasted against more traditional approaches. This distinction is significant for researchers analyzing linguistic data from web sources, as it raises questions about the validity and comprehensiveness of the corpus. El término GloWbE se utiliza principalmente en discusiones sobre el diseño y la represent

Términos relacionados / Related terms

corpus / corpus · **corpus design** / diseño de corpus · **representativeness** / representatividad · **sampling frame** / marco de muestreo · **frequency** / frecuencia · **token** / token · **general corpus** / corpus general

GloWbE

Corpus de referencia

Definición

Un corpus de referencia que abarca una amplia gama de textos provenientes de la web, GloWbE se caracteriza por su dependencia de un muestreo aleatorio simple (pseudo-aleatorio) de todo el dominio de la web accesible. Este enfoque metodológico contrasta con otros corpora que utilizan muestreo aleatorio estratificado, lo que resalta los desafíos y consideraciones únicas en el diseño y la representatividad del corpus. El corpus es especialmente notable por su tamaño extenso, que es un punto focal común en las discusiones sobre la compilación de corpora.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

grammar

Lexicon and phraseology

Definition

A structured inventory of symbolic linguistic units that encompasses both form and meaning, serving as a representation of linguistic knowledge. This concept contrasts with generative grammar, which posits a finite set of abstract rules to generate sentences, emphasizing instead the role of usage in shaping grammatical structures. The methodological approach to grammar in corpus linguistics often involves analyzing patterns that emerge from actual language use rather than relying solely on abstract principles.

Frequency (EN corpus)

abs: 423 pmw: 332.97

Corpus evidence (EN)

"The grammatical tagging of the ESC is a critical utility enabling use of these methods in the service of detailed research on grammar." (source: 2021_Culpeper et al.)

"Grammar is therefore derivative, not generative." (source: 2017_Desagulier)

"In this theory, grammar is the psychological representation of linguistic knowledge." (source: 2017_Desagulier)

gramática

Léxico y fraseología

Definición

Un inventario estructurado de unidades lingüísticas simbólicas que abarca tanto la forma como el significado, funcionando como representación del conocimiento lingüístico. Este concepto contrasta con la gramática generativa, que postula un conjunto finito de reglas abstractas para generar oraciones, enfatizando en cambio el papel del uso en la configuración de las estructuras gramaticales. En la lingüística de corpus, el enfoque metodológico hacia la gramática implica analizar patrones que emergen del uso real del lenguaje en lugar de depender únicamente de principios abstractos.

Frecuencia (corpus ES)

abs: 48 pmw: 59.13

Evidencia en corpus (ES)

"The idea of grammar being represented as a mental corpus originates from outside corpus linguistics per se." (source: 2017_Desagulier)

"Algunas aproximaciones teóricas a la gramática se basan en patrones sintagmáticos que emergen del corpus." (fuente: 2022_García Miguel J. M.)

"En esta línea podemos mencionar la Pattern Grammar de Hunston y Francis (1998, 2000), que destaca que la descripción de la combinatoria de una unidad léxica debe incluir información colocacional." (fuente: 2022_García Miguel J. M.)

Nota terminológica / Terminological note

The term "grammar" encompasses various theoretical approaches, including generative and usage-based perspectives, reflecting ongoing debates within linguistics. In corpus linguistics, grammar is often analyzed through empirical data, emphasizing the importance of real language use in understanding grammatical structures. El término "gramática" abarca diversos enfoques teóricos, incluidas las perspectivas generativas y basadas en el uso, reflejan

Términos relacionados / Related terms

corpus / corpus · **annotation** / anotación · **parts of speech** / categorías gramaticales · **collocation** / colocación · **parsing** / análisis sintáctico · **function word** / palabra funcional · **morphological annotation** / anotación morfológica

hapax legomena

Lexicon and phraseology

Definition

A type of lexical item characterized by its occurrence only once within a given corpus, distinguishing it from other words that may appear multiple times. The concept is utilized in morphological studies to operationalize the productivity of linguistic rules, as evidenced by its application in calculating the hapax-token ratio (HTR). This term is often contrasted with "dis legomena" and "tris legomena," which refer to words that occur twice or three times, respectively.

Frequency (EN corpus)

abs: 67 pmw: 52.74

Corpus evidence (EN)

Baayen's idea is quite straightforwardly to use the phenomenon of hapax legomenon as an operationalization of the construct "productive application of a rule" in the hope that the correlation between the two notions (in a large enough corpus) will be substantial enough for this operationalization to make sense. (source)

The number of hapax legomena is dependent on sample size (although the relationship is not as straightforward as in the case of types). (source)

The idea of using hapax legomena is, essentially, that a word like mageship, which is a hapax in the fiction sample, but not in the Google Books archive, somehow stands for a word like Johnship, which is a true hapax in the English language. (source)

Nota terminológica / Terminological note

The term "hapax legomena" is widely used in corpus linguistics to analyze lexical productivity and morphological richness, although its application can vary based on the corpus size and type. The distinction between hapax legomena and other frequency categories (like dis legomena) is crucial for understanding linguistic patterns. El término "hapax legómeno" se utiliza ampliamente en la lingüística de corpus para analizar la productividad léxica

Términos relacionados / Related terms

token / token · **type-token ratio** / relación tipo-token · **corpus** / corpus · **morphological annotation** / anotación morfológica · **frequency** / frecuencia

hapax legómeno

Léxico y fraseología

Definición

Tipo de unidad léxica que aparece una única vez dentro de un corpus determinado, lo que la distingue de aquellas palabras que presentan múltiples ocurrencias. Este concepto se utiliza en estudios morfológicos para operacionalizar la productividad de las reglas lingüísticas, por ejemplo a través del cálculo de la relación hapax-token (HTR). Se contrasta habitualmente con los dis legómenos y los tris legómenos, que designan palabras que aparecen dos o tres veces en el corpus, respectivamente.

Frecuencia (corpus ES)

abs: 30 pmw: 35.81

header

Metadata and formats

Definition

A component of a document that contains meta-information, distinguishing it from the main body of text. This information may include details such as the source, author, and type of text, and is often formatted differently depending on the document type, such as HTML or XML. The header serves a crucial role in organizing and retrieving data within corpus linguistics, facilitating selective recovery of relevant cases.

Frequency (EN corpus)

abs: 94 pmw: 73.99

Corpus evidence (EN)

"In 'linguistic' data, such meta-information is often stored either externally in a different file or database, or inside the document itself." (source)

"In the latter case, it's usually contained in something called a header." (source)

"Some document formats clearly separate the header and the body, whereas others don't." (source)

Nota terminológica / Terminological note

The term "header" is consistently used across various document formats to denote the section containing meta-information, which is essential for data organization and retrieval in corpus linguistics. Variations in its structure and content may arise depending on the specific requirements of the corpus design and the markup language used. El término "cabecera" se utiliza de manera consistente en diversos formatos de documentos para denotar la secc

Términos relacionados / Related terms

metadata / metadatos · **XML** / XML · **annotation** / anotación · **corpus design** / diseño de corpus · **markup language** / lenguaje de marcado

encabezado

Metadatos y formatos

Definición

Elemento de un documento que contiene metainformación, lo que lo distingue del cuerpo principal del texto. Esta información puede incluir detalles como la fuente, el autor y el tipo de texto, y suele estar formateada de manera diferente según el tipo de documento, como HTML o XML. La cabecera desempeña un papel crucial en la organización y recuperación de datos dentro de la lingüística de corpus, facilitando la recuperación selectiva de casos relevantes.

Frecuencia (corpus ES)

abs: 10 pmw: 12.32

Evidencia en corpus (ES)

"la inclusión de estos metadatos en el lugar adecuado (habitualmente la cabecera de un documento XML) permite hacer luego la recuperación selectiva de los casos que interesen." (fuente)

"Cada documento tiene un encabezado que indica la fuente del documento y proporciona información sobre el autor (origen, género, grupo social), tipo de texto (carta, testimonio, etcétera) y sobre el origen del documento (oral o escrito)." (fuente)

"Dicho de otro modo, al hacer una consulta, el corpus arrojará el resultado de un mismo registro (palabra) escrito con las diferentes ortografías que ha tenido a lo largo de la historia." (fuente)

Helsinki Corpus

Reference corpora

Definition

A specialized linguistic resource designed to represent historical stages of the English language, characterized by its static nature, as it is not intended to be updated with new data. This corpus serves as a reference point for diachronic studies, contrasting with monitor corpora that are designed to evolve over time. The Helsinki Corpus exemplifies the snapshot corpus type, capturing a specific linguistic moment without the capacity for future additions.

Frequency (EN corpus)

abs: 49 pmw: 38.57

Corpus evidence (EN)

"Even the diachronic ones are, because they've not been designed to be added to later, even if, for example, at some point in time a further Old English epic may somehow be unearthed and could thus theoretically be included in a new edition of the Helsinki Corpus." (2016_Weisser, M.)

"A genuine monitor corpus, as pointed out above, makes it possible to continually compare a language in its different stages of development, including the most recent changes, in and through one single corpus." (2016_Weisser, M.)

"An alternative solution to tracking change diachronically is to use static corpora, such as the LOB and the FLOB, which were designed to reflect the same categories of language, but using samples whose production dates were 30 years apart." (2016_Weisser, M.)

Nota terminológica / Terminological note

The term "Helsinki Corpus" is primarily used in the context of historical linguistics and corpus studies, emphasizing its role as a static resource for diachronic analysis. Its distinction from monitor corpora highlights the methodological choices made in corpus design, focusing on capturing specific linguistic moments rather than ongoing language evolution. El término "Corpus de Helsinki" se utiliza principalmente en el contexto de la lingüística

Términos relacionados / Related terms

monitor corpus / corpus monitor · **diachronic corpus** / corpus diacrónico · **monitor corpus** / corpus monitor · **reference corpus** / corpus de referencia · **corpus design** / diseño de corpus

Helsinki Corpus

Corpus de referencia

Definición

Recurso lingüístico especializado que representa etapas históricas del idioma inglés, caracterizado por su naturaleza estática, ya que no está destinado a ser actualizado con nuevos datos. Este corpus sirve como punto de referencia para estudios diacrónicos, en contraste con los corpus monitor que están diseñados para evolucionar con el tiempo. El Corpus de Helsinki ejemplifica el tipo de corpus instantáneo, capturando un momento lingüístico específico sin la capacidad de futuras adiciones.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

"La construcción de un corpus Hoy en día, pueden llevarse a cabo diversas investigaciones sobre el lenguaje con corpus ya existentes; sin embargo, cuando lo que se quiere es preservar, almacenar y sistematizar un material en particular o se requieren datos con características específicas, se hace necesaria la construcción de nuevos corpus." (2018_Bernal Chávez, J. A.)

"El término español oculta la diferencia existente en inglés entre los speech corpora y los spoken corpora." (2021_Rojo, G.)

"Dentro de la lingüística de corpus no existe un protocolo que determine paso a paso cómo crear un corpus." (2018_Bernal Chávez, J. A.)

historical corpus

Corpus design and compilation

Definition

A specialized collection of texts intentionally created to represent past stages of a language and to study language change. Historical corpora encompass various periods, genres, dialects, registers, and social strata, facilitating the analysis of linguistic evolution over time. This term contrasts with contemporary corpora, which focus on current language use rather than historical development.

Frequency (EN corpus)

abs: 60 pmw: 47.23

Corpus evidence (EN)

The earliest historical electronic resources emerged in the 1980s with the Dictionary of Old English database prepared in Toronto and the Augustan Prose Sample and the Century of Prose Corpus compiled at Cleveland State University. (source)

Since that time, corpus linguistics has continued to make its mark on the history of English through the growing number of historical corpora representing various periods, genres, dialects, registers and social strata of English. (source)

Claridge (2008: 242) defines a historical corpus as one which has been intentionally created to represent past stages of a language and/or to study language change. (source)

Nota terminológica / Terminological note

The term "historical corpus" is widely recognized in the field of corpus linguistics, emphasizing the intentional design of collections aimed at studying language change. Its usage is critical for researchers focusing on diachronic linguistics and the evolution of language over time. El término "corpus histórico" es ampliamente reconocido en el ámbito de la lingüística de corpus, enfatizando el diseño intencionado de colecciones destinadas al est

Términos relacionados / Related terms

corpus / corpus · **corpus linguistics** / lingüística de corpus · **diachronic corpus** / corpus diacrónico · **general corpus** / corpus general · **general corpus** / corpus general

corpus histórico

Diseño y compilación de corpus

Definición

Un conjunto especializado de textos creado intencionadamente para representar etapas pasadas de un idioma y estudiar el cambio lingüístico. Los corpus históricos abarcan diversos períodos, géneros, dialectos, registros y estratos sociales, lo que facilita el análisis de la evolución lingüística a lo largo del tiempo. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 29 pmw: 34.62

HTML

Metadata and formats

Definition

A markup language designed for structuring content on the web, which includes a fixed set of elements and attributes for defining document structure and formatting. HTML allows for the incorporation of hyperlinks, enabling navigation between related documents, and is recognized for its standardization and ease of use in presenting linguistic content. In contrast to XML, which is more extensible and user-defined, HTML has a more limited scope in terms of customization.

Frequency (EN corpus)

abs: 223 pmw: 175.54

Corpus evidence (EN)

"HTML itself defines a rather limited set of options for specifying structural properties of documents, such as elements for paragraphs (), different levels of headings (–), larger textual divisions (), smaller – inline – textual sequences (), different types of lists..." (source)

"HTML itself is largely standardised and also technically extensible via CSS to some extent, so that it's already quite useful for the presentation and visualisation of some linguistic content." (source)

"The option to include dynamic content via client-side scripting, which can be achieved with relative ease, can also be seen as an advantage..." (source)

Nota terminológica / Terminological note

HTML is widely used in web development and is essential for creating structured documents on the internet. Its limitations in extensibility compared to XML have led to the development of more flexible markup languages, but its foundational role in web content remains significant. HTML es ampliamente utilizado en el desarrollo web y es esencial para crear documentos estructurados en Internet. Sus limitaciones en extensibilidad en comparación con

Términos relacionados / Related terms

XML / XML · **SGML** / SGML · **metadata** / metadatos · **markup language** / lenguaje de marcado · **plain text** / texto plano · **HTML** / HTML

HTML

Metadatos y formatos

Definición

Un lenguaje de marcado específico para estructurar contenido en la web, que incluye un conjunto fijo de elementos y atributos para definir la estructura y el formato de los documentos. HTML permite la incorporación de hipervínculos, facilitando la navegación entre documentos relacionados, y es reconocido por su estandarización y facilidad de uso en la presentación de contenido lingüístico. A diferencia de XML, que es más extensible y permite definiciones personalizadas, HTML tiene un alcance más limitado en términos de personalización.

Frecuencia (corpus ES)

abs: 216 pmw: 266.08

Evidencia en corpus (ES)

"HTML incorpora los hipervínculos o vínculos, a fin de navegar entre distintos documentos con información relacionada." (fuente)

"Este lenguaje de marcado específico para compartir documentos en Internet contiene un conjunto de elementos y atributos fijos a los cuales hay que sujetarse." (fuente)

"HTML creció de una manera descontrolada y no cubrió todos los problemas que planteaba la sociedad global de Internet." (fuente)

inferential statistics

Frequency and statistics

Definition

A branch of statistics that involves methods for making inferences about population parameters based on sample data. This approach is crucial for testing hypotheses and assessing the significance of observed effects, as evidenced by its application in evaluating evidence against the null hypothesis. Inferential statistics contrasts with descriptive statistics, which focuses solely on summarizing data without drawing conclusions about a larger population.

Frequency (EN corpus)

abs: 22 pmw: 17.32

Corpus evidence (EN)

"This comparison between observed and expected frequencies also provides a foundation for inferential statistics, discussed in Chapter 6." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"Statistical tests in inferential statistics undertaken to assess the amount of evidence against the null hypothesis." (2022_McEnery_T., Brezina, V._Fundamental Principles of Corpus Linguistics)

"The choice of quantitative methods depends largely on what the corpus gives you." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

Inferential statistics is a critical component of quantitative research methodologies, allowing researchers to draw conclusions about populations based on sample data. Its application is widespread across various disciplines, including linguistics, where it aids in hypothesis testing and the evaluation of linguistic phenomena. Las estadísticas inferenciales son un componente crítico de las metodologías de investigación cuantitativa, permitiendo a

Términos relacionados / Related terms

descriptive statistics / estadísticas descriptivas · **inferential statistics** / estadísticas inferenciales · **statistical significance** / significancia estadística · **sample** / muestra · **probability** / probabilidad · **inferential statistics** / estadísticas inferenciales

estadísticas inferenciales

Frecuencia y estadística

Definición

Una rama de la estadística que implica métodos para realizar inferencias sobre parámetros poblacionales basados en datos de muestra. Este enfoque es fundamental para la formulación de hipótesis y la evaluación de la significación de los efectos observados, tal como se evidencia en su aplicación para evaluar la evidencia contra la hipótesis nula. Las estadísticas inferenciales se contrastan con las estadísticas descriptivas, que se centran únicamente en resumir datos sin extraer conclusiones sobre una población más amplia.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"La estadística multivariante es el área de la estadística que se ocupa de las observaciones realizadas a partir de muchas variables." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"Las estadísticas inferenciales se contrastan con las estadísticas descriptivas, que se centran únicamente en resumir datos." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

"Este enfoque es fundamental para la formulación de hipótesis y la evaluación de la significación de los efectos observados." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

inline annotation

Annotation and markup

Definition

A specific type of annotation that is embedded directly within the text, allowing for the addition of interpretative information without altering the original content structure. This method contrasts with standoff annotation, where annotations are stored separately from the text, thus providing a different approach to enriching linguistic data. Inline annotation enhances the text's amenability to various research questions by making specific linguistic features more salient.

Frequency (EN corpus)

abs: 2 pmw: 1.57

Corpus evidence (EN)

Different terms when talking about the process of storing and enriching linguistic data, markup and annotation. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

The specific design of annotation systems is codetermined by the specific research interests involved and therefore, we will need to refer to various research projects time and again. (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

The corpora are marked up using the ACE Pilot Format (APF), a standoff XML markup format in which a base file contains the text with some inline SGML annotation. (source: 2016_Poesio, M., et al._Annotated Corpora and Annotation Tools)

Nota terminológica / Terminological note

The term "inline annotation" is primarily used in the context of corpus linguistics to describe a method of embedding annotations directly within the text, enhancing its interpretative richness. This approach is often contrasted with standoff annotation, which separates annotations from the text, allowing for different methodologies in data enrichment. El término "anotación en línea" se utiliza principalmente en el contexto de la lingüística de c

Términos relacionados / Related terms

annotation / anotación · **markup language** / lenguaje de marcado · **corpus annotation** / anotación de corpus · **semantic annotation** / anotación semántica · **annotation scheme** / esquema de anotación

anotación en línea

Anotación y marcado

Definición

Una anotación que se inserta directamente en el texto, permitiendo la adición de información interpretativa sin modificar la estructura original del contenido. Este tipo de anotación se diferencia de la anotación externa, donde las anotaciones se almacenan por separado del texto, ofreciendo así un enfoque distinto para enriquecer los datos lingüísticos. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

—

inter-annotator agreement

Annotation and markup

Definition

A measure of the extent to which different annotators provide consistent labels or classifications for the same data. This concept is crucial for assessing the reliability of annotation schemes, particularly in studies involving multiple categories, where discrepancies can arise due to ambiguity or vagueness in the guidelines. High inter-annotator agreement indicates that the annotation scheme is well-defined and can be reliably applied across different annotators.

Frequency (EN corpus)

abs: 23 pmw: 18.10

Corpus evidence (EN)

weak inter-annotator agreement made authors reflect on the annotation results, and more specifically on the metric used (Cohen's kappa) and how suitable this metric is for the task. (source: 2023_Simaki, V., Seitanidi, E., Paradis, C.)

A common issue that arises when calculating the reliability of annotated data in a scheme with more than two labels is that infrequent categories emerge from the annotation process, which leads to an uneven distribution of categories that produces unbalanced datasets, and subsequently leads to a lower reliability score. (source: 2023_Simaki, V., Seitanidi, E., Paradis, C.)

However, in practice there are two problems with this procedure. First, it is extremely time-consuming, which will often make it difficult to impossible to find a second annotator. (source: 2020_Stefanowitsch, A.)

Nota terminológica / Terminological note

The term inter-annotator agreement is widely used in the field of corpus linguistics to assess the reliability of annotation processes. Variations in its application may arise based on the specific annotation schemes employed and the complexity of the data being annotated. El término acuerdo inter-annotador se utiliza ampliamente en el ámbito de la lingüística de corpus para evaluar la fiabilidad de los procesos de anotación. Las variaciones en

Términos relacionados / Related terms

annotation / anotación · **annotation scheme** / esquema de anotación · **inter-annotator agreement** / acuerdo interanotador · **inter-annotator agreement** / acuerdo interanotador · **annotated corpus** / corpus anotado

acuerdo interanotador

Anotación y marcado

Definición

Una medida de la consistencia con la que diferentes anotadores asignan etiquetas o clasificaciones a los mismos datos. Este concepto es fundamental para evaluar la fiabilidad de los esquemas de anotación, especialmente en estudios que involucran múltiples categorías, donde pueden surgir discrepancias debido a la ambigüedad o vaguedad en las directrices. Un alto acuerdo inter-annotador indica que el esquema de anotación está bien definido y puede aplicarse de manera fiable entre diferentes anotadores.

Frecuencia (corpus ES)

abs: 3 pmw: 3.70

Evidencia en corpus (ES)

La segunda generación de analizadores parte de esta idea del contexto precedente, pero se basa en el recuento de casos en un corpus anotado y revisado por lingüistas (lo que se conoce como gold standard). (fuente: 2022_Moreno Sandoval, A.)

Dicho en términos muy básicos, se hacen recuentos de trigramas por categorías sintácticas e incluyendo signos de puntuación y comienzo de oración. (fuente: 2022_Moreno Sandoval, A.)

La intervención humana se reduce a revisar las anotaciones del corpus de entrenamiento. (fuente: 2022_Moreno Sandoval, A.)

inter-rater reliability

Annotation and markup

Definition

A measure of the degree of agreement among different annotators when assessing the same data set, indicating the consistency and reliability of the annotation process. This concept is critical in ensuring the quality of annotated data, as highlighted by the varying metrics used to calculate it, such as Cohen's kappa and AC1, which address different aspects of agreement. The methodological status of this term is underscored by the ongoing debate regarding acceptable thresholds for reliability scores in annotation studies.

Frequency (EN corpus)

abs: 3 pmw: 2.36

Corpus evidence (EN)

weak inter-annotator agreement made authors reflect on the annotation results, and more specifically on the metric used (Cohen's kappa) and how suitable this metric is for the task. (source)

This metric estimates the agreements between annotators as they are not partly due to chance (expected agreement) and it is less affected by the prevalence of categories and the marginal probability than the Cohen's kappa. (source)

The calculations of the inter-annotator agreement raised another important question about the interpretation of the results: What can be considered as an acceptable level of reliability? (source)

Nota terminológica / Terminological note

The term inter-rater reliability is essential in the field of corpus linguistics, particularly in annotation tasks where multiple annotators are involved. Its measurement is crucial for ensuring the quality and usability of annotated data, with various metrics available to assess it, reflecting ongoing discussions about acceptable reliability thresholds in research. El término fiabilidad interevaluador es fundamental en el ámbito de la lingüística

Términos relacionados / Related terms

inter-annotator agreement / acuerdo interanotador · **annotation scheme** / esquema de anotación · **inter-annotator agreement** / acuerdo interanotador · **annotated corpus** / corpus anotado · **statistical significance** / significancia estadística · **dataset** / conjunto de datos · **accuracy** / exactitud

fiabilidad interevaluador

Anotación y marcado

Definición

La fiabilidad interevaluador es una medida que indica el grado de acuerdo entre diferentes evaluadores al analizar el mismo conjunto de datos, lo que refleja la consistencia y la fiabilidad del proceso de anotación. Este concepto es fundamental para garantizar la calidad de los datos anotados, y se utilizan diversas métricas para calcularlo, como el kappa de Cohen y AC1, que abordan diferentes aspectos del acuerdo. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 4 pmw: 4.78

International Corpus of English

Reference corpora

Definition

A specialized corpus that encompasses various English varieties used globally, designed to facilitate comparative linguistic studies. This corpus serves as a significant resource for understanding the diversity and usage patterns of English across different regions, contrasting with more localized corpora such as the Brown Corpus or the LOB Corpus, which focus on specific dialects or varieties.

Frequency (EN corpus)

abs: 52 pmw: 40.93

Corpus evidence (EN)

"the formation of International Corpus of English as a mission for generating a corpus with different varieties of English used across the world." (source)

"the International Corpus of English: Mark-up for spoken language." (source)

"the International Corpus of English, ed. S. Greenbaum." (source)

Nota terminológica / Terminological note

The term "International Corpus of English" reflects the growing recognition of English as a global language, with its varieties being systematically documented. This corpus is pivotal for researchers interested in the linguistic features and usage patterns of English across different cultures and regions. El término "Corpus Internacional de Inglés" refleja el creciente reconocimiento del inglés como lengua global, con sus variedades siendo docume

Términos relacionados / Related terms

corpus / corpus · **general corpus** / corpus general · **national corpus** / corpus nacional · **comparable corpus** / corpus comparable · **BNC** / BNC · **corpus design** / diseño de corpus · **corpus compilation** / compilación de corpus

International Corpus of English

Corpus de referencia

Definición

Un corpus especializado que abarca diversas variedades del inglés utilizadas a nivel mundial, diseñado para facilitar estudios lingüísticos comparativos. Este corpus actúa como un recurso significativo para comprender la diversidad y los patrones de uso del inglés en diferentes regiones, en contraste con corpus más localizados como el Brown Corpus o el LOB Corpus, que se centran en dialectos o variedades específicas.

Frecuencia (corpus ES)

abs: 6 pmw: 7.39

Evidencia en corpus (ES)

"la lingüística de corpus ha sido más espectacular en el inglés, como se observa en el número de corpus de inglés, como el International Corpus of English." (fuente)

"el International Corpus of English es un recurso significativo para la investigación en variación lingüística." (fuente)

"el International Corpus of English se ha desarrollado en varias partes del mundo, reflejando la diversidad del inglés." (fuente)

keyness

Lexicon and phraseology

Definition

A statistical measure used in corpus linguistics to identify words that are significantly more frequent in a specific corpus compared to a reference corpus. This measure helps to reveal the distinctive lexical characteristics of texts, contributing to the understanding of keywords in various contexts, such as discourse analysis and genre studies. Keyness is often contrasted with traditional frequency measures, as it accounts for both frequency and association strength.

Frequency (EN corpus)

abs: 86 pmw: 67.70

Corpus evidence (EN)

"It is this information loss that the following sections are trying to combat." (source)

"The first of its two main advantages is that it is less related to frequency and, thus, amounts to less of a conflation." (source)

"This measure is an information-theoretic measure called the 'Kullback-Leibler (KL) divergence'." (source)

Nota terminológica / Terminological note

Keyness is a crucial concept in corpus linguistics, particularly in keyword analysis, where it serves to highlight the distinctive vocabulary of specific texts. Its methodological significance lies in its ability to combine frequency and association measures, providing a more nuanced understanding of lexical usage across different contexts. La clave es un concepto crucial en la lingüística de corpus, especialmente en el análisis de palabras clav

Términos relacionados / Related terms

keyword / palabra clave · **frequency** / frecuencia · **corpus-based** / basado en corpus · **association measures** / medidas de asociación · **concordance** / concordancia · **dispersion** / dispersión

keyness

Léxico y fraseología

Definición

Una medida estadística utilizada en la lingüística de corpus para identificar palabras que son significativamente más frecuentes en un corpus específico en comparación con un corpus de referencia. Esta medida permite revelar las características léxicas distintivas de los textos, contribuyendo a la comprensión de las palabras clave en diversos contextos, como el análisis del discurso y los estudios de género. La clave se contrasta a menudo con las medidas de frecuencia tradicionales, ya que tiene en cuenta tanto la frecuencia como la fuerza de asociación.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Evidencia en corpus (ES)

"Los corpus generales permiten, en efecto, extraer datos acerca de las características relevantes de la L2 y hacerlo de forma selectiva en función de los diferentes tipos de texto..." (fuente)

"El análisis de errores gana en precisión y posibilidades de generalización si el corpus ha recibido ese tipo de codificación." (fuente)

"Una forma rápida y cómoda de ver algunos datos de interés consiste en buscar en el CAES casos de artículos masculinos seguidos inmediatamente por sustantivos femeninos." (fuente)

keyword

Lexicon and phraseology

Definition

A significant term in corpus linguistics, this concept denotes a word that exhibits statistical significance in one corpus when compared to another. The identification of such terms is data-driven, relying on frequency analysis to reveal their importance within specific discourses. Unlike general vocabulary, keywords are often used to signal important social, cultural, and political cues in discourse, thus serving as indicators for further qualitative analysis.

Frequency (EN corpus)

abs: 337 pmw: 265.27

Corpus evidence (EN)

"In cads, a keyword is one that is statistically significant in one corpus relative to another." (2025_Batchelor, J., Lee-Laminack, H.)

"Keyword analysis thus allows researchers to make sound conclusions about what words are representative of a given corpus." (2025_Batchelor, J., Lee-Laminack, H.)

"The order of KWs is not intrinsically trustworthy, because it depends not only on the frequency in the text we are studying but also on their frequencies in the reference corpus." (2016_Weisser, M.)

Nota terminológica / Terminological note

The term "keyword" is often employed in a quantitative context, emphasizing its statistical basis for significance in corpus analysis. However, its qualitative implications are equally important, as keywords can reveal deeper cultural and social meanings within texts. El término "palabra clave" se utiliza frecuentemente en un contexto cuantitativo, enfatizando su base estadística para la significación en el análisis de corpus. Sin embargo, sus i

Términos relacionados / Related terms

keyword analysis / análisis de palabras clave · **frequency** / frecuencia · **corpus** / corpus · **concordance** / concordancia · **collocation** / colocación · **reference corpus** / corpus de referencia

palabra clave

Léxico y fraseología

Definición

En lingüística de corpus, este término designa una palabra que muestra una significación estadística en un corpus en comparación con otro. La identificación de estas palabras se basa en análisis de frecuencia, lo que permite revelar su importancia en discursos específicos. A diferencia del vocabulario general, las palabras clave suelen señalar indicios sociales, culturales y políticos relevantes, sirviendo como indicadores para un análisis cualitativo más profundo.

Frecuencia (corpus ES)

abs: 16 pmw: 19.71

Evidencia en corpus (ES)

"En corpus anotados también podemos hacer lo mismo con elementos gramaticales, esto es buscar y obtener muestras de uso contextualizado y frecuencias de aparición y coaparición de cualquier categoría gramatical anotada." (2022_García Miguel J. M.)

"Tomando la palabra (ortográfica) como unidad básica de referencia, cualquier sistema de exploración de corpus nos permite obtener listados de las palabras del corpus con su frecuencia." (2022_García Miguel J. M.)

"Los resultados que nos ofrecen algunos corpus, tales como palabras clave de un texto o conjunto de textos, no son sino resultados derivados de los anteriores." (2022_García Miguel J. M.)

keyword analysis

Lexicon and phraseology

Definition

A method employed in corpus linguistics to identify words that exhibit statistically significant frequency in a target corpus compared to a reference corpus. This technique allows researchers to discern linguistic features that are characteristic of specific texts or discourse communities, thus providing insights into cultural and social contexts. It is often contrasted with qualitative analyses that focus on thematic interpretations of language use.

Frequency (EN corpus)

abs: 141 pmw: 110.99

Corpus evidence (EN)

"Keyword analysis thus allows researchers to make sound conclusions about what words are representative of a given corpus." (2025_Batchelor, J., Lee-Laminack, H.)

"In other words, the corpus-linguistic identification of keywords is analogous to the identification of differential collocates." (2020_Stefanowitsch, A.)

"To perform keyword analysis, researchers generally follow the following steps." (2025_Batchelor, J., Lee-Laminack, H.)

Nota terminológica / Terminological note

The term "keyword analysis" is widely recognized in corpus linguistics as a quantitative method for identifying significant words within texts. Its application often intersects with qualitative approaches, emphasizing the need for a comprehensive understanding of language in context. El término "análisis de palabras clave" es ampliamente reconocido en la lingüística de corpus como un método cuantitativo para identificar palabras significativas d

Términos relacionados / Related terms

corpus / corpus · frequency / frecuencia · collocation / colocación · concordance / concordancia · keyword analysis / análisis de palabras clave · statistical significance / significancia estadística

análisis de palabras clave

Léxico y fraseología

Definición

El análisis de palabras clave es un método utilizado en la lingüística de corpus para identificar términos que presentan una frecuencia estadísticamente significativa en un corpus objetivo en comparación con un corpus de referencia. Este enfoque permite a los investigadores discernir características lingüísticas que son representativas de textos específicos o comunidades discursivas. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 2 pmw: 2.39

KWIC

Search and retrieval

Definition

A display format that presents a target word in the center of a line, flanked by a specified number of words on either side, facilitating the examination of contextual usage. This method, known as keyword in context (KWIC), is particularly useful for initial data exploration, allowing researchers to identify patterns and collocational relationships. Unlike simple frequency lists, KWIC displays provide a more nuanced understanding of word usage within specific contexts.

Frequency (EN corpus)

abs: 41 pmw: 32.27

Corpus evidence (EN)

"This kind of display is called keyword in context or KWIC." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"A KWIC can usually be sorted alphabetically or by frequency of co-occurrence." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"KWIC display actually starts with the second unit." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term KWIC is widely used in corpus linguistics to denote a specific method of displaying word contexts, which enhances the interpretative power of linguistic data. Variations in its application may arise depending on the corpus type and research objectives, reflecting the evolving methodologies in the field. El término KWIC se utiliza ampliamente en la lingüística de corpus para denotar un método específico de visualización de contextos de pa

Términos relacionados / Related terms

concordance / concordancia · **collocation** / colocación · **frequency** / frecuencia · **corpus queries** / consultas de corpus · **keyword analysis** / análisis de palabras clave · **text type** / tipo de texto

KWIC

Búsqueda y consulta

Definición

Un formato de visualización que presenta una palabra objetivo en el centro de una línea, rodeada por un número especificado de palabras a cada lado, facilitando el examen del uso contextual. Este método, conocido como palabra clave en contexto (KWIC), es especialmente útil para la exploración inicial de datos, permitiendo a los investigadores identificar patrones y relaciones de colocación. A diferencia de las listas de frecuencia simples, las visualizaciones KWIC ofrecen una comprensión más matizada del uso de palabras dentro de contextos específicos.

Frecuencia (corpus ES)

abs: 8 pmw: 9.85

Evidencia en corpus (ES)

"Los corpus paralelos o bitextos tienen un rol esencial en los estudios modernos relacionados a la traducción automática." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"El análisis de errores gana en precisión y posibilidades de generalización si el corpus ha recibido ese tipo de codificación." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

"Una forma rápida y cómoda de ver algunos datos de interés consiste en buscar en el CAES casos de artículos masculinos seguidos inmediatamente por sustantivos femeninos." (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

learner corpus

Corpus design and compilation

Definition

A specific type of corpus is generated from a selected collection of texts produced by language learners, encompassing both written and spoken samples. This corpus is primarily composed of language samples created by learners during spontaneous linguistic interactions, distinguishing it from other types of corpora that may include expert-generated texts. The term is well-established in the field, contrasting with "learner's corpus," which refers to texts designed by experts to aid learners.

Frequency (EN corpus)

abs: 99 pmw: 77.93

Corpus evidence (EN)

"A learner corpus is generated from a chosen collection of texts produced by the language learners." (2018_Sekhar Dash, N., Arulmozi, S.)

"The corpus should contain both written and spoken text samples produced by the learners." (2018_Sekhar Dash, N., Arulmozi, S.)

"If one wants to create a corpus of this kind, one should invariably concentrate on the systematic collection of texts written and spoken by the learners in spontaneous linguistic interactions." (2018_Sekhar Dash, N., Arulmozi, S.)

Nota terminológica / Terminological note

The term "learner corpus" is widely accepted in the field of corpus linguistics, specifically referring to texts produced by language learners. It is important to distinguish it from "learner's corpus," which may include expert-designed materials for learners. The methodological implications of compiling a learner corpus involve careful consideration of the types of texts included and the contexts in which they were produced. El término "corpus d

Términos relacionados / Related terms

corpus / corpus · corpus design / diseño de corpus · reference corpus / corpus de referencia · annotated corpus / corpus anotado · specialized corpus / corpus especializado · training corpus / corpus de entrenamiento

corpus de aprendices

Diseño y compilación de corpus

Definición

Un tipo específico de corpus que se genera a partir de una colección seleccionada de textos producidos por aprendices de lengua, que abarca tanto muestras escritas como habladas. Este corpus se compone principalmente de muestras de lenguaje creadas por los aprendices durante interacciones lingüísticas espontáneas, lo que lo distingue de otros tipos de corpus que pueden incluir textos generados por expertos. El término está bien establecido en el campo, en contraste con "corpus del aprendiz", que se refiere a textos diseñados por expertos para ayudar a los aprendices.

Frecuencia (corpus ES)

abs: 32 pmw: 39.42

Evidencia en corpus (ES)

"Normalmente, el primero siempre será más grande que el segundo y, de hecho, se usa en numerosas ocasiones como referencia." (2024_Jiménez-Navarro, E. L.)

"Otro punto relevante es el tipo de discurso que abarca, que puede ser escrito o hablado, así como la muestra de textos que incluye." (2024_Jiménez-Navarro, E. L.)

"Se ha llevado a cabo la presentación de la herramienta Sketch Engine, la cual se puede utilizar para dos objetivos principales: (1) la compilación de un nuevo corpus, y (2) la exploración de corpus." (2024_Jiménez-Navarro, E. L.)

lemma

Language processing

Definition

A fundamental concept in linguistics, this term encompasses all forms of a word paradigm, including variations based on part of speech. It serves as a reference point in corpus linguistics for grouping inflected forms, facilitating more efficient searches and analyses. The methodological significance is highlighted by its role in lemmatisation, which aims to reduce ambiguity in corpus data by consolidating related forms.

Frequency (EN corpus)

abs: 89 pmw: 70.06

Corpus evidence (EN)

"Some concordance programs... are able to 'understand' the structure of such annotations and offer a query syntax that allows the researcher to refer to this structure directly." (source: 2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"The main disadvantage of the COCA interface... lies in the fact that it's not possible to get the frequency breakdown according to tags, which makes it more difficult to discern between polysemous forms." (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"In order to compare the results to the equivalent data from the BNC, click to open the dropdown list that initially reads SIDE BY SIDE." (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term "lemma" is widely accepted in both English and Spanish corpus linguistics, serving as a cornerstone for various analytical processes. Its application can vary slightly depending on the specific linguistic framework or corpus design, but its core function remains consistent across methodologies. El término "lema" es ampliamente aceptado en la lingüística de corpus tanto en inglés como en español, sirviendo como piedra angular para divers

Términos relacionados / Related terms

lemmatisation / lematización · **token** / token · **parts of speech** / categorías gramaticales · **annotation** / anotación · **corpus** / corpus · **frequency** / frecuencia

lema

Procesamiento del lenguaje

Definición

Concepto fundamental en lingüística que agrupa todas las formas de un paradigma léxico, incluyendo variaciones según la categoría gramatical. Este término actúa como un punto de referencia en la lingüística de corpus para la lematización, permitiendo búsquedas y análisis más eficientes al reducir la ambigüedad en los datos del corpus.

Frecuencia (corpus ES)

abs: 316 pmw: 389.27

Evidencia en corpus (ES)

"Por otra parte, al tratarse de un factor que se introduce con carácter adicional, permite combinar opciones muy diferentes entre sí: es posible pedir una forma o bien todas las formas de un lema..." (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

"Del lema comer devolvería todas las formas de como, que corresponde a dos lemas: comer y como." (fuente: 2019_de Benito, C._Los corpus del español desde la perspectiva del usuario lingüista_Scriptum digital)

"Si se buscan en el CORDE los textos anteriores a 1400 en los que aparecen las formas altísimo y muy alto, la respuesta es que solo hay un texto en el que alternen..." (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

lemmatisation

Language processing

Definition

The process of grouping different word forms under their dictionary headword, enabling the analysis of all inflected forms of a lexeme as a single entity. This methodological feature is crucial for corpus analysis, as it allows for comprehensive searches that capture all relevant word forms, such as "woman," "women," "woman's," and "women's." Lemmatisation serves as a layer of corpus annotation, distinguishing it from tokenisation, which deals with individual occurrences of word forms.

Frequency (EN corpus)

abs: 49 pmw: 38.57

Corpus evidence (EN)

A general consideration for corpus analysis is the way in which searches and frequency counts group together the different word forms in the corpus. (source)

This is accomplished using lemmatisation. (source)

Many modern corpora of well-studied languages, however, include the technical feature of lemmatisation, that is, the information about which wordforms belong to which lexemes. (source)

lematización

Procesamiento del lenguaje

Definición

La lematización es el proceso de agrupar diferentes formas de palabras bajo su lema o forma base, permitiendo el análisis de todas las formas flexionadas de un lexema como una única entidad. Esta característica metodológica es esencial para el análisis de corpus, ya que facilita búsquedas exhaustivas que capturan todas las formas relevantes de palabras. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 95 pmw: 113.41

Nota terminológica / Terminological note

Lemmatisation is a fundamental process in corpus linguistics that enhances the accuracy and efficiency of text analysis by consolidating various word forms. Its application can vary across different corpora, depending on the linguistic features of the language being studied and the goals of the analysis. La lematización es un proceso fundamental en la lingüística de corpus que mejora la precisión y eficiencia del análisis de texto al consolidar

Términos relacionados / Related terms

tokenisation / tokenización · **lemma** / lema · **corpus annotation** / anotación de corpus · **part-of-speech tagging** / etiquetado morfosintáctico · **corpus queries** / consultas de corpus

lexeme

Language processing

Definition

A fundamental unit in linguistic analysis, this concept represents a set of related wordforms that share a common meaning. The distinction between lexemes and wordforms is crucial in corpus linguistics, as it informs the methodology for conducting corpus queries and understanding lexical variation. For instance, the term is often contrasted with "wordform," which refers to the specific grammatical variations of a lexeme.

Frequency (EN corpus)

abs: 40 pmw: 31.49

Corpus evidence (EN)

The distinction between wordforms and lexemes, which, depending on the research question can be an important distinction. (source)

If we are interested in the use of any given lexeme in a corpus, we have to make sure that we are going to capture all its wordforms when searching for it. (source)

Many modern corpora of well-studied languages, however, include the technical feature of lemmatisation, that is, the information about which wordforms belong to which lexemes. (source)

Nota terminológica / Terminological note

The term "lexeme" is widely accepted in linguistic studies, particularly in corpus linguistics, where it serves as a foundational concept for analyzing wordforms and their meanings. Variations in its usage may arise from different linguistic traditions or methodological approaches, particularly in relation to lemmatisation and tokenisation practices. El término "lexema" es ampliamente aceptado en los estudios lingüísticos, especialmente en la li

Términos relacionados / Related terms

token / token · **lemma** / lema · **word class** / clase de palabras · **collocation** / colocación · **tokenisation** / tokenización · **frequency** / frecuencia

lexema

Procesamiento del lenguaje

Definición

Unidades fundamentales en el análisis lingüístico, los lexemas representan un conjunto de formas de palabras que comparten un significado común. La distinción entre lexema y forma de palabra es crucial en la lingüística de corpus, ya que informa la metodología para realizar consultas en corpus y comprender la variación léxica. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 20 pmw: 23.88

lexical bundles

Lexicon and phraseology

Definition

Sequences of words that frequently co-occur within a specific corpus, typically defined as multi-word expressions that appear together with a certain frequency threshold. These bundles are operationalized in research as sequences that occur at least ten times per million words and in a minimum of five texts, indicating their relevance in the discourse of the target domain. The study of lexical bundles is crucial for understanding patterns of language use and the evolution of academic writing styles across disciplines.

Frequency (EN corpus)

abs: 48 pmw: 37.78

Corpus evidence (EN)

"To illustrate, we operationalized lexical bundles as four-word sequences that occurred at least ten times per million words and in at least five texts in the sample corpus." (source)

"Some bundles, such as on the other hand, in the case of, and on the basis of, have remained popular throughout the period..." (source)

"The results show a significant shift in uses and perhaps how these disciplines understand academic argument and the ways their members seek to persuade peers." (source)

Nota terminológica / Terminological note

The concept of lexical bundles is essential in corpus linguistics for analyzing language patterns and usage across different contexts. Variations in the definition and identification of these bundles may arise depending on the corpus size and the specific linguistic features being examined. El concepto de grupos léxicos es esencial en la lingüística de corpus para analizar patrones y usos del lenguaje en diferentes contextos. Las variaciones en

Términos relacionados / Related terms

collocation / colocación · **frequency** / frecuencia · **corpus** / corpus · **text type** / tipo de texto · **grammar** / gramática · **keyword** / palabra clave

grupos léxicos

Léxico y fraseología

Definición

Secuencias de palabras que co-ocurren con frecuencia dentro de un corpus específico, definidas generalmente como expresiones de varias palabras que aparecen juntas con un umbral de frecuencia determinado. Estos grupos léxicos se operacionalizan en la investigación como secuencias que ocurren al menos diez veces por millón de palabras y en un mínimo de cinco textos, lo que indica su relevancia en el discurso del dominio objetivo. El estudio de los grupos léxicos es crucial para comprender los patrones de uso del lenguaje y la evolución de los estilos de escritura académica en diversas disciplin

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"Una rama de creciente importancia dentro de los estudios de corpus es el análisis de grupos o clustering, que se puede utilizar para la exploración de datos..." (fuente)

"El objetivo de estos métodos de agrupación es crear grupos tanto con una alta similitud dentro de la misma clase como de una baja similitud entre diferentes clases." (fuente)

"La idea básica es reorganizar el método de investigación tradicional y no aplicar la interpretación solo a los resultados y al análisis..." (fuente)

LOB

Reference corpora

Definition

A specialized corpus that serves as a reference for linguistic analysis, particularly in the study of British English. It is noted for its role in part-of-speech tagging and has been used in various studies to facilitate the retrieval of grammatical categories. The LOB corpus is often contrasted with the Brown Corpus, highlighting differences in size and temporal context.

Frequency (EN corpus)

abs: 304 pmw: 239.30

Corpus evidence (EN)

"the word-class tagging of the LOB and F-LOB corpora" (2022_McEnery_ T., Brezina, V._Fundamental Principles of Corpus Linguistics)

"the formation and content of the Lancaster-Oslo-Bergen (LOB) Corpus" (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

"the precise scheme in question is not identified, but again, by convention we may assume it is the one encoded in the public distributions of the LOB and FLOB corpora" (2022_McEnery_ T., Brezina, V._Fundamental Principles of Corpus Linguistics)

Nota terminológica / Terminological note

The LOB corpus represents a significant milestone in the development of digital corpora for linguistic research, particularly in British English. Its methodologies and design principles have influenced subsequent corpus projects, establishing a foundation for comparative studies in English linguistics. El corpus LOB representa un hito significativo en el desarrollo de corpora digitales para la investigación lingüística, especialmente en el inglés

Términos relacionados / Related terms

Brown Corpus / Brown Corpus · **part-of-speech tagging** / etiquetado morfosintáctico · **corpus design** / diseño de corpus · **LOB Corpus** / LOB Corpus · **reference corpus** / corpus de referencia · **annotation** / anotación

LOB

Corpus de referencia

Definición

Un corpus especializado que actúa como referencia para el análisis lingüístico, especialmente en el estudio del inglés británico. Se destaca por su función en la etiquetación de partes del discurso y ha sido utilizado en diversos estudios para facilitar la recuperación de categorías gramaticales. El corpus LOB se contrasta a menudo con el Brown Corpus, subrayando diferencias en tamaño y contexto temporal.

Frecuencia (corpus ES)

abs: 18 pmw: 22.17

Evidencia en corpus (ES)

"los corpus generales permiten, en efecto, extraer datos acerca de las características relevantes de la L2" (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

"los corpus de aprendientes incorporan los textos tal como han sido producidos originalmente" (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

"los corpus de aprendientes son 'colecciones electrónicas de textos de aprendices de una lengua extranjera o segunda'" (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

LOB Corpus

Reference corpora

Definition

A specialized reference corpus designed to provide a comprehensive linguistic resource, the LOB Corpus encompasses a wide range of genres and text types. It was developed to closely match the structure and content of the Brown Corpus, ensuring a systematic arrangement of text samples into subject categories. This corpus serves as a methodological model for text selection and collection in linguistic research.

Frequency (EN corpus)

abs: 159 pmw: 125.16

Corpus evidence (EN)

"the formation and content of the Lancaster-Oslo-Bergen (LOB) Corpus; presented a short overview of the content and structure of the Australian Corpus of English; briefly reported on the process of generating the Corpus of New Zealand English..." (source)

"the technique of text selection and collection in the case of the LOB Corpus is an interesting story that may be imitated for other languages." (source)

"the materials within the main text categories of the LOB Corpus are arranged to match that of the Brown Corpus as closely as possible." (source)

Nota terminológica / Terminological note

The LOB Corpus represents a significant advancement in the development of digital corpora, particularly in its systematic approach to text selection and categorization. Its design principles have influenced the creation of other corpora, establishing a framework for linguistic research that emphasizes representativeness and genre diversity. El Corpus LOB representa un avance significativo en el desarrollo de corpora digitales, especialmente en su

Términos relacionados / Related terms

Brown Corpus / Brown Corpus · **reference corpus** / corpus de referencia · **corpus design** / diseño de corpus · **genre** / género · **text type** / tipo de texto · **sampling frame** / marco de muestreo

LOB Corpus

Corpus de referencia

Definición

El Corpus LOB es un corpus de referencia diseñado para proporcionar un recurso lingüístico integral que abarca una amplia gama de géneros y tipos de texto. Se desarrolló para coincidir estrechamente con la estructura y el contenido del Brown Corpus, asegurando una disposición sistemática de las muestras de texto en categorías temáticas. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 18 pmw: 21.49

log-likelihood

Frequency and statistics

Definition

A statistical measure used to determine the strength of association between two terms based on their co-occurrence frequencies in a given context. This metric is often employed in collocational analysis, contrasting with other association measures like mutual information and chi-squared tests. The log-likelihood ratio is particularly noted for its application in identifying statistically significant collocations within corpus data.

Frequency (EN corpus)

abs: 46 pmw: 36.21

Corpus evidence (EN)

"many analyses proceed by computing the log-likelihood ratio (LLR) for this table..." (source: 2021_Gries, S. T.)

"this study used collocational analysis based on a combination of Mutual Information and log-likelihood tests..." (source: 2017_Allen, W.)

"the important parts are the row totals, the column totals, and the table totals, as you know from Sect. 9.3.1." (source: 2017_Desagulier, G.)

Nota terminológica / Terminological note

The term "log-likelihood" is widely used in corpus linguistics for statistical analysis, particularly in identifying collocations. Its application alongside other measures like mutual information and chi-squared tests highlights its methodological significance in the field. El término "log-verosimilitud" se utiliza ampliamente en la lingüística de corpus para el análisis estadístico, especialmente en la identificación de colocaciones. Su aplicac

Términos relacionados / Related terms

mutual information / información mutua · **chi-squared** / test de chi-cuadrado · **collocation** / colocación · **association measures** / medidas de asociación · **keyword** / palabra clave · **frequency** / frecuencia · **statistical significance** / significancia estadística

log-verosimilitud

Frecuencia y estadística

Definición

Una medida estadística que se utiliza para determinar la fuerza de la asociación entre dos términos en función de sus frecuencias de co-ocurrencia en un contexto determinado. Este estadístico se emplea comúnmente en el análisis de colocaciones, contrastando con otras medidas de asociación como la información mutua y la prueba de chi-cuadrado. La log-verosimilitud se destaca por su aplicación en la identificación de colocaciones estadísticamente significativas dentro de los datos de corpus.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

"log-verosimilitud... uno de los varios estadísticos que sirven para determinar la fuerza de la asociación que se establece entre dos términos..." (fuente: 2021_Rojo, G.)

"la log-verosimilitud se destaca por su aplicación en la identificación de colocaciones estadísticamente significativas..." (fuente: 2021_Rojo, G.)

"la frecuencia de aparición en el mismo contexto." (fuente: 2021_Rojo, G.)

markup language

Annotation and markup

Definition

A system for annotating a document in a way that is syntactically distinguishable from the text itself, allowing for the inclusion of metadata and structural information. This format is essential for enriching linguistic data and can be applied to various types of texts, facilitating both categorization and enhanced readability. Markup languages, such as XML and HTML, differ from annotation in that they primarily focus on the structural representation of data rather than interpretative information.

Frequency (EN corpus)

abs: 41 pmw: 32.27

Corpus evidence (EN)

different terms when talking about the process of storing and enriching linguistic data, markup and annotation. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

As such, they can refer to either a particular format for enriching a text, so as to categorize parts thereof, or to the actual process of applying this form of annotation. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

the original SGML (Standard Generalized Markup Language) markup format of the ICE spoken data was defined in Nelson (1991), and later revised in Annotating the ICE corpora pragmatically. (source: 2017_Weisser, M._Annotating the ICE corpora pragmatically. Preliminary issues and steps_ICAME)

Nota terminológica / Terminological note

The term "markup language" encompasses various systems used for annotating documents, with XML and HTML being prominent examples. The distinction between markup and annotation is often blurred, as both serve to enrich textual data, but markup specifically emphasizes structural representation. El término "lenguaje de marcado" abarca diversos sistemas utilizados para anotar documentos, siendo XML y HTML ejemplos destacados. La distinción entre mar

Términos relacionados / Related terms

annotation / anotación · **metadata** / metadatos · **XML** / XML · **SGML** / SGML · **text type** / tipo de texto · **corpus annotation** / anotación de corpus

lenguaje de marcado

Anotación y marcado

Definición

Un sistema para anotar un documento de manera que sea sintácticamente distinguible del texto mismo, permitiendo la inclusión de metadatos e información estructural. Este formato es esencial para enriquecer los datos lingüísticos y puede aplicarse a diversos tipos de textos, facilitando tanto la categorización como la legibilidad mejorada. Los lenguajes de marcado, como XML y HTML, se diferencian de la anotación en que se centran principalmente en la representación estructural de los datos en lugar de la información interpretativa.

Frecuencia (corpus ES)

abs: 17 pmw: 20.94

Evidencia en corpus (ES)

Este etiquetado con metadatos o XML, cuyas siglas en inglés corresponden a Extensible Markup Language, incluye información relevante como el autor, el título, fecha, etc. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

Los lenguajes de marcado permiten la inclusión de información estructural que facilita el análisis lingüístico. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

El etiquetado documental facilita información bibliográfica sobre cada uno de los textos que conforman del corpus. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

mean score

Frequency and statistics

Definition

A quantitative measure representing the average value derived from a set of scores or data points, calculated by summing the individual scores and dividing by the number of scores. This term is often employed in statistical analyses to summarize data distributions, as evidenced by its use in calculating the overall mean score in various linguistic features across different domains. It contrasts with median and mode, which are alternative measures of central tendency that may provide different insights into data distribution.

Frequency (EN corpus)

abs: 77 pmw: 60.61

Corpus evidence (EN)

"Calculate the mean G2 score of all five pairs." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

"With respect to the three hypotheses concerning the distribution of the possessive and the of-possessive, it is obvious that they all involve at least one nominal variable." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"The overall mean score in the full domain Categories Features books films/TV..." (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

Nota terminológica / Terminological note

The term "mean score" is widely used in quantitative research to summarize data, particularly in linguistic studies where it serves as a key indicator of central tendency. Its application is crucial for interpreting statistical results and understanding linguistic patterns. El término "puntuación media" se utiliza ampliamente en la investigación cuantitativa para resumir datos, especialmente en estudios lingüísticos donde sirve como un indicador

Términos relacionados / Related terms

statistical significance / significancia estadística · **absolute frequency** / frecuencia absoluta · **sample size** / tamaño de muestra · **standard deviation** / desviación estándar · **descriptive statistics** / estadísticas descriptivas

puntuación media

Frecuencia y estadística

Definición

Medida cuantitativa que representa el valor promedio de un conjunto de puntuaciones o datos, calculada sumando los valores individuales y dividiendo el resultado entre el número total de observaciones. Se emplea habitualmente en análisis estadísticos para resumir distribuciones de datos, como en el cálculo de puntuaciones medias sobre distintas características lingüísticas en diferentes dominios. Se diferencia de la mediana y la moda, que son medidas alternativas de tendencia central que pueden ofrecer perspectivas distintas sobre la distribución de los datos.

Frecuencia (corpus ES)

abs: 108 pmw: 128.93

mega corpora

Corpus design and compilation

Definition

A type of large-scale corpus characterized by its extensive size and diverse text sources, enabling comprehensive linguistic analysis across various genres. These corpora differ from smaller, traditional corpora by providing a broader representation of language use, which can enhance the reliability of linguistic studies. The methodological advantages of mega corpora include access to vast amounts of data that facilitate the exploration of language patterns and trends.

Frequency (EN corpus)

abs: 45 pmw: 35.42

Corpus evidence (EN)

However, the latter issue is often not such a big problem after all because most openly accessible mega corpora these days provide online interfaces that users can sign up for free of charge. (Weisser, M.)

In order to do so, let's take the BNC as an example and find out where some of the more significant differences may lie, and why using it may represent an advantage over simply working with the smaller earlier corpora that may be much easier to process on our own computer. (Weisser, M.)

This will also help to prepare you for working with them later. (Weisser, M.)

Nota terminológica / Terminological note

The term "mega corpora" reflects a contemporary trend in corpus linguistics towards the use of large datasets for linguistic analysis, emphasizing the importance of scale in research. This term is increasingly relevant as digital resources expand, allowing for more comprehensive studies of language use across different contexts. El término "mega corpora" refleja una tendencia contemporánea en la lingüística de corpus hacia el uso de grandes conjuntos de datos.

Términos relacionados / Related terms

corpus / corpus · **general corpus** / corpus general · **national corpus** / corpus nacional · **corpus compilation** / compilación de corpus · **balanced corpus** / corpus equilibrado · **web corpus** / corpus web

mega corpora

Diseño y compilación de corpus

Definición

Un tipo de corpus de gran escala caracterizado por su tamaño extenso y fuentes textuales diversas, lo que permite un análisis lingüístico integral a través de varios géneros. Estos corpora se diferencian de los corpora más pequeños y tradicionales al ofrecer una representación más amplia del uso del lenguaje, lo que puede mejorar la fiabilidad de los estudios lingüísticos. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 8 pmw: 9.55

metadata

Metadata and formats

Definition

A type of data that provides information about other data, encompassing properties of both the corpus text and its creation process. In corpus linguistics, metadata includes details such as participant characteristics, situational features, and the relationship between primary and raw data, which are essential for evaluating the representativeness and usability of a corpus. The absence of metadata can significantly hinder the ability to conduct meaningful analyses or to ascertain the corpus's representativeness.

Frequency (EN corpus)

abs: 251 pmw: 197.58

Corpus evidence (EN)

Metadata is literally 'data about data'. In corpora, it encompasses properties of all data types, as well as data about the corpus as a whole and its creation process. (source)

Metadata capture properties of the (written) corpus text (text format, encoding, script, structure of annotations, etc.), properties of the original text, that is, the raw data linked to corpus data (audio and video formats, recording equipment, publication details, etc.). (source)

Metadata can be used to limit searches to a particular subsection of the corpus, or can be used for examining variation due to some aspect of the individuals (i.e. gender, education, second-language influence) or the files (i.e. register, time period). (source)

Nota terminológica / Terminological note

The term "metadata" is widely used in various fields, but in corpus linguistics, it specifically refers to the contextual and descriptive information that enhances the understanding of the corpus data. Variations in the detail and type of metadata collected can significantly affect the analytical capabilities and representativeness of the corpus. El término "metadatos" se utiliza ampliamente en diversos campos, pero en la lingüística de corpus se

Términos relacionados / Related terms

corpus / corpus · **annotation** / anotación · **representativeness** / representatividad · **corpus design** / diseño de corpus · **dataset** / conjunto de datos · **frequency** / frecuencia

metadatos

Metadatos y formatos

Definición

Un tipo de dato que proporciona información sobre otros datos, abarcando propiedades tanto del texto del corpus como del proceso de creación del mismo. En la lingüística de corpus, los metadatos incluyen detalles como las características de los participantes, las características situacionales y la relación entre los datos primarios y los datos en bruto, que son esenciales para evaluar la representatividad y la utilidad de un corpus. La ausencia de metadatos puede obstaculizar significativamente la capacidad de realizar análisis significativos o de determinar la representatividad del corpus.

Frecuencia (corpus ES)

abs: 95 pmw: 117.03

Evidencia en corpus (ES)

En general, sin embargo, el acceso a otro tipo de metadatos sociológicos de los hablantes (sexo, edad, formación, etc.) está tan restringido como en los macrocorpus digitales ya mencionados. (fuente)

La inserción de estas etiquetas y un mayor número de datos externos registrados facilitan las búsquedas cruzadas y con una cobertura de más variables. (fuente)

Esto, sin embargo, no es exactamente así: para estar seguros de que tal efecto es despreciable debemos conocer la proporción de casos en los que no coincide dominio geográfico con procedencia del hablante. (fuente)

Definition

A specialized spoken language corpus, this resource comprises approximately 1.7 million words collected from nearly 190 hours of academic speech at the University of Michigan. It aims to capture the nuances of contemporary university discourse, providing empirical data for analyzing grammatical and phraseological patterns distinct from traditional written texts. The corpus serves as a foundational tool for researchers examining the evolution of academic speech within a diverse speaker population, including both native and non-native English speakers.

Frequency (EN corpus)

abs: 30 pmw: 23.61

Corpus evidence (EN)

"In summary, Michigan Corpus of Academic Spoken English (MICASE) is a spoken language corpus of approximately 1.7 million words with duration of nearly 190 hours." (source)

"The MICASE corpus was thus developed for a series of interlocking factors: (a) During that time no database of this kind was publicly available for empirical research and application of academic speech." (source)

"It was expected that once the investigators were able to examine the corpus for recurrent grammatical and phraseological patterns of use, they might find many divergences from those that were described in contemporary grammars and vocabulary books." (source)

Definición

Un corpus de habla especializado que comprende aproximadamente 1.7 millones de palabras recolectadas de casi 190 horas de discurso académico en la Universidad de Michigan. Su objetivo es capturar las particularidades del discurso universitario contemporáneo, proporcionando datos empíricos para analizar patrones gramaticales y fraseológicos distintos de los textos escritos tradicionales. El corpus sirve como una herramienta fundamental para los investigadores que examinan la evolución del habla académica dentro de una población de hablantes diversa, que incluye tanto hablantes nativos como no n

Frecuencia (corpus ES)

—

Nota terminológica / Terminological note

The term MICASE is specifically tied to the study of academic spoken language, providing a unique resource for researchers interested in the dynamics of university discourse. Its design and compilation reflect a methodological approach that prioritizes the authenticity and diversity of academic speech patterns. El término MICASE está vinculado específicamente al estudio del lenguaje hablado académico, proporcionando un recurso único para investig

Términos relacionados / Related terms

speech corpus / corpus oral · speech corpus / corpus oral · corpus design / diseño de corpus · annotation / anotación · corpus compilation / compilación de corpus

monitor corpus

Corpus design and compilation

Definition

A specialized corpus that continuously grows over time, incorporating a wide variety of texts to reflect ongoing linguistic changes. Its primary function is to monitor language evolution by capturing new word usages and variations, thus serving as a dynamic resource for lexicographical studies. This contrasts with static corpora, which do not adapt to the changing linguistic landscape.

Frequency (EN corpus)

abs: 50 pmw: 39.36

Corpus evidence (EN)

"A monitor corpus is a 'representative corpus' in the sense that it grows continuously with time to include infinite numbers and varieties of text samples from all possible sources of written and spoken the language to represent the language in its truest possible sense." (2018_Sekhar Dash, N., Arulmozi, S.)

"The primary purpose of a monitor corpus is to refer to the texts that are spoken or written in a language over a long time span." (2018_Sekhar Dash, N., Arulmozi, S.)

"Due to this quality, a monitor corpus has high functional relevance in lexicography since it captures the course of change of word use as well as constantly refurbishing new sets of data in order to trace the novel changes that are creeping into the language." (2018_Sekhar Dash, N., Arulmozi, S.)

Nota terminológica / Terminological note

The term "monitor corpus" denotes a dynamic and evolving resource in corpus linguistics, emphasizing its role in tracking language change over time. Its definition and application may vary among scholars, particularly in relation to its contrast with static corpora and diachronic studies. El término "corpus monitor" denota un recurso dinámico y en evolución en la lingüística de corpus, enfatizando su papel en el seguimiento del cambio lingüístico

Términos relacionados / Related terms

corpus / corpus · **corpus design** / diseño de corpus · **reference corpus** / corpus de referencia · **general corpus** / corpus general · **diachronic corpus** / corpus diacrónico · **corpus compilation** / compilación de corpus

corpus monitor

Diseño y compilación de corpus

Definición

Un corpus especializado que crece continuamente a lo largo del tiempo, incorporando una amplia variedad de textos para reflejar los cambios lingüísticos en curso. Su función principal es monitorizar la evolución del lenguaje al capturar nuevos usos de palabras y variaciones, sirviendo así como un recurso dinámico para estudios lexicográficos. Esto contrasta con los corpus estáticos, que no se adaptan al paisaje lingüístico cambiante.

Frecuencia (corpus ES)

abs: 11 pmw: 13.55

Evidencia en corpus (ES)

"Los corpus monitor buscan mostrar un estado actual de la lengua, de manera que contienen textos recientes, por decir algo, pertenecientes a los últimos 25 años." (2015_Sierra Martínez, G. E.)

"El corpus contiene un volumen textual o periodo de tiempo constantes, por lo que su contenido se actualiza con frecuencia." (2015_Sierra Martínez, G. E.)

"Esta acción ofrece la posibilidad de tener un corpus dinámico, en los que se van incluyendo nuevos materiales al mismo tiempo que se eliminan los más antiguos." (2015_Sierra Martínez, G. E.)

monolingual corpus

Corpus design and compilation

Definition

A collection of texts that belong to a single language, often designed to represent a specific variety or genre. Such corpora are utilized in linguistic studies to analyze language use within a defined context, contrasting with multilingual corpora that encompass multiple languages. The methodological focus on a single language allows for in-depth analysis of linguistic features and patterns.

Frequency (EN corpus)

abs: 37 pmw: 29.12

Corpus evidence (EN)

Typically, reference corpora target a single language, often a standard and/or official language of a nation-state (German, Turkish, Russian, etc.). Such corpora are thus monolingual. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Monolingual versus multilingual corpora. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

corpus monolingüe

Diseño y compilación de corpus

Definición

Colección de textos que pertenecen a una única lengua, diseñada para representar una variedad o género específico. Estos corpus se utilizan en estudios lingüísticos para analizar el uso del lenguaje dentro de un contexto definido, en contraste con los corpus multilingües que abarcan múltiples lenguas. El enfoque metodológico en una sola lengua permite un análisis profundo de las características y patrones lingüísticos.

Frecuencia (corpus ES)

abs: 6 pmw: 7.39

Evidencia en corpus (ES)

Corpus constituido por textos pertenecientes a una única lengua. (2021_Rojo, G._Introducción a la lingüística de corpus en español)

Se diferencia habitualmente entre los corpus paralelos, que contienen textos que son traducciones unos de otros, y los corpus comparables, que contienen textos diferentes, pero pertenecientes al mismo tipo. (2021_Rojo, G._Introducción a la lingüística de corpus en español)

Corpus constituido por textos pertenecientes a un solo período de una lengua. (2021_Rojo, G._Introducción a la lingüística de corpus en español)

Nota terminológica / Terminological note

The term "monolingual corpus" is widely accepted in corpus linguistics, emphasizing the focus on a single language for analysis. However, its application may vary depending on the specific linguistic context or research objectives. El término "corpus monolingüe" es ampliamente aceptado en la lingüística de corpus, enfatizando el enfoque en una sola lengua para el análisis. Sin embargo, su aplicación puede variar según el contexto lingüístico esp

Términos relacionados / Related terms

multilingual corpus / corpus multilingüe · **parallel corpus** / corpus paralelo · **reference corpus** / corpus de referencia · **sample** / muestra · **general corpus** / corpus general

morphological annotation

Annotation and markup

Definition

A specific type of linguistic annotation that captures the morphological features of tokens within a corpus, including aspects such as number, gender, and tense. This annotation is essential for enabling systematic analysis of linguistic data across different layers of information. Morphological annotation is often part of a broader annotation scheme that may include syntactic and semantic layers, distinguishing it from simpler forms of annotation like tokenization.

Frequency (EN corpus)

abs: 7 pmw: 5.51

Corpus evidence (EN)

The different layers of annotation for each token are displayed across multiple tabular-separated columns. (2016_Poesio et al.)

Typical morphosyntactic annotations are part-of-speech tagging (PoS tagging) which captures the word class and other morphological and syntactic properties of token wordforms in a corpus. (2023_Barth, D., Schnell, S.)

It is also on this level that clause boundaries are inserted that mark the beginning of clauses, represented by '##' or '#', depending on the type of clause. (2023_Barth, D., Schnell, S.)

Nota terminológica / Terminological note

Morphological annotation is crucial in corpus linguistics for analyzing the grammatical properties of words, facilitating deeper linguistic insights. Its integration with other annotation types enhances the richness of linguistic data, allowing for comprehensive analyses across various linguistic dimensions. La anotación morfológica es fundamental en la lingüística de corpus para analizar las propiedades gramaticales de las palabras, facilitando

Términos relacionados / Related terms

annotation / anotación · **part-of-speech tagging** / etiquetado morfosintáctico · **syntactic annotation** / anotación sintáctica · **annotated corpus** / corpus anotado · **treebank** / treebank

anotación morfológica

Anotación y marcado

Definición

La anotación morfológica es un tipo de anotación lingüística que se centra en capturar las características morfológicas de los tokens dentro de un corpus, como el número, el género y el tiempo verbal. Este tipo de anotación es fundamental para permitir un análisis sistemático de los datos lingüísticos a través de diferentes capas de información. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 6 pmw: 7.16

multilingual corpus

Corpus design and compilation

Definition

A collection of texts in multiple languages, typically designed for comparative linguistic analysis or translation studies. This type of corpus may include parallel texts, where original and translated versions are aligned, or comparable texts that share similar topics or genres but are not direct translations. The methodological significance of multilingual corpora is highlighted in their role in enhancing cross-linguistic research and developing language processing tools.

Frequency (EN corpus)

abs: 72 pmw: 56.68

Corpus evidence (EN)

"In order to achieve this objective, the corpus has to meet certain requirements regarding quality of texts and translations, size and representativeness and accuracy of the alignment." (2017_Doval, I.)

"Such texts are so well contracted that the content and structure of both the languages are almost identical." (2018_Sekhar Dash, N.)

"The utilization of parallel corpora has been clearly observed in numerous ways in the domains of multilingual lexicography, multilingual terminology databanks, machine and human translations, cross-language information retrieval, language learning and so on." (2018_Sekhar Dash, N.)

Nota terminológica / Terminological note

The term "multilingual corpus" encompasses a variety of corpus types, including parallel and comparable corpora, which serve different research purposes. While the definitions and applications may vary, the overarching goal remains the facilitation of cross-linguistic analysis and the enhancement of translation studies. El término "corpus multilingüe" abarca una variedad de tipos de corpus, incluidos los corpus paralelos y comparables, que sirven

Términos relacionados / Related terms

[parallel corpus](#) / corpus paralelo · [comparable corpus](#) / corpus comparable · [corpus compilation](#) / compilación de corpus · [parallel corpus](#) / corpus paralelo · [corpus design](#) / diseño de corpus · [corpus annotation](#) / anotación de corpus

corpus multilingüe

Diseño y compilación de corpus

Definición

Conjunto de textos que pertenecen a varias lenguas, diseñado generalmente para el análisis lingüístico comparativo o los estudios de traducción. Este tipo de corpus puede incluir textos paralelos, donde se alinean versiones originales y traducidas, o textos comparables que comparten temas o géneros similares pero no son traducciones directas. La importancia metodológica de los corpus multilingües radica en su capacidad para mejorar la investigación en lingüística contrastiva y en el desarrollo de herramientas de procesamiento del lenguaje.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Evidencia en corpus (ES)

"En este sentido, resaltamos dos iniciativas multilingües europeas en las que convergieron la investigación de corpus y traducción." (2022_Martí, M. A.)

"La confluencia de ambas áreas, los estudios descriptivos sobre traducción y la lingüística de corpus ha dado lugar a los Estudios de la Traducción basados en Corpus." (2022_Martí, M. A.)

"Corpus constituido por textos pertenecientes a varias lenguas." (2021_Rojo, G.)

multimodal corpus

Corpus design and compilation

Definition

A specialized collection that integrates various modes of human communication, including spoken and written texts, gestures, and visual elements. This type of corpus is designed to provide a comprehensive representation of communication by aligning transcripts with audio or video recordings, thus addressing the limitations of traditional text and speech corpora. The methodological focus on multimodal interaction allows for in-depth analysis of the interplay between verbal and non-verbal communication features.

Frequency (EN corpus)

abs: 61 pmw: 48.02

Corpus evidence (EN)

A recent offshoot in the field of corpus typology is a multimodal corpus, which records and annotates several modalities of human communication and aims to include spoken texts, written texts, gestures, hand movements, facial expressions, body postures and so on. (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

By its simple definition, a multimodal corpus is "an annotated collection of coordinated content on communication channels including speech, gaze, hand gesture and body language, and is generally based on recorded human behavior." (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

The combination of textual, audio and video data of various communicative events in multimodal corpus provides "a unique source for the exploration of a range of lexical, prosodic and gestural features of conversation, and for investigations of the ways in which these features interact in real, everyday speech." (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

Nota terminológica / Terminological note

The term "multimodal corpus" is still developing within the field of corpus linguistics, with ongoing discussions about its definition and scope. Its emergence reflects a growing recognition of the need to analyze communication in a more holistic manner, incorporating both verbal and non-verbal elements. El término "corpus multimodal" está en desarrollo dentro del campo de la lingüística de corpus, con discusiones en curso sobre su definición y

Términos relacionados / Related terms

annotated corpus / corpus anotado · **speech corpus** / corpus oral · **corpus design** / diseño de corpus · **metadata** / metadatos · **corpus compilation** / compilación de corpus · **annotation scheme** / esquema de anotación

corpus multimodal

Diseño y compilación de corpus

Definición

Un corpus especializado que integra diferentes modalidades de comunicación humana, incluyendo textos hablados y escritos, gestos y elementos visuales. Este tipo de corpus está diseñado para proporcionar una representación integral de la comunicación al alinear transcripciones con grabaciones de audio o video, abordando así las limitaciones de los corpus de texto y de habla tradicionales. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 27 pmw: 32.23

mutual information

Frequency and statistics

Definition

A statistical measure of co-occurrence that quantifies the degree to which the presence of one word influences the presence of another word. This measure is grounded in information theory and is commonly employed in corpus linguistics to assess collocational strength. It is methodologically significant, as it provides a standard for evaluating the association between lexemes, contrasting with other measures like Fisher's exact test or chi-squared.

Frequency (EN corpus)

abs: 33 pmw: 25.98

Corpus evidence (EN)

MI: mutual information, a statistical measure of co-occurrence that measures the strength of collocations. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

The underlying assumption is that W1 and W2 are independent. $I(W1, W2) = 0$ if and only if W1 and W2 are independent. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Because it is intuitively and methodologically simple, British lexicographers have made pointwise MI a standard association measure. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

The term "mutual information" is widely recognized in corpus linguistics as a standard measure for assessing word associations, particularly in collocation studies. Variations in its application may arise from differing methodological approaches or the specific contexts in which it is employed. El término "información mutua" es ampliamente reconocido en la lingüística de corpus como una medida estándar para evaluar las asociaciones entre palabras

Términos relacionados / Related terms

association measures / medidas de asociación · **collocation** / colocación · **association measures** / medidas de asociación · **chi-squared** / test de chi-cuadrado · **probability** / probabilidad · **keyword analysis** / análisis de palabras clave

información mutua

Frecuencia y estadística

Definición

Una medida estadística de coocurrencia que cuantifica el grado en que la presencia de una palabra influye en la presencia de otra. Este concepto, fundamentado en la teoría de la información, se utiliza frecuentemente en la lingüística de corpus para evaluar la fuerza de las colocaciones. Su importancia metodológica radica en que ofrece un estándar para evaluar la asociación entre lexemas, en contraste con otras medidas como la prueba exacta de Fisher o el chi-cuadrado.

Frecuencia (corpus ES)

abs: 16 pmw: 19.71

Evidencia en corpus (ES)

Esos lemas llevan también la indicación de la clase de palabras a la que pertenecen, de modo que es sencillo seleccionar, por ejemplo, los adjetivos que coaparecen con un determinado sustantivo. (fuente: 2016_Rojo, G._Citius, maius, melius. Del CREA al CORPES XXI)

La información sobre el contenido y el diseño del corpus, al igual que las convenciones de transcripción, les resulta de interés a todos los investigadores. (fuente: 2019_de Benito, C._Los corpus del español desde la perspectiva del usuario lingüista_Scriptum digital)

La aparente incongruencia de estos resultados se aclara al hacer las búsquedas diferenciadas y comprobar que en América son yute, tweed, abotonar, corbata y solapa. (fuente: 2016_Rojo, G._Citius, maius, melius. Del CREA al CORPES XXI)

n-gram

Lexicon and phraseology

Definition

A sequence of n words occurring in a specific order within a text, where n can be any integer greater than one. This term is commonly applied in natural language processing and corpus linguistics to analyze patterns and predict word sequences. Unlike unigrams or bigrams, which refer specifically to one or two words, n-grams encompass a broader range of word combinations, making them useful for various computational tasks.

Frequency (EN corpus)

abs: 37 pmw: 29.12

Corpus evidence (EN)

A bigram refers to two words that occur next to each other and a trigram refers to three words that occur together sequentially. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

The term n-gram can be used for any number, that is, n of words that occur in a sequence. (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

N-grams have a wide range of applications in NLP, the main one being probability models. (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

n-grama

Léxico y fraseología

Definición

Una secuencia de n palabras que ocurren en un orden específico dentro de un texto, donde n puede ser cualquier número entero mayor que uno. Este término se aplica comúnmente en el procesamiento del lenguaje natural y la lingüística de corpus para analizar patrones y predecir secuencias de palabras. A diferencia de los unigrams o bigrams, que se refieren específicamente a una o dos palabras, los n-gramas abarcan un rango más amplio de combinaciones de palabras, lo que los hace útiles para diversas tareas computacionales.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

En su formulación básica, consiste en la lematización y anotación morfosintáctica de las formas del texto para producir los elementos gramaticales correspondientes. (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

La inclusión de estos metadatos en el lugar adecuado permite hacer luego la recuperación selectiva de los casos que interesen. (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

La utilidad de un corpus constituido solo por los textos es bastante escasa, puesto que se reduce a la posibilidad de hacer recuentos y recuperaciones automáticas de las secuencias de caracteres. (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

Nota terminológica / Terminological note

The term "n-gram" is widely used in computational linguistics and has become a fundamental concept for analyzing language patterns. Its application spans various fields, including natural language processing and corpus linguistics, where it serves as a basis for statistical modeling and predictive text analysis. El término "n-grama" se utiliza ampliamente en la lingüística computacional y se ha convertido en un concepto fundamental para analizar

Términos relacionados / Related terms

n-gram / n-grama · **n-gram** / n-grama · **frequency** / frecuencia · **corpus** / corpus · **keyword analysis** / análisis de palabras clave · **collocation** / colocación

named entity recognition

Language processing

Definition

A subtask of information extraction that focuses on identifying and classifying named entities within text into predefined categories such as persons, organizations, and locations. This process is essential for tasks that require understanding the semantic structure of text, as evidenced by its use in the ACE annotation scheme, which emphasizes the importance of named entities for coreference resolution and information extraction.

Frequency (EN corpus)

abs: 3 pmw: 2.36

Corpus evidence (EN)

"The ACE guidelines follow a small number of semantic classes considered particularly relevant for information extraction: persons, organizations, locations, geopolitical entities, weapons, and vehicles." (source)

"The aim of the project was to annotate linguistic coreference using the most literal interpretation of the text at a very high degree of consistency." (source)

"The coreference portion of ONTONOTES captures general anaphoric coreference that covers entities and events not limited to noun phrases, or a limited set of entity types." (source)

Nota terminológica / Terminological note

The term "named entity recognition" is widely used in natural language processing and information extraction, with its methodologies evolving alongside advancements in machine learning and linguistic annotation. Variations in its definition may arise based on the specific application or the types of entities being recognized. El término "reconocimiento de entidades nombradas" se utiliza ampliamente en el procesamiento del lenguaje natural y la ex

Términos relacionados / Related terms

semantic annotation / anotación semántica · **annotation** / anotación · **named entity recognition** / reconocimiento de entidades nombradas · **semantic annotation** / anotación semántica · **tagger** / etiquetador

reconocimiento de entidades nombradas

Procesamiento del lenguaje

Definición

Una tarea del procesamiento del lenguaje natural que se centra en la identificación y clasificación de entidades nombradas en un texto en categorías predefinidas, como personas, organizaciones y ubicaciones. Este proceso es fundamental para tareas que requieren la comprensión de la estructura semántica del texto, como se evidencia en el esquema de anotación ACE, que subraya la importancia de las entidades nombradas para la resolución de correferencias y la extracción de información.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"Este capítulo describe la detección automática de léxico especializado o términos que está sujeta al corpus especializado." (fuente)

"En este sentido, según sea el enfoque, lexicográfico o terminológico, se tendrán unidades léxicas especializadas (ULE, en adelante) o términos, respectivamente." (fuente)

"Las unidades léxicas especializadas han sido estudiadas en el dominio de la lexicografía, específicamente de la lexicografía de especialidad." (fuente)

national corpus

Corpus design and compilation

Definition

A large collection of texts that is systematically compiled to represent a specific language variety or state, typically encompassing both written and spoken forms. National corpora are designed to reflect the linguistic practices of a particular country, often involving collaboration between academic institutions and industry stakeholders. This term is distinct from general corpora, which may not be limited to a specific national context.

Frequency (EN corpus)

abs: 201 pmw: 158.22

Corpus evidence (EN)

"The British National Corpus (BNC) is a large corpus of modern English texts." (2018_Sekhar Dash, N., Arulmozi, S.)

"It is scientifically designed to represent much wider cross-sections of the current British English, reflected both in spoken and written practices of native British speakers." (2018_Sekhar Dash, N., Arulmozi, S.)

"The project was led by the Oxford University Press with the participation of the majority of dictionary publishers of England." (2018_Sekhar Dash, N., Arulmozi, S.)

corpus nacional

Diseño y compilación de corpus

Definición

Colección extensa de textos que se compila de manera sistemática para representar una variedad o estado específico de una lengua, abarcando típicamente tanto formas escritas como habladas. Los corpus nacionales están diseñados para reflejar las prácticas lingüísticas de un país en particular, a menudo mediante la colaboración entre instituciones académicas y actores de la industria. Este término se diferencia de los corpus generales, que pueden no estar limitados a un contexto nacional específico.

Frecuencia (corpus ES)

abs: 19 pmw: 23.41

Evidencia en corpus (ES)

"Los corpus de referencia están formados por cientos o miles de millones de formas." (2015_Sierra Martínez, G. E.)

"Los corpus nacionales están diseñados para reflejar las prácticas lingüísticas de un país en particular." (2021_Rojo, G.)

"El corpus del español es un ejemplo de un corpus nacional que busca representar la lengua en su uso actual." (2018_Bernal Chávez, J. A.)

Nota terminológica / Terminological note

The term "national corpus" is widely used in corpus linguistics to denote collections that are representative of a specific language within a national context. Its usage may vary across different linguistic communities, and the methodologies for compiling such corpora are often subject to debate among researchers. El término "corpus nacional" se utiliza ampliamente en la lingüística de corpus para denotar colecciones que son representativas de u

Términos relacionados / Related terms

corpus / corpus · **general corpus** / corpus general · **reference corpus** / corpus de referencia · **parallel corpus** / corpus paralelo · **monitor corpus** / corpus monitor · **corpus compilation** / compilación de corpus · **spoken corpus** / corpus oral

natural language processing

Related disciplines

Definition

A field within computational linguistics that focuses on the interaction between computers and human language, encompassing various techniques for analyzing and generating natural language. This discipline is essential for tasks such as part-of-speech tagging, which is described as an important preprocessing step in natural language processing applications, highlighting its methodological significance in exploiting corpus data. The term contrasts with traditional linguistic approaches that may not leverage computational methods for language analysis.

Frequency (EN corpus)

abs: 93 pmw: 73.21

Corpus evidence (EN)

"POS tagging for short, is an important and widely used preprocessing step in natural language processing applications, and it is almost indispensable for the exploitation of corpus data."
(2017_Doval, I._POS-tagging a bilingual parallel corpus. *Methods and challenges_Research in Corpus Linguistics*)

"Natural Language Processing (EMNLP 2014), 1532–1543."
(2017_Desagulier, G._Corpus Linguistics and Statistics with R)

procesamiento del lenguaje natural

Disciplinas afines

Definición

Un campo de la lingüística computacional que se centra en la interacción entre computadoras y el lenguaje humano, abarcando diversas técnicas para analizar y generar lenguaje natural. Esta disciplina es fundamental para tareas como la etiquetación de partes del discurso, que se describe como un paso de preprocesamiento importante en las aplicaciones de procesamiento del lenguaje natural, subrayando su relevancia metodológica en la explotación de datos de corpus. El término contrasta con enfoques lingüísticos tradicionales que pueden no aprovechar métodos computacionales para el análisis del le

Frecuencia (corpus ES)

abs: 39 pmw: 48.04

Evidencia en corpus (ES)

"Thanks to the digital revolution, we now have access to samples of real language use for the first time, which means that introspection is no longer the only way to test the adequacy of our theoretical postulates."
(2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"La lingüística de corpus ha ampliado el ámbito de estudio del lenguaje, que actualmente se concibe en el marco más amplio de la comunicación humana y no como una simple álgebra formal." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"El procesamiento del lenguaje natural ha llevado a profundos cambios en la forma en que se lleva a cabo la investigación en los campos de la biología, medicina, neurociencia y lingüística." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

Nota terminológica / Terminological note

The term "natural language processing" encompasses a variety of techniques and applications that are increasingly relevant in the digital age, reflecting a shift from traditional linguistic analysis to computational methods. This evolution highlights the growing importance of technology in understanding and processing human language. El término "procesamiento del lenguaje natural" abarca una variedad de técnicas y aplicaciones que son cada vez más

Términos relacionados / Related terms

computational linguistics / lingüística computacional · **part-of-speech tagging** / etiquetado morfosintáctico · **corpus linguistics** / lingüística de corpus · **annotation** / anotación · **corpus annotation** / anotación de corpus · **tagger** / etiquetador

NLTK

Tools and software

Definition

A software library for Python designed for natural language processing, providing tools for tasks such as tokenization, parsing, and semantic analysis. It enables researchers to perform linguistic data processing and analysis, facilitating the exploration of language corpora. This tool is particularly relevant for those with basic knowledge of computational linguistics, as it allows for the execution of complex tasks with relative ease.

Frequency (EN corpus)

abs: 10 pmw: 7.87

Corpus evidence (EN)

"The availability of speech corpora and the development of tools and systems for the systematic processing and interpretation of speech corpora are gradually opening up many new avenues of speech technology." (source)

"Although it is known that speech is livelier, more varied and more reliable than text in its representation of a natural language, the present limited availability of speech corpora... is a problem for the people working in corpus linguistics." (source)

"Recent works of corpus generation are strikingly tilted to written texts." (source)

NLTK

Herramientas y software

Definición

Una biblioteca de software para Python destinada al procesamiento del lenguaje natural, que ofrece herramientas para tareas como la tokenización, el análisis sintáctico y el análisis semántico. Permite a los investigadores realizar el procesamiento y análisis de datos lingüísticos, facilitando la exploración de corpus de lenguaje. Esta herramienta es especialmente relevante para quienes tienen conocimientos básicos en lingüística computacional, ya que permite ejecutar tareas complejas con relativa facilidad.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

"Los corpus del español gozan de una situación envidiable en lo que se refiere a dicho acceso a los textos." (fuente)

"Las diferencias más fundamentales entre los distintos corpus se refiere a cómo se realiza dicha descarga y al formato en que se ofrecen los textos." (fuente)

"Una forma rápida y cómoda de ver algunos datos de interés consiste en buscar en el CAES casos de artículos masculinos seguidos inmediatamente por sustantivos femeninos." (fuente)

Nota terminológica / Terminological note

The term NLTK is widely recognized in the field of natural language processing and is often associated with educational contexts, where it serves as an introductory tool for computational linguistics. Its applications span various linguistic analyses, making it a versatile resource for researchers. El término NLTK es ampliamente reconocido en el campo del procesamiento del lenguaje natural y a menudo se asocia con contextos educativos, donde sirve

Términos relacionados / Related terms

corpus / corpus · **token** / token · **annotation** / anotación · **natural language processing** / procesamiento del lenguaje natural · **tagger** / etiquetador · **concordance** / concordancia

node word

Lexicon and phraseology

Definition

A lexical item that serves as the central element in a collocational or colligational analysis, distinguished by its relationships with surrounding words. This term is often utilized in methodologies that explore semantic prosody and the contextual meanings derived from collocates, as evidenced in discussions of how collocates can influence the interpretation of the node word. The concept is closely related to the analysis of function words and content words, which can exhibit different collocational behaviors.

Frequency (EN corpus)

abs: 18 pmw: 14.17

Corpus evidence (EN)

into a more or less clearly recognizable semantic class that is difficult to characterize in terms of denotational properties of the node word. (source: 2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Experimenting with the options should allow you to find that BNCweb also lets you list the PoS categories that collocate with the node by selecting 'collocations on POS-tags' next to 'Information'. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

The relationship is undirected, i.e. symmetric. In Sect. 9.3.7, we saw that collocations could be asymmetric. Likewise, the edges of a graph may be asymmetric, i.e. have a direction association with them. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Nota terminológica / Terminological note

The term "node word" is frequently employed in corpus linguistics to denote a central lexical item in collocational studies, often highlighting its semantic and grammatical relationships with other words. Variations in its application may arise depending on the specific analytical framework or methodology adopted by researchers. El término "palabra nodo" se utiliza con frecuencia en la lingüística de corpus para denotar una unidad léxica central

Términos relacionados / Related terms

collocate / colocado · **colligation** / coligación · **semantic prosody** / prosodia semántica · **function word** / palabra funcional · **content words** / palabras de contenido · **keyword** / palabra clave

palabra nodo

Léxico y fraseología

Definición

Una unidad léxica que actúa como el elemento central en un análisis de colocaciones o coligaciones, caracterizada por sus relaciones con las palabras circundantes. Este término se utiliza frecuentemente en metodologías que exploran la prosodia semántica y los significados contextuales derivados de los coligados, como se evidencia en las discusiones sobre cómo los coligados pueden influir en la interpretación de la palabra nodo. El concepto está estrechamente relacionado con el análisis de palabras funcionales y palabras de contenido, que pueden exhibir comportamientos coligacionales diferentes

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

La lematización de un corpus consiste en la asignación a cada palabra de su correspondiente forma de diccionario, para poder recuperar con una simple búsqueda todas las formas de un paradigma... (fuente: 2019_de Benito, C._Los corpus del español desde la perspectiva del usuario lingüista_Scriptum digital)

Estos procesos, que, lógicamente, se realizan de forma automática, presentan distintos niveles de complejidad, pero la dificultad siempre reside en el mismo aspecto: en la ambigüedad lingüística. (fuente: 2019_de Benito, C._Los corpus del español desde la perspectiva del usuario lingüista_Scriptum digital)

Normalmente suelen ser 20 palabras. Cada texto o documento, finalmente, contiene varios topics según los topics de las palabras que lo forman. (fuente: 2022_Navarro Colorado, B._Sistemas de anotación semántica para corpus de español)

normalized frequency

Frequency and statistics

Definition

A statistical measure that expresses the occurrence of a linguistic unit relative to a standard size of text, typically per 10,000 words. This allows for fair comparisons across corpora of different sizes, as it mitigates the impact of corpus size on frequency counts. Normalized frequency is essential for assessing the distribution of linguistic units and is often used in conjunction with raw frequency to evaluate significance in corpus analysis.

Frequency (EN corpus)

abs: 10 pmw: 7.87

Corpus evidence (EN)

The frequencies normed to a basis per 10000 words is obtained by dividing the verb count by the number of words in the sample and multiplying the result by 10000. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

The normalized frequencies tell you that the distributions of the linguistic unit across the two samples are similar. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Normalized frequency (per thousand words, log-scaled) ... reflects how likely it is that the index fails to discriminate between token distributions that differ in the upper tail. (source: 2025_Sonnig, L._Advancing our understanding of dispersion measures in corpus research_Corpora)

Nota terminológica / Terminological note

The concept of normalized frequency is crucial in corpus linguistics for ensuring that frequency counts are comparable across different corpora. Its application can vary depending on the specific research context, and it is often used alongside other statistical measures to provide a more nuanced understanding of linguistic data. El concepto de frecuencia normalizada es crucial en la lingüística de corpus para garantizar que los conteos de frecu

Términos relacionados / Related terms

raw frequency / frecuencia bruta · **frequency list** / lista de frecuencias · **corpus design** / diseño de corpus · **statistical significance** / significancia estadística · **keyword analysis** / análisis de palabras clave

frecuencia normalizada

Frecuencia y estadística

Definición

Medida estadística que expresa la ocurrencia de una unidad lingüística en relación con un tamaño estándar de texto, típicamente por cada 10,000 palabras. Esto permite comparaciones justas entre corpora de diferentes tamaños, ya que mitiga el impacto del tamaño del corpus en los conteos de frecuencia. La frecuencia normalizada es esencial para evaluar la distribución de las unidades lingüísticas y se utiliza a menudo junto con la frecuencia bruta para evaluar la significación en el análisis de corpus.

Frecuencia (corpus ES)

abs: 121 pmw: 149.05

Evidencia en corpus (ES)

La frecuencia normalizada de esta palabra está comprendida entre veinte y cuarenta casos por millón (cpm) en casi todas las zonas lingüísticas. (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

El método de normalización de frecuencias es efectivo aún si se toman ejemplos de ambos corpus y se estudian periodos de tiempo considerables. (fuente: 2015_Molina Salinas, C., Sierra Martínez, G. E._Hacia una normalización de la frecuencia de los corpus CREA y CORDE_Signos)

Esta diferencia está marcada por la escasa entidad de las frecuencias normalizadas de ambas construcciones en España frente a la que presenta en otras áreas. (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

NOW Corpus

Reference corpora

Definition

A collection of web-based texts that serves as a large-scale resource for linguistic analysis, characterized by its extensive size and the diversity of its content. This corpus is utilized for various research purposes, including the study of language use across different contexts and genres, contrasting with smaller, more specialized corpora. The NOW Corpus exemplifies the methodological shift towards using digital platforms for corpus linguistics, reflecting the growing importance of web corpora in contemporary linguistic research.

Frequency (EN corpus)

abs: 3 pmw: 2.36

Corpus evidence (EN)

In fact, there are currently several corpora with more than 10 billion words, including the NOW (News on the Web) Corpus (www.english-corpora.org/now). (2022_Egbert, J. Biber, D. y Gray, B.)

The NOW Corpus exemplifies the methodological shift towards using digital platforms for corpus linguistics. (2022_Egbert, J. Biber, D. y Gray, B.)

The primary focus of this book applies to all of these conceptualizations: to what extent does the sample of language in the corpus represent the targeted real-world domain of language use? (2022_Egbert, J. Biber, D. y Gray, B.)

Nota terminológica / Terminological note

The NOW Corpus represents a significant advancement in corpus linguistics, particularly in the context of digital resources. Its extensive size and diverse content allow for a comprehensive analysis of language use, contrasting with more traditional, smaller corpora. El Corpus NOW representa un avance significativo en la lingüística de corpus, especialmente en el contexto de los recursos digitales. Su tamaño extenso y contenido diverso permiten

Términos relacionados / Related terms

corpus / corpus · **web corpus** / corpus web · **reference corpus** / corpus de referencia · **general corpus** / corpus general · **corpus compilation** / compilación de corpus · **BNC** / BNC · **corpus design** / diseño de corpus

NOW Corpus

Corpus de referencia

Definición

Una colección de textos basados en la web que sirve como un recurso a gran escala para el análisis lingüístico, caracterizada por su tamaño extenso y la diversidad de su contenido. Este corpus se utiliza para diversos propósitos de investigación, incluyendo el estudio del uso del lenguaje en diferentes contextos y géneros, en contraste con corpus más pequeños y especializados. El Corpus NOW ejemplifica el cambio metodológico hacia el uso de plataformas digitales en la lingüística de corpus, reflejando la creciente importancia de los corpus web en la investigación lingüística contemporánea.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

El corpus NOW incluye textos escritos publicados en línea y representa el subcorpus de español de las Américas del corpus EsTenTen. (2022_Gironzetti, E.)

Este corpus se utiliza para diversos propósitos de investigación, incluyendo el estudio del uso del lenguaje en diferentes contextos y géneros. (2022_Gironzetti, E.)

El Corpus NOW ejemplifica el cambio metodológico hacia el uso de plataformas digitales en la lingüística de corpus. (2022_Gironzetti, E.)

occurrence

Frequency and statistics

Definition

A measurable event that signifies the presence of a specific item within a given text or corpus. This term is often utilized in statistical analyses to quantify how frequently an item appears relative to the total number of tokens, thereby providing insights into its significance within the text. The concept is essential for understanding dispersion measures and frequency distributions in corpus linguistics.

Frequency (EN corpus)

abs: 308 pmw: 242.45

Corpus evidence (EN)

"*R_i will denote the occurrence rate of an item in text i.*" (2025_Sonnig, L._Advancing our understanding of dispersion measures in corpus research_Corpora)

"*The frequency of occurrence inside this framework differs most significantly from their frequency of occurrence outside of this framework.*" (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"*The occurrence of v. demonstrates that parts of the general subcorpus contain references to legal matters.*" (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term "occurrence" is widely used in corpus linguistics to denote the presence of items in texts, and its definition is generally stable across different contexts. However, variations may arise in its application depending on the specific statistical methods employed in frequency analysis. El término "ocurrencia" se utiliza ampliamente en la lingüística de corpus para denotar la presencia de ítems en los textos, y su definición es generalment

Términos relacionados / Related terms

frequency / frecuencia · **token** / token · **dispersion** / dispersión · **corpus** / corpus · **normalized frequency** / frecuencia normalizada

ocurrencia

Frecuencia y estadística

Definición

Un evento medible que indica la presencia de un ítem específico dentro de un texto o corpus determinado. Este término se utiliza frecuentemente en análisis estadísticos para cuantificar la frecuencia con la que un ítem aparece en relación con el número total de tokens, proporcionando así información sobre su relevancia dentro del texto. Es fundamental para comprender las medidas de dispersión y las distribuciones de frecuencia en la lingüística de corpus.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"*El algoritmo de desambiguación calcula la probabilidad de cuál es la etiqueta más probable para circular en función de las dos categorías precedentes.*" (2022_Moreno Sandoval, A._Etiquetadores morfosintácticos para corpus en español)

"*Cada aparición de una palabra en el corpus (token) tiene asignado un topic.*" (2022_Navarro Colorado, B._Sistemas de anotación semántica para corpus de español)

"*La idea intuitiva sobre la que se sustenta topic modeling es que si dos o más palabras tienden a aparecer en los mismos contextos posiblemente sea porque hacen referencia al mismo tema.*" (2022_Navarro Colorado, B._Sistemas de anotación semántica para corpus de español)

parallel corpus

Corpus design and compilation

Definition

Collections of texts in one language aligned with their translations in another language characterize this type of corpus. They are utilized extensively in contrastive linguistics and translation studies, often requiring expert translations to ensure quality. The term is sometimes ambiguously used, as it can also refer to comparable original texts, but it is distinct in its focus on aligned bitexts.

Frequency (EN corpus)

abs: 328 pmw: 258.19

Corpus evidence (EN)

"Parallel corpora contain source texts in a given language, aligned with their translations in another language." (2020_Lefer, M. A._Parallel corpora)

"The term 'parallel corpus' has now been established to refer to collections of bitexts, consisting of original texts in one language, together with their translations into another language." (2017_Doval, I._POS-tagging a bilingual parallel corpus. Methods and challenges_Research in Corpus Linguistics)

"Such texts are so well contracted that the content and structure of both the languages are almost identical." (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

corpus paralelo

Diseño y compilación de corpus

Definición

Conjuntos de textos originales en una lengua, alineados con sus traducciones en otra lengua, definen este tipo de corpus. Se utilizan ampliamente en la lingüística contrastiva y en estudios de traducción, y suelen requerir traducciones realizadas por expertos para garantizar la calidad. Aunque el término puede usarse de manera ambigua, se distingue por su enfoque en los textos alineados.

Frecuencia (corpus ES)

abs: 130 pmw: 160.14

Evidencia en corpus (ES)

"A parallel corpus is formed by original texts in one language A and their corresponding translations into language B." (2016_Molés-Cases, T._Compilación y análisis de un corpus paralelo para la investigación en traducción)

"Los corpus paralelos o comparables utilizados en los estudios de traducción son de características muy específicas." (2016_Molés-Cases, T._Compilación y análisis de un corpus paralelo para la investigación en traducción)

"Un corpus paralelo está formado por textos originales en una lengua A y sus correspondientes traducciones a una lengua B." (2016_Molés-Cases, T._Compilación y análisis de un corpus paralelo para la investigación en traducción)

Nota terminológica / Terminological note

The term "parallel corpus" has gained prominence in recent years, particularly in the fields of translation studies and natural language processing, reflecting its methodological significance. Its usage may vary, as it can sometimes overlap with comparable corpora, but it is primarily defined by the alignment of source texts and their translations. El término "corpus paralelo" ha cobrado relevancia en los últimos años, especialmente en los campos

Términos relacionados / Related terms

comparable corpus / corpus comparable · **corpus annotation** / anotación de corpus · **parallel corpus** / corpus paralelo · **multilingual corpus** / corpus multilingüe · **corpus compilation** / compilación de corpus · **POS tagging** / etiquetado morfosintáctico · **natural language processing** / procesamiento del lenguaje natural

parsing

Language processing

Definition

The process of syntactic analysis involves the application of algorithms to determine the grammatical structure of sentences, resulting in parse trees that represent the syntactic relationships among words. This methodology can be executed through both manual and automated means, with the latter increasingly relying on statistical approaches to enhance accuracy. Parsing is essential for extracting syntactic information from corpora, which is necessary for advanced linguistic analysis and applications.

Frequency (EN corpus)

abs: 54 pmw: 42.51

Corpus evidence (EN)

The annotation of corpora for syntactic analyses with parse trees followed part-of-speech tagging. (source: 2017_Gries, S. T., Berez, A. L.)

The results of such analyses come in the form of either phrase-structure representations – the most frequent parse type – or dependency-tree representations. (source: 2017_Gries, S. T., Berez, A. L.)

Some parsed corpora are provided in yet different formats. (source: 2017_Gries, S. T., Berez, A. L.)

Nota terminológica / Terminological note

The term "parsing" encompasses various methodologies, including both manual and automated approaches, with a growing emphasis on statistical techniques in contemporary linguistic research. This evolution reflects the increasing complexity of linguistic data and the need for precise syntactic analysis in corpus linguistics. El término "análisis sintáctico" abarca diversas metodologías, incluyendo enfoques manuales y automáticos, con un énfasis cre

Términos relacionados / Related terms

POS tagging / etiquetado morfosintáctico · **treebank** / treebank · **annotation** / anotación · **dependency parsing** / análisis de dependencias · **corpus annotation** / anotación de corpus · **parsing** / análisis sintáctico

análisis sintáctico

Procesamiento del lenguaje

Definición

El análisis sintáctico consiste en la aplicación de algoritmos para determinar la estructura gramatical de las oraciones, generando árboles de análisis que representan las relaciones sintácticas entre las palabras. Este proceso puede llevarse a cabo mediante métodos manuales o automáticos, siendo estos últimos cada vez más dependientes de enfoques estadísticos para mejorar la precisión. El análisis sintáctico es fundamental para extraer información sintáctica de los corpus, lo cual es necesario para análisis lingüísticos avanzados y aplicaciones.

Frecuencia (corpus ES)

abs: 23 pmw: 28.33

Evidencia en corpus (ES)

Estos procesos, que, lógicamente, se realizan de forma automática, presentan distintos niveles de complejidad, pero la dificultad siempre reside en el mismo aspecto: en la ambigüedad lingüística. (fuente: 2019_de Benito, C.)

En el etiquetado sintáctico deben resolverse ambigüedades sintácticas. (fuente: 2019_de Benito, C.)

Para poder utilizar elementos abstractos en las búsquedas es preciso que esa información haya sido añadida mediante un proceso de anotación morfosintáctica y lematización. (fuente: 2024_Rojo, G.)

part-of-speech tagging

Annotation and markup

Definition

A process within corpus linguistics that involves assigning a part-of-speech label to each token in a text based on its form and context. This method consists of two main steps: tag assignment, where possible tags are assigned, and tag disambiguation, which reduces the tags to the correct one for the specific context. The complexity of this task arises from the inherent ambiguity of word forms, making it challenging even for human annotators without complete syntactic analysis.

Frequency (EN corpus)

abs: 89 pmw: 70.06

Corpus evidence (EN)

"This kind of linguistic technology makes it possible to enrich data with information that facilitates extracting and analysing specific word forms or constructions..." (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"POS tagging is the process of assigning a part-of-speech label to each token in an input text based on both its form and its context." (source: 2017_Doval, I._POS-tagging a bilingual parallel corpus. Methods and challenges_Research in Corpus Linguistics)

"Tagging therefore consists of two steps: (a) tag assignment: each token is assigned the corresponding set of possible tags for a particular tagset; and (b) tag disambiguation..." (source: 2017_Doval, I._POS-tagging a bilingual parallel corpus. Methods and challenges_Research in Corpus Linguistics)

Nota terminológica / Terminological note

The term "part-of-speech tagging" is widely recognized in corpus linguistics as a fundamental technique for analyzing text data, with various methodologies employed to enhance accuracy. The complexity of the task often leads to discussions about the limitations of different tagging systems and their reliance on statistical methods versus rule-based approaches. El término "etiquetado morfosintáctico" es ampliamente reconocido en la lingüística de

Términos relacionados / Related terms

annotation / anotación · **token** / token · **tagset** / tagset · **morphological annotation** / anotación morfológica · **corpus annotation** / anotación de corpus · **tagger** / etiquetador

etiquetado morfosintáctico

Anotación y marcado

Definición

Proceso en la lingüística de corpus que consiste en asignar una etiqueta de parte del discurso a cada token en un texto, basándose en su forma y contexto. Este procedimiento incluye dos etapas principales: la asignación de etiquetas, donde se asignan las posibles etiquetas, y la desambiguación de etiquetas, que reduce las etiquetas a la correcta para el contexto específico. La ambigüedad inherente de las formas de palabras complica esta tarea, dificultando su realización incluso para los anotadores humanos sin un análisis sintáctico completo.

Frecuencia (corpus ES)

abs: 8 pmw: 9.85

Evidencia en corpus (ES)

"En este capítulo se presentarán de forma panorámica algunos de los principales sistemas de análisis semántico computacional..." (fuente: 2022_Moreno Sandoval, A._Etiquetadores morfosintácticos para corpus en español)

"La anotación morfosintáctica del corpus C-ORAL-ROM: metodología, herramientas y evaluación." (fuente: 2022_Moreno Sandoval, A._Etiquetadores morfosintácticos para corpus en español)

"La combinación de estrategias léxicas y estadísticas para el reconocimiento automático de términos: su aplicación a un corpus de medicina." (fuente: 2022_Moreno Sandoval, A._Etiquetadores morfosintácticos para corpus en español)

parts of speech

Annotation and markup

Definition

A grammatical category that classifies words based on their function within a sentence, such as nouns, verbs, adjectives, and adverbs. This classification is essential for understanding syntactic structures and is often utilized in corpus linguistics for tasks like part-of-speech tagging. The term is methodologically significant as it aids in the analysis of linguistic data and the identification of patterns in language use.

Frequency (EN corpus)

abs: 269 pmw: 211.75

Corpus evidence (EN)

"Colligation is the co-occurrence of specific parts of speech (verbs, nouns, adjectives, etc.) with each other..." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"As we've seen before, this makes a lot of sense because it not only allows us to distinguish features on different linguistic levels more easily..." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"Understanding manual gestures (as opposed to bodily gestures or facial gestures such as eyebrow-raising, which have received less attention) is a large area of study." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Nota terminológica / Terminological note

The term "parts of speech" is widely used in linguistic studies to categorize words based on their grammatical function, which is crucial for syntactic analysis and corpus linguistics. Variations in its application may arise from different linguistic traditions or frameworks, but its core function remains consistent across disciplines. El término "categorías gramaticales" se utiliza ampliamente en los estudios lingüísticos para clasificar las pal

Términos relacionados / Related terms

POS tagging / etiquetado morfosintáctico · **annotation** / anotación · **grammar** / gramática · **tagset** / tagset · **collocation** / colocación · **concordance** / concordancia

categorías gramaticales

Anotación y marcado

Definición

Categoría gramatical que clasifica las palabras según su función dentro de una oración, como sustantivos, verbos, adjetivos y adverbios. Esta clasificación es fundamental para comprender las estructuras sintácticas y se utiliza frecuentemente en la lingüística de corpus para tareas como el etiquetado de partes del discurso. El término tiene un estatus metodológico significativo, ya que facilita el análisis de datos lingüísticos y la identificación de patrones en el uso del lenguaje.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"El Reconocimiento Automático del Habla –ASR– es un proceso complejo mediante el cual un sistema informático toma como entrada una señal de audio, y presenta como resultado una secuencia de palabras o frases en forma de texto." (2017_Rojas Curieux, T._A propósito de la lingüística de corpus, fundamentos y discrepancias. A manera de introducción)

"Este proceso se divide en cuatro fases principales: pre-procesamiento de la señal, extracción de características, modelado del lenguaje y finalmente una clasificación que permite obtener la secuencia de palabras o frases que más se aproximan a la entrada." (2017_Rojas Curieux, T._A propósito de la lingüística de corpus, fundamentos y discrepancias. A manera de introducción)

"La mejora de la fonación. Módulo de técnicas vocálicas. Trabaja la precisión, el contraste y la creación de modelos vocálicos." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

Penn Treebank

Reference corpora

Definition

A syntactically annotated corpus that serves as a standard for part-of-speech tagging and syntactic parsing in English. It provides a framework for analyzing the grammatical structure of sentences, facilitating various linguistic studies and applications in computational linguistics. The methodology established by the Penn Treebank has influenced the development of other tagging systems and treebanks across different languages.

Frequency (EN corpus)

abs: 43 pmw: 33.85

Corpus evidence (EN)

The Penn treebank: An overview. In A. Abeillé (Ed.). Treebanks. Text, speech and language technology. Springer. (source)

Some parsed corpora are provided in yet different formats. An example is the NEGRA Corpus, a parsed corpus of German newspaper texts (355K words, 20.6K sentences), which are available both in the Penn Treebank format and in an export format. (source)

The Penn Treebank annotation is widely used in linguistic research and has become a model for other tagging systems. (source)

Nota terminológica / Terminological note

The term "Penn Treebank" is widely recognized in the field of corpus linguistics, particularly for its role in syntactic annotation and part-of-speech tagging. Its methodologies have been adopted and adapted in various linguistic studies, making it a cornerstone in the development of treebanks for multiple languages. El término "Penn Treebank" es ampliamente reconocido en el campo de la lingüística de corpus, especialmente por su papel en la anotación.

Términos relacionados / Related terms

tagset / tagset · **syntactic annotation** / anotación sintáctica · **annotated corpus** / corpus anotado · **dependency parsing** / análisis de dependencias · **corpus design** / diseño de corpus · **grammar** / gramática

Penn Treebank

Corpus de referencia

Definición

Un corpus anotado sintácticamente que sirve como estándar para el etiquetado de partes del discurso y el análisis sintáctico en inglés. Proporciona un marco para analizar la estructura gramatical de las oraciones, facilitando diversos estudios lingüísticos y aplicaciones en lingüística computacional. La metodología establecida por el Penn Treebank ha influido en el desarrollo de otros sistemas de etiquetado y treebanks en diferentes lenguas.

Frecuencia (corpus ES)

abs: 6 pmw: 7.39

Evidencia en corpus (ES)

El etiquetador del inglés usado en el Penn TreeBank se convirtió en un modelo para otros etiquetarios. (fuente)

La clave está en obtener un equilibrio entre el nivel de detalle y la nitidez de la distinción entre categorías, como se observa en el etiquetador del Penn Treebank. (fuente)

La metodología establecida por el Penn Treebank ha influido en el desarrollo de otros sistemas de etiquetado y treebanks en diferentes lenguas. (fuente)

Perl

Tools and software

Definition

A programming language designed for text processing and manipulation, characterized by its capability to handle complex data structures and regular expressions. It is often utilized in the development of scripts for corpus analysis and linguistic data processing, demonstrating a methodological relevance in computational linguistics. Perl contrasts with other programming languages like Python, which may offer different libraries or frameworks for similar tasks.

Frequency (EN corpus)

abs: 70 pmw: 55.10

Perl

Herramientas y software

Definición

Un lenguaje de programación orientado al procesamiento y manipulación de texto, que se distingue por su capacidad para manejar estructuras de datos complejas y expresiones regulares. Se utiliza frecuentemente en el desarrollo de scripts para el análisis de corpus y el procesamiento de datos lingüísticos, mostrando una relevancia metodológica en la lingüística computacional. Perl contrasta con otros lenguajes de programación como Python, que pueden ofrecer bibliotecas o marcos diferentes para tareas similares.

Frecuencia (corpus ES)

abs: 10 pmw: 12.32

Evidencia en corpus (ES)

"Dicho script está disponible bajo petición. Compilación y análisis de un corpus paralelo para la investigación en traducción." (source)

"Para activar el script y segmentar el documento se tienen que insertar en la línea de comandos las instrucciones que se muestran a continuación." (source)

"Se puede etiquetar bien cada texto de cada lengua individualmente, bien todos los textos de cada lengua de forma conjunta." (source)

Nota terminológica / Terminological note

The term "Perl" is primarily associated with text processing in computational linguistics, reflecting its utility in developing scripts for corpus analysis. Its application may vary depending on the specific linguistic tasks and the integration with other tools or languages. El término "Perl" se asocia principalmente con el procesamiento de texto en la lingüística computacional, reflejando su utilidad en el desarrollo de scripts para el análisis

Términos relacionados / Related terms

corpus / corpus · annotation / anotación · tokenisation / tokenización · concordance / concordancia · tagger / etiquetador · regular expression / expresión regular

phraseology

Lexicon and phraseology

Definition

A branch of linguistics that studies fixed expressions and idiomatic combinations of words, focusing on their meaning and usage within a language. Phraseology emphasizes the importance of context and collocation, as the meaning of a word is often dependent on the company it keeps, contrasting with more traditional lexical studies that may overlook these nuances.

Frequency (EN corpus)

abs: 13 pmw: 10.23

Corpus evidence (EN)

"The availability of speech corpora and the development of tools and systems for the systematic processing and interpretation of speech corpora are gradually opening up many new avenues of speech technology, quantitative linguistics, cognitive linguistics, forensic linguistics, and psycholinguistics." (source)

"In this context, it is necessary to divert attention towards the generation of the corpora in different speech varieties used by the members of speech communities both in artificial and natural settings." (source)

"The process of corpus building is in full swing and the number of corpora is increasing at a high speed across countries and languages." (source)

fraseología

Léxico y fraseología

Definición

Una rama de la lingüística que estudia las expresiones fijas y las combinaciones idiomáticas de palabras, centrándose en su significado y uso dentro de un idioma. La fraseología enfatiza la importancia del contexto y la colocación, ya que el significado de una palabra a menudo depende de la compañía que la rodea, en contraste con estudios léxicos más tradicionales que pueden pasar por alto estas sutilezas.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Evidencia en corpus (ES)

"La explotación básica de los corpus desde sus orígenes como una vía claramente diferenciada de la línea racionalista característica de la orientación chomskyana y también como una reacción frente a los procedimientos y materiales de trabajo utilizados en la lingüística descriptiva tradicional." (fuente)

"Por su carácter empírico y también por basarse en el análisis de datos procedentes de actos lingüísticos efectivamente realizados, la LC se opone fundamentalmente a la lingüística racionalista." (fuente)

"La investigación con los corpus generales no consiste habitualmente en determinar la frecuencia de un cierto elemento léxico o fenómeno gramatical en todo el corpus, sino en establecer las diferencias entre las características que presenta en dos o más tipos diferentes de textos." (fuente)

Nota terminológica / Terminological note

Phraseology is often intertwined with studies of collocation and lexical bundles, reflecting a shift towards empirical approaches in linguistics that prioritize actual language use over theoretical constructs. This term's application can vary across different linguistic frameworks, with some emphasizing its role in understanding idiomatic expressions while others may focus on its implications for grammatical analysis. La fraseología a menudo se e

Términos relacionados / Related terms

collocation / colocación · **lexical bundles** / grupos léxicos · **corpus linguistics** / lingüística de corpus · **grammar** / gramática · **frequency** / frecuencia

plain text

Metadata and formats

Definition

A format characterized by the absence of complex markup or formatting, allowing for straightforward readability and editing in basic text editors. Unlike encoded texts, which may include annotations or structural elements, plain text consists solely of unadorned characters, potentially with line breaks. This simplicity facilitates the processing and analysis of textual data in various computational contexts.

Frequency (EN corpus)

abs: 66 pmw: 51.95

Corpus evidence (EN)

Any document that purely contains text (plus potentially some form of markup, see Chapter 11), is generally referred to as a plain-text document and should be readable (and writable) with any basic text editor. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

There should be clear-cut guidelines for the purpose of clarity of texts so that it becomes helpful to distinguish between plain texts and encoded texts. (source: 2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

All the formats we'll be discussing here are essentially plain text-based, and thus constitute 'human-readable' formats where the text itself contains different types of additional information. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term "plain text" is widely used in computational linguistics and corpus studies to denote a specific format that lacks additional markup, making it essential for various analytical tasks. Its distinction from encoded texts is crucial for understanding data processing methodologies in corpus linguistics. El término "texto plano" se utiliza ampliamente en lingüística computacional y estudios de corpus para denotar un formato específico que ca

Términos relacionados / Related terms

markup language / lenguaje de marcado · **encoding** / codificación · **annotation** / anotación · **metadata** / metadatos · **text type** / tipo de texto

texto plano

Metadatos y formatos

Definición

Un formato que se caracteriza por la ausencia de marcas o formatos complejos, lo que permite una lectura y edición sencilla en editores de texto básicos. A diferencia de los textos codificados, que pueden incluir anotaciones o elementos estructurales, el texto plano consiste únicamente en caracteres desnudos, con posibles saltos de línea. Esta simplicidad facilita el procesamiento y análisis de datos textuales en diversos contextos computacionales.

Frecuencia (corpus ES)

abs: 2 pmw: 2.46

Evidencia en corpus (ES)

La mayor parte de estos datos son textos en lenguaje natural cuya clasificación manual ya no es factible; entonces surge la necesidad de diseñar métodos de clasificación automática. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

Para automatizar la clasificación, se ha desarrollado una amplia gama de técnicas computacionales. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

A pesar de ello, también podemos encontrar algunos problemas en la utilización de la web que tienen que ver con el "ruido" que se genera debido al material no lingüístico. (fuente: 2017_González Fernández, A._La web como corpus. Un esbozo LENGUA Y HABLA)

population

Frequency and statistics

Definition

A collection of all members of a defined group from which a sample may be drawn for analysis. In corpus linguistics, the term emphasizes the need for representativeness in sampling methods, contrasting with random sampling techniques that may not adequately reflect the diversity of the population. Methodologically, it is crucial for ensuring that the corpus can accurately estimate linguistic parameters relevant to the entire population.

Frequency (EN corpus)

abs: 286 pmw: 225.13

Corpus evidence (EN)

'population' indicates that all members of the population are included in the corpus. (source: 2025_Hashimoto, B., Nelson, K.)

A survey of the literature revealed some studies that use a form of the word "estimate" to refer to the relationship between a corpus sample and a target population. (source: 2022_Egbert, J. Biber, D. y Gray, B.)

The tolerable error depends on the precision required of population estimates based on the corpus sample. (source: 2022_Egbert, J. Biber, D. y Gray, B.)

Nota terminológica / Terminological note

The term "population" is foundational in corpus linguistics, as it underpins the methodologies used for sampling and representativeness. Variations in its application can arise from different research contexts, particularly in sociolinguistic studies where the diversity of speech communities must be considered. El término "población" es fundamental en la lingüística de corpus, ya que sustenta las metodologías utilizadas para el muestreo y la rep

Términos relacionados / Related terms

sample / muestra · **representativeness** / representatividad · **frequency** / frecuencia · **corpus design** / diseño de corpus · **sampling frame** / marco de muestreo · **representativeness** / representatividad

población

Frecuencia y estadística

Definición

Conjunto de todos los miembros de un grupo definido del cual se puede extraer una muestra para su análisis. En la lingüística de corpus, el término subraya la necesidad de representatividad en los métodos de muestreo, en contraste con técnicas de muestreo aleatorio que pueden no reflejar adecuadamente la diversidad de la población. Desde una perspectiva metodológica, es fundamental para garantizar que el corpus pueda estimar con precisión los parámetros lingüísticos relevantes para toda la población.

Frecuencia (corpus ES)

abs: 14 pmw: 17.25

Evidencia en corpus (ES)

Cada bloque de (tipos de) textos de un corpus debe contener una cantidad que sea proporcional al peso que ese género representa en la población. (fuente: 2021_Rojo, G.)

La cuestión de la representatividad recibió mucha atención tanto desde el punto de vista teórico como en la práctica en los corpus generales. (fuente: 2022_Rojo, G., Palacios, I.)

La representatividad no implica que la muestra sea una versión en miniatura de la población, sino que permite hacer inferencias sobre ella. (fuente: 2021_Rojo, G.)

POS tagging

Annotation and markup

Definition

A process within corpus linguistics that involves assigning part-of-speech labels to tokens in a text, based on their form and context. This method consists of two main steps: tag assignment, where possible tags are allocated, and tag disambiguation, which reduces the options to the correct label for each token. It is a crucial preprocessing step in natural language processing applications and is essential for effective corpus data exploitation.

Frequency (EN corpus)

abs: 101 pmw: 79.50

Corpus evidence (EN)

"POS tagging is the process of assigning a part-of-speech label to each token in an input text based on both its form and its context." (2017_Doval, I._POS-tagging a bilingual parallel corpus. Methods and challenges_Research in Corpus Linguistics)

"Tagging therefore consists of two steps: (a) tag assignment: each token is assigned the corresponding set of possible tags for a particular tagset; and (b) tag disambiguation." (2017_Doval, I._POS-tagging a bilingual parallel corpus. Methods and challenges_Research in Corpus Linguistics)

"This morpho-syntactic annotation, which is also referred to as Part-of-Speech (or PoS) tagging, makes it possible to enrich data with information that facilitates extracting and analysing specific word forms." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term "POS tagging" is widely recognized in the field of corpus linguistics and natural language processing, often considered a foundational technique for text analysis. Variations in tagging methodologies and tagsets can lead to differences in accuracy and effectiveness, particularly in multilingual contexts. El término "etiquetado morfosintáctico" es ampliamente reconocido en el ámbito de la lingüística de corpus y el procesamiento del lenguaje natural.

Términos relacionados / Related terms

morphological annotation / anotación morfológica · **tagset** / tagset · **token** / token · **corpus annotation** / anotación de corpus · **lemmatisation** / lematización · **natural language processing** / procesamiento del lenguaje natural

etiquetado morfosintáctico

Anotación y marcado

Definición

Proceso que consiste en asignar etiquetas de parte del discurso a los tokens de un texto, basándose en su forma y contexto. Este método incluye dos pasos principales: la asignación de etiquetas, donde se asignan las posibles etiquetas, y la desambiguación de etiquetas, que reduce las opciones a la etiqueta correcta para cada token. Es un paso de preprocesamiento crucial en aplicaciones de procesamiento del lenguaje natural y es esencial para la explotación efectiva de los datos del corpus.

Frecuencia (corpus ES)

abs: 11 pmw: 13.55

Evidencia en corpus (ES)

"El etiquetado morfosintáctico (part-of-speech tagging o POS tagging para abreviar) es un paso de preprocesamiento importante y ampliamente utilizado en aplicaciones de procesamiento del lenguaje natural." (2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

"El etiquetador debe cumplir ciertos requisitos en cuanto a la calidad de los textos y traducciones, así como la precisión de la alineación." (2022_Moreno Sandoval, A._Etiquetadores morfosintácticos para corpus en español)

"El etiquetado morfosintáctico es un proceso que incluye la selección del software etiquetador y la evaluación de los resultados en ambos idiomas." (2022_Moreno Sandoval, A._Etiquetadores morfosintácticos para corpus en español)

probability

Frequency and statistics

Definition

A quantitative measure representing the likelihood of an event occurring, expressed on a continuous scale from 0 to 1, where 0 indicates impossibility and 1 indicates certainty. This concept is essential in statistical analysis and is often used to make judgments about outcomes based on observed frequencies or conditions. The methodological approach to probability can vary, as seen in discussions contrasting frequency interpretation with propensity theory, which emphasizes individual events rather than collective occurrences.

Frequency (EN corpus)

abs: 380 pmw: 299.12

Corpus evidence (EN)

A probability is expressed on a continuous scale from 0 to 1: 0 means that the outcome has no chance to occur, 0.5 that it has one chance out of two to occur, and 1 that it is certain to occur. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

Probability becomes a function of the conditions that give rise to it in individual cases, not of the set that an event may be seen as a member of. (source: 2022_McEnery_ T., Brezina, V._Fundamental Principles of Corpus Linguistics)

Nota terminológica / Terminological note

The term "probability" encompasses various interpretations and applications across different fields, particularly in statistics and linguistics. Its usage can vary significantly depending on the methodological framework adopted, such as frequency-based or propensity-based approaches. El término "probabilidad" abarca diversas interpretaciones y aplicaciones en diferentes campos, especialmente en estadística y lingüística. Su uso puede variar sign

Términos relacionados / Related terms

frequency / frecuencia · **statistical significance** / significancia estadística · **sample** / muestra · **mean score** / puntuación media · **confidence interval** / intervalo de confianza · **inferential statistics** / estadísticas inferenciales

probabilidad

Frecuencia y estadística

Definición

Una medida cuantitativa que representa la probabilidad de que ocurra un evento, expresada en una escala continua de 0 a 1, donde 0 indica imposibilidad y 1 certeza. Este concepto es fundamental en el análisis estadístico y se utiliza para hacer juicios sobre resultados basados en frecuencias observadas o condiciones. La aproximación metodológica a la probabilidad puede variar, como se observa en las discusiones que contrastan la interpretación de frecuencia con la teoría de propensidad, que enfatiza los eventos individuales en lugar de las ocurrencias colectivas.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

The probability of selection of individuals need not be uniform, as long as it is known what these probabilities are. (source: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

La principal diferencia entre ellas es que los nuevos modelos neuronales tienen mayor acierto en el etiquetado categorial y proponen un lema para todas las palabras. (fuente: 2022_Moreno Sandoval, A._Etiquetadores morfosintácticos para corpus en español)

Una formulación bastante más manejable del concepto puede establecerse en términos de proporcionalidad. (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

query

Search and retrieval

Definition

A method for retrieving specific information from a corpus, characterized by the use of syntactic structures that define the parameters of the search. Queries can target tokens or sequences of tokens at various levels of annotation, allowing for precise linguistic analysis. The effectiveness of a query is contingent upon the corpus's annotation scheme and the complexity of the search criteria employed.

Frequency (EN corpus)

abs: 422 pmw: 332.18

Corpus evidence (EN)

The queries are meant to work for the spoken portion of the BNC, which uses the comma for all kinds of things, including hesitation or incomplete phrases... (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Syntax is very powerful, allowing us to query the corpus for tokens or sequences of tokens at any level of annotation. (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

This query syntax is so transparent and widely used that we will treat it as a standard in the remainder of the book... (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "query" is widely used in corpus linguistics to denote the process of searching for specific linguistic patterns or tokens within a corpus. Variations in query syntax and complexity can lead to different retrieval outcomes, emphasizing the importance of understanding the underlying annotation framework. El término "consulta" se utiliza ampliamente en la lingüística de corpus para denotar el proceso de búsqueda de patrones lingüísticos e

Términos relacionados / Related terms

corpus / corpus · **annotation** / anotación · **concordance** / concordancia · **corpus query language** / lenguaje de consulta de corpus · **token** / token · **frequency** / frecuencia

consulta

Búsqueda y consulta

Definición

Método para recuperar información específica de un corpus, caracterizado por el uso de estructuras sintácticas que definen los parámetros de búsqueda. Las consultas pueden dirigirse a tokens o secuencias de tokens en diferentes niveles de anotación, lo que permite un análisis lingüístico preciso. La efectividad de una consulta depende del esquema de anotación del corpus y de la complejidad de los criterios de búsqueda empleados.

Frecuencia (corpus ES)

abs: 15 pmw: 18.48

Evidencia en corpus (ES)

...se han procesado los bitextos para que puedan realizarse consultas lingüísticas en ellos. (2018_Leiva Rojo, J._Diseño y compilación de corpus paralelos alineados. Dificultades y algunas soluciones_Revista de Lingüística y Lenguas Aplicadas)

Para realizar la búsqueda se han empleado las denominadas CQL (Corpus Query Language), un lenguaje de búsqueda de corpus basado en algunos códigos especiales de interrogación. (2021_Piccioni, S., Pontrandolfo, G._WebLesp. Corpus de comunicación digital especializada en español. Arquitectura. Compilación y usos_Revista de lingüística teórica y aplicada)

raw frequency

Frequency and statistics

Definition

A quantitative measure representing the total number of occurrences of a specific item within a corpus, raw frequency does not account for the overall size of the corpus or the relative significance of the occurrences. This term is often contrasted with relative frequency, which provides a proportionate view of occurrences in relation to the total number of items. Methodologically, raw frequency can be misleading if used without consideration of other statistical measures, as it may not accurately reflect the importance of the data in linguistic analysis.

Frequency (EN corpus)

abs: 10 pmw: 7.87

Corpus evidence (EN)

"However, we should be wary of basing our assessment of corpus data directly on raw frequencies in a contingency table." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

"The raw frequency only tells us whether the contribution is larger than that of other types, but not to which extent this is actually significant regarding the data." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"These can be very misleading, especially if the marginal frequencies of the variables differ substantially." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "raw frequency" is widely used in corpus linguistics to denote the absolute count of occurrences, but its utility can be limited without contextualization through relative measures. Scholars often emphasize the importance of considering both raw and relative frequencies to achieve a comprehensive understanding of linguistic data. El término "frecuencia bruta" se utiliza ampliamente en la lingüística de corpus para denotar el conteo absol

Términos relacionados / Related terms

relative frequency / frecuencia relativa · **frequency list** / lista de frecuencias · **token** / token · **corpus** / corpus · **absolute frequency** / frecuencia absoluta · **normalized frequency** / frecuencia normalizada

frecuencia bruta

Frecuencia y estadística

Definición

Una medida cuantitativa que representa el número total de ocurrencias de un ítem específico dentro de un corpus, la frecuencia bruta no toma en cuenta el tamaño total del corpus ni la significación relativa de las ocurrencias. Este término se contrasta a menudo con la frecuencia relativa, que ofrece una visión proporcional de las ocurrencias en relación con el número total de ítems. Metodológicamente, la frecuencia bruta puede resultar engañosa si se utiliza sin considerar otras medidas estadísticas, ya que puede no reflejar con precisión la importancia de los datos en el análisis lingüístico.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"En la evaluación del sistema reportan una rata de error con promedio de 21.2% logrando una mejora del 6.2% sobre el mismo modelo pero basado en MLP." (2017_Rojas Curieux, T._A propósito de la lingüística de corpus, fundamentos y discrepancias. A manera de introducción)

"Sin embargo, esta base de datos presenta algunas limitaciones relacionadas con su diseño, imputables a su gran extensión, selección de géneros textuales y unidad de muestra que afectan su representatividad." (2015_Molina Salinas, C., Sierra Martínez, G. E._Hacia una normalización de la frecuencia de los corpus CREA y CORDE_Signos)

"Es necesario encontrar el equilibrio entre el simple volumen y la riqueza de la codificación en los textos." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

recall

Annotation and markup

Definition

A measure of the effectiveness of a retrieval method, calculated as the number of true positives divided by the sum of true positives and false negatives. This metric indicates the proportion of relevant instances that were successfully identified, highlighting the completeness of the search results. Recall is often contrasted with precision, which focuses on the accuracy of the retrieved items.

Frequency (EN corpus)

abs: 107 pmw: 84.23

Corpus evidence (EN)

Recall is defined as the number of true positives divided by the number of true positives and false negatives (i.e. all items that should have been found). (source)

Ideally, the value of both measures should be 1, i.e., our data should include all cases of the phenomenon under investigation (a recall rate of 100 percent). (source)

If our data do differ along one or more of the dimensions relevant to our research project, we might have to increase the recall at the expense of precision. (source)

Nota terminológica / Terminological note

Recall is a critical metric in corpus linguistics, particularly in the evaluation of data retrieval methods and annotation processes. Its importance lies in ensuring that all relevant instances are captured, which is essential for the validity of linguistic analyses. La recuperación es una métrica crítica en la lingüística de corpus, especialmente en la evaluación de métodos de recuperación de datos y procesos de anotación. Su importancia radica

Términos relacionados / Related terms

accuracy / exactitud · **annotation** / anotación · **corpus annotation** / anotación de corpus · **recall** / exhaustividad · **accuracy** / exactitud · **recall** / exhaustividad

exhaustividad

Anotación y marcado

Definición

Una medida de la efectividad de un método de recuperación, calculada como el número de verdaderos positivos dividido por la suma de verdaderos positivos y falsos negativos. Este indicador refleja la proporción de instancias relevantes que fueron identificadas con éxito, subrayando la exhaustividad de los resultados de búsqueda. La recuperación se contrasta frecuentemente con la precisión, que se centra en la exactitud de los elementos recuperados.

Frecuencia (corpus ES)

abs: 16 pmw: 19.71

Evidencia en corpus (ES)

El principio de la total accountability (exhaustividad, explicabilidad total) se convierte en el rasgo definitorio y característico del trabajo en LC. (fuente)

Este principio consiste en la consideración de que los análisis deben ser exhaustivos en dos sentidos diferentes. (fuente)

En este sentido, el principio de exhaustividad tropieza con las frecuencias que poseen algunos elementos, fenómenos o esquemas en los corpus actuales. (fuente)

reference corpus

Corpus design and compilation

Definition

A type of corpus designed to provide comprehensive information about a language, capturing its total linguistic identity at both diachronic and synchronic levels. The methodological rigor in its compilation is crucial, as it must reflect a representative sample of the language, often incorporating diverse registers and geographical variants. This contrasts with a learner corpus, which focuses specifically on language produced by learners rather than a comprehensive linguistic representation.

Frequency (EN corpus)

abs: 131 pmw: 103.12

Corpus evidence (EN)

a 'reference corpus' should be designed to provide comprehensive information about a language in its total linguistic identity both in a diachronic and synchronic scale; (source)

The present chapter discusses the types of corpus based on the nature of the application of texts with reference to English and Indian languages. (source)

A unified and operational definition of corpus representativeness is needed. (source)

Nota terminológica / Terminological note

The term "reference corpus" is widely accepted in corpus linguistics, yet its definition can vary based on the specific criteria used for compilation and the intended use of the corpus. The emphasis on methodological rigor and representativeness is a common theme in its definition, reflecting the need for a reliable linguistic resource. El término "corpus de referencia" es ampliamente aceptado en la lingüística de corpus, aunque su definición pue

Términos relacionados / Related terms

corpus / corpus · **representativeness** / representatividad · **learner corpus** / corpus de aprendices · **balanced corpus** / corpus equilibrado · **corpus compilation** / compilación de corpus · **metadata** / metadatos

corpus de referencia

Diseño y compilación de corpus

Definición

Un tipo de corpus que se elabora para ofrecer información exhaustiva sobre una lengua, reflejando su identidad lingüística total en niveles diacrónicos y sincrónicos. La rigurosidad metodológica en su compilación es fundamental, ya que debe representar una muestra representativa de la lengua, incorporando a menudo registros diversos y variantes geográficas. Esto contrasta con un corpus de aprendices, que se centra específicamente en el lenguaje producido por los aprendices en lugar de una representación lingüística integral.

Frecuencia (corpus ES)

abs: 194 pmw: 238.98

Evidencia en corpus (ES)

Los corpus de referencia constituyen, por tanto, un modelo aproximado de la realidad de las lenguas y su valor representativo depende, en gran medida, de los criterios metodológicos con los que se ha elaborado. (fuente)

Estos corpus son una muestra de la lengua española escrita y oral que se utilizan como modelo representativo del español estándar. (fuente)

Los corpus CREA y CORPES-XXI corresponden a esta modalidad. (fuente)

regular expression

Language processing

Definition

A method for defining search patterns in text, characterized by the use of specific symbols and syntax to represent various character sequences. Regular expressions are integral to computational linguistics, enabling complex queries for data extraction and analysis in corpus studies. They differ from simple string matching by allowing for more sophisticated pattern recognition, thus enhancing the efficiency of linguistic analysis.

Frequency (EN corpus)

abs: 158 pmw: 124.37

Corpus evidence (EN)

Regular Expressions (or regexes, for short) are an important and very powerful means of specifying such complex search terms for concordances or computer programs for language processing. (source: 2016_Weisser, M._Practical Corpus Linguistics)

Most concordance packages support at least some basic forms of regexes, although they're not necessarily as advanced as the options offered by command-line search utilities. (source: 2016_Weisser, M._Practical Corpus Linguistics)

Regular expressions also allow us to match less obvious things, like every non-digit character \D. (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Nota terminológica / Terminological note

The term "regular expression" is widely used in computational linguistics and corpus studies, often varying in implementation across different programming languages and tools. Its application is critical for enhancing search capabilities and data analysis in linguistic research. El término "expresión regular" se utiliza ampliamente en lingüística computacional y estudios de corpus, variando a menudo en su implementación a través de diferentes le

Términos relacionados / Related terms

query / consulta · **concordance** / concordancia · **tokenisation** / tokenización · **annotation** / anotación · **collocation** / colocación

expresión regular

Procesamiento del lenguaje

Definición

Método para definir patrones de búsqueda en texto, caracterizado por el uso de símbolos y sintaxis específicos que representan diversas secuencias de caracteres. Las expresiones regulares son fundamentales en la lingüística computacional, permitiendo consultas complejas para la extracción y análisis de datos en estudios de corpus. Se diferencian de la simple coincidencia de cadenas al permitir un reconocimiento de patrones más sofisticado, mejorando así la eficiencia del análisis lingüístico.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

Así, el carácter . se refiere a cualquier carácter que ocupe esa posición. (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

Se relacionan con los metacaracteres y los comodines. (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

Los patrones utilizados para generalizar secuencias con ciertas características comunes son fundamentales en el análisis lingüístico. (fuente: 2021_Rojo, G._Introducción a la lingüística de corpus en español)

relative frequency

Frequency and statistics

Definition

A statistical measure that expresses the frequency of a linguistic phenomenon as a proportion of the total number of occurrences within a defined sample or corpus. This calculation is achieved by dividing the absolute frequency of the phenomenon by the total number of cases, allowing for comparisons across different datasets. The methodological significance of relative frequency lies in its ability to normalize data, thereby facilitating more accurate analyses of linguistic patterns.

Frequency (EN corpus)

abs: 29 pmw: 22.83

Corpus evidence (EN)

In order to convert an absolute frequency n into a relative one, we simply divide it by the total number of cases N of which it is a part. (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Thus, it is generally useful to convert the absolute frequencies to relative frequencies, abstracting away from the differences in marginal frequencies. (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

frecuencia relativa

Frecuencia y estadística

Definición

Medida estadística que expresa la frecuencia de un fenómeno lingüístico como una proporción del número total de ocurrencias dentro de una muestra o corpus definido. Este cálculo se realiza dividiendo la frecuencia absoluta del fenómeno por el número total de casos, lo que permite comparaciones entre diferentes conjuntos de datos. La importancia metodológica de la frecuencia relativa radica en su capacidad para normalizar los datos, facilitando así análisis más precisos de los patrones lingüísticos.

Frecuencia (corpus ES)

abs: 27 pmw: 33.26

Evidencia en corpus (ES)

The frequency relative of a linguistic phenomenon (f_i) is obtained by calculating the quotient of the absolute frequency of this fact in the sample (n_i) and the size of this (N). (2015_Molina Salinas, C., Sierra Martínez, G. E._Hacia una normalización de la frecuencia de los corpus CREA y CORDE_Signos)

La frecuencia relativa de un fenómeno lingüístico se obtiene calculando el cociente de la frecuencia absoluta de este hecho en la muestra y el tamaño de esta, procedimiento que permite reasignarle a un número de ocurrencias un valor en relación con el tamaño de la partición o del mismo corpus. (2015_Molina Salinas, C., Sierra Martínez, G. E._Hacia una normalización de la frecuencia de los corpus CREA y CORDE_Signos)

En el análisis de los diccionarios de frecuencias, se puede conseguir normalmente mediante el análisis de los datos procedentes de la totalidad de un corpus o los extraídos de los elementos más frecuentes. (2021_Rojo, G._Introducción a la lingüística de corpus en español)

Nota terminológica / Terminological note

Relative frequency is a foundational concept in corpus linguistics that enables researchers to compare linguistic phenomena across different corpora and contexts. Its application is crucial for ensuring that analyses are not skewed by the size of the datasets involved. La frecuencia relativa es un concepto fundamental en la lingüística de corpus que permite a los investigadores comparar fenómenos lingüísticos entre diferentes corpora y contextos

Términos relacionados / Related terms

absolute frequency / frecuencia absoluta · **frequency** / frecuencia · **corpus** / corpus · **normalized frequency** / frecuencia normalizada · **sample size** / tamaño de muestra

representativeness

Corpus design and compilation

Definition

A sample is considered representative if it accurately reflects the characteristics of the larger population it is drawn from, allowing for valid generalizations about language use. The concept is methodologically significant in corpus linguistics, as it requires precise operational definitions to ensure that the corpus can stand as a proxy for broader linguistic phenomena. Variability in the understanding of representativeness highlights the need for context-specific criteria to evaluate a sample's adequacy.

Frequency (EN corpus)

abs: 555 pmw: 436.87

Corpus evidence (EN)

"By definition, a sample is representative if what we find for the sample also holds for the general population." (source: 2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

"It means that anyone carrying out a principled study on a representative corpus can extrapolate from the corpus to the whole universe of language use." (source: 2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

"There is little doubt that, as the corpus approach to language develops, the concepts of balance and representativeness will undergo further critical scrutiny." (source: 2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

Nota terminológica / Terminological note

The term "representativeness" is often contested in corpus linguistics, with varying definitions and criteria depending on the specific research context. This variability underscores the importance of establishing clear operational definitions to enhance the methodological rigor of corpus studies. El término "representatividad" a menudo es objeto de controversia en la lingüística de corpus, con definiciones y criterios que varían según el context

Términos relacionados / Related terms

sample / muestra · **population** / población · **balanced corpus** / corpus equilibrado · **corpus design** / diseño de corpus · **general corpus** / corpus general · **frequency** / frecuencia · **annotation** / anotación

representatividad

Diseño y compilación de corpus

Definición

Una muestra se considera representativa si refleja con precisión las características de la población más amplia de la que se extrae, permitiendo generalizaciones válidas sobre el uso del lenguaje. Este concepto es metodológicamente significativo en la lingüística de corpus, ya que requiere definiciones operativas precisas para asegurar que el corpus pueda actuar como un proxy de fenómenos lingüísticos más amplios. La variabilidad en la comprensión de la representatividad subraya la necesidad de criterios específicos del contexto para evaluar la adecuación de una muestra.

Frecuencia (corpus ES)

abs: 223 pmw: 274.70

Evidencia en corpus (ES)

"The intention of the representativeness of a corpus is related to its predictive purpose." (source: 2016_Torruella, J._Tres propuestas en el ámbito de la lingüística de corpus)

"La representatividad de los corpus está relacionada con el aspecto cualitativo de las obras que se seleccionan." (fuente: 2016_Torruella, J._Tres propuestas en el ámbito de la lingüística de corpus)

"La representatividad cuantitativa viene determinada por el equilibrio externo, es decir, por la relación numérica entre el número de muestras seleccionadas y el volumen total de la población." (fuente: 2016_Torruella, J._Tres propuestas en el ámbito de la lingüística de corpus)

sample

Frequency and statistics

Definition

A collection of texts that serves as a miniature representation of a larger population, characterized by its proportionality to the elements within that population. A sample is deemed representative when it reflects the same ratios and types of text as the broader linguistic universe it is drawn from, allowing for valid extrapolation of findings. Methodologically, the concept of a sample is crucial for ensuring that studies can generalize results to the entire language or variety being investigated.

Frequency (EN corpus)

abs: 1.127 pmw: 887.13

Corpus evidence (EN)

"In practice, this will be a proportional sample - a corpus that includes the same textual categories occurring in the same relative proportions as in the general domain." (Egbert, Biber, & Gray 2022)

"A representative corpus is one sampled in such a way that it contains all the types of text, in the correct proportions, that are needed to make the contents of the corpus an accurate reflection of the whole of the language or variety that it samples." (Egbert, Biber, & Gray 2022)

"When a corpus is being set up as a sample ... the relationship between the sample and the target population is very important." (Egbert, Biber, & Gray 2022)

Nota terminológica / Terminological note

The term "sample" is often contested in its definition, particularly regarding what constitutes representativeness and how it is operationalized in different studies. Variations in methodological approaches can lead to differing interpretations of what a sample should include, impacting the generalizability of research findings. El término "muestra" a menudo es objeto de controversia en su definición, especialmente en lo que respecta a lo que co

Términos relacionados / Related terms

representativeness / representatividad · **population** / población · **sampling frame** / marco de muestreo · **balanced corpus** / corpus equilibrado · **representativeness** / representatividad · **frequency** / frecuencia · **dataset** / conjunto de datos

muestra

Frecuencia y estadística

Definición

Un conjunto de textos que actúa como una representación en miniatura de una población más amplia, caracterizado por su proporcionalidad a los elementos dentro de esa población. Se considera que una muestra es representativa cuando refleja las mismas proporciones y tipos de texto que el universo lingüístico más amplio del cual se extrae, permitiendo la extrapolación válida de los hallazgos. Metodológicamente, el concepto de muestra es crucial para garantizar que los estudios puedan generalizar resultados a toda la lengua o variedad que se investiga.

Frecuencia (corpus ES)

abs: 440 pmw: 542.02

Evidencia en corpus (ES)

"Se obtuvo un total de 4.224 muestras diferentes, divididas en 132 muestras para cada una de las 32 unidades vocálicas." (Rojas Curieux 2017)

"Con esta muestra se realizó un análisis de su espectro de frecuencias, para identificar el inicio y el fin de la unidad vocálica presente." (Rojas Curieux 2017)

"Una vez que se han determinado los parámetros que identifican la unidad vocálica, se realiza un análisis de las muestras de cada palabra." (Rojas Curieux 2017)

sample size

Corpus design and compilation

Definition

A quantitative measure representing the number of texts or data points included in a corpus, which is essential for achieving reliable estimates of linguistic parameters. The determination of an adequate sample size is influenced by factors such as the desired confidence interval and the variability of the linguistic features being studied. Larger sample sizes generally enhance the precision of statistical estimates, thereby minimizing the risks associated with undersampling.

Frequency (EN corpus)

abs: 217 pmw: 170.81

Corpus evidence (EN)

"The primary distribution considerations are the linguistic variable and the sample size." (source)

"Sample size is the more obvious of these considerations: how big does a sample need to be in order to reliably represent quantitative distributions?" (source)

"As sample size increases, so does precision." (source)

tamaño de muestra

Diseño y compilación de corpus

Definición

Medida cuantitativa que representa la cantidad de textos o puntos de datos incluidos en un corpus, fundamental para lograr estimaciones confiables de los parámetros lingüísticos. La determinación de un tamaño de muestra adecuado está influenciada por factores como el intervalo de confianza deseado y la variabilidad de las características lingüísticas estudiadas. Generalmente, tamaños de muestra más grandes mejoran la precisión de las estimaciones estadísticas, minimizando así los riesgos asociados con el submuestreo.

Frecuencia (corpus ES)

abs: 6 pmw: 7.39

Evidencia en corpus (ES)

"El tamaño está dado por los objetivos del corpus, las necesidades de cada investigación y los recursos electrónicos de los que se disponga para el almacenamiento del corpus." (fuente)

"Si bien es cierto que una cantidad mayor de datos permite potencialmente abarcar una porción mayor de la lengua, lo que en verdad importa es que el tamaño esté pensado con base en muestras diversificadas y balanceadas." (fuente)

"Para que un corpus sea representativo tiene que ser, a su vez, diverso; es decir, el corpus debe contener registros o categorías textuales variadas." (fuente)

Nota terminológica / Terminological note

The term "sample size" is widely used in corpus linguistics to denote the number of texts or data points necessary for reliable linguistic analysis. Variations in its application may arise based on the specific research objectives and the linguistic features being examined. El término "tamaño de muestra" se utiliza ampliamente en la lingüística de corpus para denotar la cantidad de textos o puntos de datos necesarios para un análisis lingüístico

Términos relacionados / Related terms

corpus / corpus · **representativeness** / representatividad · **accuracy** / exactitud · **sample size** / tamaño de muestra · **confidence interval** / intervalo de confianza

sampling frame

Corpus design and compilation

Definition

An itemized list of all texts within the operational domain that are available for sampling constitutes this concept. It serves as a foundational element in corpus design, ensuring that the selection of texts is systematic and representative. The absence of a sampling frame may hinder the methodological rigor of corpus compilation, contrasting with random sampling methods that rely on such a framework for unbiased selection.

Frequency (EN corpus)

abs: 93 pmw: 73.21

Corpus evidence (EN)

A sampling frame is an itemized list of all texts (from the operational domain) that are available for sampling. (source)

If it is not possible or not practical to create a sampling frame, it can still usually be possible to apply a principled approach to sampling. (source)

The full set of texts from the domain that could be included in the corpus, as well as the major internal categories in the domain that will be incorporated in the corpus design. (source)

Nota terminológica / Terminological note

This term is critical in corpus linguistics as it underpins the methodological framework for text selection, influencing the representativeness and validity of the corpus. The concept is widely accepted, although variations in its application may arise depending on the specific research context or corpus design strategy. Este término es fundamental en la lingüística de corpus, ya que sustenta el marco metodológico para la selección de textos, inf

Términos relacionados / Related terms

[sample](#) / muestra · [sample](#) / muestra · [representativeness](#) / representatividad · [representativeness](#) / representatividad · [population](#) / población

marco de muestreo

Diseño y compilación de corpus

Definición

Lista detallada de todos los textos del dominio operativo que están disponibles para ser muestreados. Constituye un elemento fundacional en el diseño de corpus, ya que garantiza que la selección de textos sea sistemática y representativa. La ausencia de un marco de muestreo puede comprometer el rigor metodológico de la compilación del corpus, a diferencia de los métodos de muestreo aleatorio, que dependen de dicho marco para garantizar una selección imparcial.

Frecuencia (corpus ES)

—

segmentation

Language processing

Definition

A process in language processing that involves dividing text into smaller, manageable units such as words, phrases, or sentences. This methodological approach is essential for various linguistic analyses, including annotation and topic modeling, as it facilitates the identification of linguistic patterns and structures within a corpus. Segmentation is often contrasted with aggregation, where data is combined rather than separated.

Frequency (EN corpus)

abs: 28 pmw: 22.04

Corpus evidence (EN)

"The segmentation and annotation of a vlog in ELAN Translingual Insertion (TI) is a linguistic phenomenon that involves the prominent use of specific lexical items..." (2024_Misir, H.)

"A corpus may be static or dynamic. A static corpus has a fixed size, which will not change." (2018_Sekhar Dash, N.)

"After presenting a tentative typology of corpora, this chapter provides guidelines as to making your own corpora before presenting the characteristics of ready-made, annotated corpora." (2017_Desagulier, G.)

Nota terminológica / Terminological note

The term "segmentation" is widely used in both theoretical and applied linguistics, particularly in corpus linguistics, where it serves as a foundational step in various analytical processes. Its application may vary depending on the specific linguistic context and the goals of the analysis. El término "segmentación" se utiliza ampliamente en lingüística teórica y aplicada, particularmente en lingüística de corpus, donde sirve como un paso funda

Términos relacionados / Related terms

annotation / anotación · **keyword analysis** / análisis de palabras clave · **token** / token · **corpus annotation** / anotación de corpus · **text type** / tipo de texto · **frequency list** / lista de frecuencias

segmentación

Procesamiento del lenguaje

Definición

Un proceso en el procesamiento del lenguaje que consiste en dividir un texto en unidades más pequeñas y manejables, como palabras, frases o oraciones. Este enfoque metodológico es esencial para diversos análisis lingüísticos, incluida la anotación y el modelado de temas, ya que facilita la identificación de patrones y estructuras lingüísticas dentro de un corpus. La segmentación se contrasta a menudo con la agregación, donde los datos se combinan en lugar de separarse.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

"El resultado del análisis se ofrece de dos maneras: por un lado, los grupos de palabras que representan cada topic y, por otro, los topics más relevantes en cada texto del corpus." (2022_Navarro Colorado, B.)

"Para el procesamiento de texto en español, es importante mantener la expresión regular que aparece en esta pantalla para que la herramienta procese correctamente las vocales con tilde y las eñes." (2022_Navarro Colorado, B.)

"Cada texto o documento, finalmente, contiene varios topics según los topics de las palabras que lo forman." (2022_Navarro Colorado, B.)

semantic annotation

Annotation and markup

Definition

A specific type of annotation that provides information about lexical fields, synonymy, and antonymy within a text. This form of annotation enhances the interpretative value of linguistic data by categorizing words based on their meanings and relationships. It is often contrasted with morpho-syntactic annotation, which focuses on grammatical structures rather than semantic relationships.

Frequency (EN corpus)

abs: 35 pmw: 27.55

Corpus evidence (EN)

"semantic annotation annotation information about lexical fields, synonymy/antonymy" (source)

"different types or levels of annotation and their development over the years." (source)

"the ACE annotation scheme for entity detection and tracking focuses on a small number of semantic classes considered particularly relevant for information extraction." (source)

anotación semántica

Anotación y marcado

Definición

Un tipo específico de anotación que proporciona información sobre campos léxicos, sinónimos y antónimos dentro de un texto. Esta forma de anotación enriquece el valor interpretativo de los datos lingüísticos al categorizar palabras según sus significados y relaciones. Se contrasta a menudo con la anotación morfosintáctica, que se centra en las estructuras gramaticales en lugar de las relaciones semánticas.

Frecuencia (corpus ES)

abs: 5 pmw: 6.16

Evidencia en corpus (ES)

"la anotación semántica se refiere a la información sobre campos léxicos y relaciones de sinonimia y antonimia." (fuente)

"la anotación morfosintáctica se contrasta a menudo con la anotación semántica, que se centra en las relaciones de significado." (fuente)

"la anotación de corpus incluye la anotación semántica como un componente clave para enriquecer los datos." (fuente)

Nota terminológica / Terminological note

The term "semantic annotation" is often used interchangeably with related terms but specifically emphasizes the meaning-related aspects of linguistic data. Its application can vary across different corpora and methodologies, reflecting the evolving nature of annotation practices in corpus linguistics. El término "anotación semántica" se utiliza a menudo de manera intercambiable con términos relacionados, pero enfatiza específicamente los aspectos

Términos relacionados / Related terms

annotation / anotación · **morphological annotation** / anotación morfológica · **corpus annotation** / anotación de corpus · **tagset** / tagset · **semantic annotation** / anotación semántica · **syntactic annotation** / anotación sintáctica

semantic prosody

Lexicon and phraseology

Definition

A linguistic phenomenon characterized by the connotational meanings that a word acquires through its collocates, often described as a "consistent aura of meaning." This term has been methodologically explored in corpus linguistics, revealing that semantic prosody can vary in positivity, neutrality, or negativity depending on the context and specific collocates. The distinction between general and specific semantic prosody highlights the complexity of attitudinal meanings associated with lexical items.

Frequency (EN corpus)

abs: 29 pmw: 22.83

Corpus evidence (EN)

Louw (1993: 157) refers to this phenomenon as "semantic prosody", defined, somewhat impressionistically, as the "consistent aura of meaning with which a form is imbued by its collocates." (source: 2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Much of the subsequent research on semantic prosody is based on the understanding that this "aura" consists of connotational meaning... so that words can have a "positive", "neutral" or "negative" semantic prosody. (source: 2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Studies on semantic prosody can also take into account dimensions beyond the immediate structural context. (source: 2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "semantic prosody" has been subject to various interpretations in the literature, with some researchers emphasizing its connotational aspects while others focus on its pragmatic implications. This variation in understanding reflects the complexity of lexical semantics and the influence of context on meaning. El término "prosodia semántica" ha sido objeto de diversas interpretaciones en la literatura, con algunos investigadores enfatizand

Términos relacionados / Related terms

collocation / colocación · **concordance** / concordancia · **keyword** / palabra clave · **corpus-based** / basado en corpus · **phraseology** / fraseología · **semantic prosody** / prosodia semántica

prosodia semántica

Léxico y fraseología

Definición

Fenómeno lingüístico que se caracteriza por los significados connotativos que adquiere una palabra a través de sus colocalizaciones, a menudo descrito como una "aura de significado consistente". Este término ha sido explorado metodológicamente en la lingüística de corpus, revelando que la prosodia semántica puede variar en positividad, neutralidad o negatividad según el contexto y los colocalizadores específicos. La distinción entre prosodia semántica general y específica resalta la complejidad de los significados atitudinales asociados con las unidades léxicas.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

La investigación con los corpus generales no consiste habitualmente en determinar la frecuencia de un cierto elemento léxico o fenómeno gramatical en todo el corpus, sino en establecer las diferencias entre las características que presenta en dos o más tipos diferentes de textos. (fuente: 2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

La lingüística de corpus focaliza su actividad en el tratamiento de aspectos pragmáticos y subjetivos del lenguaje no tratados anteriormente: las emociones, la factualidad, la veracidad de los mensajes y la polaridad de los mismos. (fuente: 2022_Martí, M. A., Taulé, M._Desarrollos tecnológicos de la lingüística de corpus en español)

Los corpus de español que incorporan información de esta naturaleza son muy limitados y de tamaño bastante reducido. (fuente: 2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

SGML

Metadata and formats

Definition

A markup format that requires a Document Type Definition (DTD) to specify its structure, enabling serious processing of annotated data. SGML is characterized by its complexity and the necessity for strict adherence to its coding standards, which can lead to errors if not properly managed. Compared to HTML and XML, SGML is less flexible and not widely supported by standard browser software, making it more challenging for corpus annotation tasks.

Frequency (EN corpus)

abs: 64 pmw: 50.38

Corpus evidence (EN)

The original SGML (Standard Generalized Markup Language) markup format of the ICE spoken data was defined in Nelson (1991), and later revised in Nelson (2002). (source)

SGML also has two other major disadvantages compared to HTML or XML, the first being that it absolutely requires a DTD (Document Type Definition) specifying its structure, in order to allow any type of serious processing. (source)

One big advantage, at least in comparison to HTML, is that a large set of tag definitions/DTDs for linguistic purposes, such as for the TEI (Text Encoding Initiative), were originally designed for SGML. (source)

Nota terminológica / Terminological note

SGML has been largely superseded by XML due to its complexity and the need for a DTD, which can complicate the annotation process. Its use in corpus linguistics is primarily historical, as modern practices have shifted towards more user-friendly markup languages that facilitate easier data processing and analysis. SGML ha sido en gran medida superado por XML debido a su complejidad y la necesidad de una DTD, lo que puede complicar el proceso de a

Términos relacionados / Related terms

[XML](#) / XML · [HTML](#) / HTML · [TEI](#) / TEI · [metadata](#) / metadatos · [annotation](#) / anotación · [markup language](#) / lenguaje de marcado

SGML

Metadatos y formatos

Definición

Un formato de marcado que requiere una Definición de Tipo de Documento (DTD) para especificar su estructura, lo que permite un procesamiento serio de los datos anotados. SGML se caracteriza por su complejidad y la necesidad de cumplir estrictamente con sus estándares de codificación, lo que puede dar lugar a errores si no se gestiona adecuadamente. En comparación con HTML y XML, SGML es menos flexible y no está ampliamente soportado por software de navegador estándar, lo que lo hace más desafiante para las tareas de anotación de corpus.

Frecuencia (corpus ES)

abs: 27 pmw: 33.26

Evidencia en corpus (ES)

La codificación del corpus debe ser UTF-8. (fuente)

Con la elección del lenguaje de marcado y el estándar, se da comienzo al proceso de etiquetado o marcado de metadatos. (fuente)

La inserción de estas etiquetas y un mayor número de datos externos registrados facilitan las búsquedas cruzadas y con una cobertura de más variables. (fuente)

Sketch Engine

Tools and software

Definition

A software tool developed by Lexical Computing Ltd, designed for the analysis of bilingual and multilingual parallel corpora. It provides functionalities such as bilingual Word Sketches and automatic bilingual terminology extraction, facilitating detailed frequency and collocational analysis. This tool is recognized for its methodological contributions to corpus linguistics, particularly in enabling researchers to explore authentic language use and compile specialized corpora.

Frequency (EN corpus)

abs: 26 pmw: 20.47

Corpus evidence (EN)

"Sketch Engine by Lexical Computing Ltd is undoubtedly the most powerful tool available to linguists, translation scholars, and lexicographers to analyze bilingual and multilingual parallel corpora." (2020_Lefer, M. A._Parallel corpora)

"Sketch Engine (and NoSketch Engine) also allow users to upload their own corpora for 'word sketches' (detailed collocate information)." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"MigObs used Sketch Engine to conduct more detailed frequency and collocational analysis similar in type to, but in greater depth than, the pilot study." (2017_Allen, W._Making corpus data visible. Visualising text with research intermediaries_Corpora)

Nota terminológica / Terminological note

The term "Sketch Engine" is widely recognized in the field of corpus linguistics for its advanced functionalities in analyzing parallel corpora. Its methodological significance lies in its ability to facilitate both quantitative and qualitative analyses of language, making it a preferred choice among researchers. El término "Sketch Engine" es ampliamente reconocido en el campo de la lingüística de corpus por sus avanzadas funcionalidades en el a

Términos relacionados / Related terms

corpus / corpus · annotation / anotación · concordance / concordancia · parallel corpus / corpus paralelo · keyword analysis / análisis de palabras clave · collocation / colocación

Sketch Engine

Herramientas y software

Definición

Una herramienta desarrollada por Lexical Computing Limited, destinada al análisis de corpus paralelos bilingües y multilingües. Ofrece funcionalidades como los Word Sketches bilingües y la extracción automática de terminología, lo que permite realizar análisis detallados de frecuencia y colocaciones. Esta herramienta es reconocida por sus aportaciones metodológicas a la lingüística de corpus, especialmente en la exploración del uso auténtico del lenguaje y la compilación de corpus especializados.

Frecuencia (corpus ES)

abs: 113 pmw: 139.20

Evidencia en corpus (ES)

"Sketch Engine es una herramienta desarrollada por Lexical Computing Limited desde 2003." (2024_Jiménez-Navarro, E. L._Consideraciones para la compilación y exploración de un corpus lingüístico)

"Uno de los puntos a favor de Sketch Engine, aparte de las numerosas funciones que ofrece, es que todos los resultados pueden descargarse directamente en distintos formatos." (2024_Jiménez-Navarro, E. L._Consideraciones para la compilación y exploración de un corpus lingüístico)

"Sketch Engine permite la compilación de corpus especializados y ofrece ajustes que refinan las búsquedas." (2024_Jiménez-Navarro, E. L._Consideraciones para la compilación y exploración de un corpus lingüístico)

specialized corpus

Corpus design and compilation

Definition

A collection of texts sampled from a specific domain or variety of language, designed to facilitate investigations into particular linguistic phenomena. This type of corpus often contains a smaller number of texts compared to general corpora but is more focused and representative of the language use within its defined scope. Specialized corpora are particularly useful for targeted linguistic research, as they allow for the examination of language features that may not be prevalent in broader datasets.

Frequency (EN corpus)

abs: 76 pmw: 59.82

Corpus evidence (EN)

texts collected from the people belonging to specialized domains of profession (e.g., auction, medicine, music, games and sports, cooking, law, underworld, gambling) may be designated as examples of a special corpus due to high representative function of texts about a particular type or a variety of language these people use for specific purposes. (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

A special corpus contains texts sampled from a particular variety of a language. (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

The main advantage of this corpus is that texts are selected in such a way that the particular phenomena that we are looking for in the language variety may occur more frequently and recurrently than noted in a general corpus. (2018_Sekhar Dash, N., Arulmozi, S._History, Features, and Typology of Language Corpora)

Nota terminológica / Terminological note

The term "specialized corpus" is often contrasted with "general corpus," highlighting its focused nature and smaller size. This distinction is important in corpus linguistics, as specialized corpora are designed to investigate specific linguistic phenomena, making them invaluable for targeted research. El término "corpus especializado" se contrasta a menudo con "corpus general", destacando su naturaleza enfocada y su menor tamaño. Esta distinció

Términos relacionados / Related terms

general corpus / corpus general · **corpus design** / diseño de corpus · **representativeness** / representatividad · **annotated corpus** / corpus anotado · **frequency** / frecuencia

corpus especializado

Diseño y compilación de corpus

Definición

Una colección de textos seleccionados de un dominio o variedad específica del lenguaje, diseñada para facilitar investigaciones sobre fenómenos lingüísticos particulares. Este tipo de corpus suele contener un menor número de textos en comparación con los corpus generales, pero es más enfocado y representativo del uso del lenguaje dentro de su ámbito definido. Los corpus especializados son especialmente útiles para la investigación lingüística dirigida, ya que permiten examinar características del lenguaje que pueden no ser prevalentes en conjuntos de datos más amplios.

Frecuencia (corpus ES)

abs: 32 pmw: 39.42

Evidencia en corpus (ES)

su tamaño, dada su condición de ser especializado y alineado, será inferior a otros corpus generales o monolingües. (2018_Leiva Rojo, J._Diseño y compilación de corpus paralelos alineados. Dificultades y algunas soluciones_Revista de Lingüística y Lenguas Aplicadas)

un corpus especializado suele contener un menor número de palabras que uno de referencia, pues posee una mayor densidad léxica. (2024_Jiménez-Navarro, E. L._Consideraciones para la compilación y exploración de un corpus lingüístico)

otro punto relevante es el tipo de discurso que abarca, que puede ser escrito o hablado, así como la muestra de textos que incluye, que pueden ser textos completos o extractos de textos. (2024_Jiménez-Navarro, E. L._Consideraciones para la compilación y exploración de un corpus lingüístico)

speech corpus

Corpus design and compilation

Definition

A collection of spoken language data, typically transcribed or recorded, used for linguistic analysis and research. This type of corpus is essential for studying phonetics, speech recognition, and discourse analysis, as it captures the nuances of natural spoken interaction. The generation of speech corpora is often more complex than that of written corpora due to the inherent variability and spontaneity of spoken language.

Frequency (EN corpus)

abs: 246 pmw: 193.64

Corpus evidence (EN)

"To achieve success, we need help from expert phoneticians, field linguists, computer experts, language experts and some sophisticated systems for spoken text collection, storage, management, processing, analysis and application." (2018_Sekhar Dash, N., Arulmozi, S.)

"The Edinburgh University Speech Timing Archive and Corpus of English (EUSTACE) is a useful resource for researchers working in phonetics, speech synthesis, and speech recognition." (2018_Sekhar Dash, N., Arulmozi, S.)

"Although it is known that speech is livelier, more varied and more reliable than text in its representation of a natural language, the present limited availability of speech corpora... is a problem for the people working in corpus linguistics." (2018_Sekhar Dash, N., Arulmozi, S.)

Nota terminológica / Terminological note

The term "speech corpus" is increasingly recognized as essential in linguistic research, particularly in fields such as phonetics and speech technology. Its complexity arises from the need for accurate transcription and annotation, which distinguishes it from written corpora. El término "corpus oral" se reconoce cada vez más como esencial en la investigación lingüística, especialmente en campos como la fonética y la tecnología del habla. Su comp

Términos relacionados / Related terms

corpus / corpus · **spoken corpus** / corpus oral · **annotation** / anotación · **corpus design** / diseño de corpus · **corpus compilation** / compilación de corpus · **speech corpus** / corpus oral

corpus oral

Diseño y compilación de corpus

Definición

Conjunto de datos de lenguaje hablado, que puede estar transcrito o grabado, utilizado para el análisis y la investigación lingüística. Este tipo de corpus es fundamental para el estudio de la fonética, el reconocimiento del habla y el análisis del discurso, ya que captura las sutilezas de la interacción oral natural. La generación de corpus orales suele ser más compleja que la de los corpus escritos debido a la variabilidad y espontaneidad inherentes al lenguaje hablado.

Frecuencia (corpus ES)

abs: 3 pmw: 3.70

Evidencia en corpus (ES)

"Los corpus orales están formados por grabaciones de textos orales, transcritas o no." (2021_Rojo, G.)

"La generación de corpus orales suele ser más compleja que la de los corpus escritos debido a la variabilidad y espontaneidad inherentes al lenguaje hablado." (2021_Rojo, G.)

"Este potencial es particularmente útil en los esfuerzos llevados a cabo por la Universidad del Cauca para la revitalización y fortalecimiento del nasa yuwe y el nam trik, específicamente en el apoyo a los procesos de enseñanza y aprendizaje de estas lenguas." (2017_Rojas Curieux, T.)

spoken corpus

Corpus design and compilation

Definition

A specialized collection of spoken language data, characterized by its focus on capturing natural speech in various contexts. This type of corpus is essential for phonetic and phonological investigations, as it allows for the analysis of spoken language features that are not present in written texts. Unlike written corpora, spoken corpora face unique challenges in collection and transcription due to the spontaneous and variable nature of spoken discourse.

Frequency (EN corpus)

abs: 122 pmw: 96.03

Corpus evidence (EN)

"To achieve success, we need help from expert phoneticians, field linguists, computer experts, language experts and some sophisticated systems for spoken text collection, storage, management, processing, analysis and application." (2018_Sekhar Dash, N., Arulmozi, S.)

"Speech corpora are a special type of spoken corpus that are intended for corpus-based investigations into the phonetic and phonological structure of spoken language use." (2023_Barth, D., Schnell, S.)

"Although it is known that speech is livelier, more varied and more reliable than text in its representation of a natural language, the present limited availability of speech corpora, in comparison with the large number of written corpora is a problem for the people working in corpus linguistics." (2018_Sekhar Dash, N., Arulmozi, S.)

Nota terminológica / Terminological note

The term "spoken corpus" is increasingly recognized in corpus linguistics as essential for understanding the dynamics of spoken language. Its methodological challenges, including transcription and annotation, highlight the complexities involved in capturing natural speech. El término "corpus oral" se reconoce cada vez más en la lingüística de corpus como esencial para comprender la dinámica del lenguaje hablado. Sus desafíos metodológicos, que i

Términos relacionados / Related terms

speech corpus / corpus oral · **corpus annotation** / anotación de corpus · **corpus design** / diseño de corpus · **written corpus** / corpus escrito · **annotation scheme** / esquema de anotación

corpus oral

Diseño y compilación de corpus

Definición

Un conjunto especializado de datos de lenguaje hablado, caracterizado por su enfoque en capturar el habla natural en diversos contextos. Este tipo de corpus es esencial para investigaciones fonéticas y fonológicas, ya que permite el análisis de características del lenguaje hablado que no están presentes en los textos escritos. A diferencia de los corpus escritos, los corpus orales enfrentan desafíos únicos en su recopilación y transcripción debido a la naturaleza espontánea y variable del discurso hablado.

Frecuencia (corpus ES)

abs: 116 pmw: 142.89

Evidencia en corpus (ES)

"Las conversaciones coloquiales incorporadas a los corpus son particularmente valoradas porque esta es la modalidad discursiva más empleada y prototípica en la comunicación humana." (2018_Parodi, G., Burdiles, G.)

"Es recomendable trabajar con corpus orales y facilitar el aprendizaje de la lengua a través del uso de conversaciones reales que sean frecuentes en los encuentros comunicativos del día a día." (2018_Parodi, G., Burdiles, G.)

"El corpus MASC es un corpus oral bilingüe, especializado, discursivo, multigénero y multidisciplinar, que recoge clases, conferencias y sesiones de discusión en español peninsular y en inglés." (2022_Bosio, I. V., Cubo, L.)

standard deviation

Frequency and statistics

Definition

A statistical measure of dispersion, this value quantifies the extent to which individual data points differ from the mean of a dataset. It is calculated as the square root of the variance, which itself is derived from the average of the squared differences between each data point and the mean. The standard deviation is widely utilized in corpus linguistics to assess variability in frequency distributions, although it may not be ideal for skewed data distributions.

Frequency (EN corpus)

abs: 122 pmw: 96.03

Corpus evidence (EN)

The standard deviation (σ) is the most widely used measure of dispersion. (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

The standard deviation is calculated based on the squared distance of rates from their mean. (2025_Sonnig, L._Advancing our understanding of dispersion measures in corpus research)

A larger standard deviation (s) will result in a larger required sample size. (2022_Egbert_ J. Biber_ D. y Gray_ B._Designing and Evaluating Language Corpora)

Nota terminológica / Terminological note

The term "standard deviation" is foundational in statistics and corpus linguistics, serving as a critical measure for understanding data variability. Its application is particularly relevant in the context of frequency distributions, where it helps researchers interpret the spread of linguistic phenomena. El término "desviación estándar" es fundamental en estadística y lingüística de corpus, sirviendo como una medida crítica para comprender la v

Términos relacionados / Related terms

standard deviation / desviación estándar · **frequency** / frecuencia · **sample size** / tamaño de muestra · **confidence interval** / intervalo de confianza · **descriptive statistics** / estadísticas descriptivas · **probability** / probabilidad

desviación estándar

Frecuencia y estadística

Definición

Medida estadística de la dispersión, este valor cuantifica el grado en que los puntos de datos individuales difieren de la media de un conjunto de datos. Se calcula como la raíz cuadrada de la varianza, que a su vez se deriva del promedio de las diferencias al cuadrado entre cada punto de datos y la media. La desviación estándar se utiliza ampliamente en la lingüística de corpus para evaluar la variabilidad en las distribuciones de frecuencia, aunque puede no ser ideal para distribuciones de datos sesgadas.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

La desviación estándar se utiliza ampliamente en la lingüística de corpus para evaluar la variabilidad en las distribuciones de frecuencia. (2021_Rojo, G._Introducción a la lingüística de corpus en español)

La medida de la desviación estándar es crucial para entender la dispersión de los datos en un corpus. (2017_Rojas Curieux, T._A propósito de la lingüística de corpus, fundamentos y discrepancias. A manera de introducción)

La desviación estándar se calcula como la raíz cuadrada de la varianza, lo que permite evaluar la variabilidad de los datos. (2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

statistical significance

Frequency and statistics

Definition

A measure indicating that the results obtained from a sample are unlikely to have occurred by chance, thus allowing for generalization to the broader population. Statistical significance is distinct from theoretical importance, as it does not imply the strength or relevance of the observed relationship. It is essential in research methodology to ensure that findings are not merely random occurrences.

Frequency (EN corpus)

abs: 36 pmw: 28.34

Corpus evidence (EN)

"The differences between the constructions are highly significant ($\chi^2 = 272.16$, $df = 1$, $p < 0.001$)." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"Statistical significance has nothing to do with the quality of our data." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

"Statistical significance does not actually tell us anything about the importance of the relationship we have observed." (2020_Stefanowitsch, A._Corpus Linguistics A guide to the methodology)

Nota terminológica / Terminological note

The term "statistical significance" is often misinterpreted as implying practical importance, which is not necessarily the case. This distinction is crucial in research contexts where findings must be evaluated beyond mere statistical thresholds. El término "significancia estadística" a menudo se malinterpreta como implicando importancia práctica, lo cual no es necesariamente el caso. Esta distinción es crucial en contextos de investigación donde

Términos relacionados / Related terms

probability / probabilidad · **effect size** / tamaño del efecto · **inferential statistics** / estadísticas inferenciales · **confidence interval** / intervalo de confianza · **chi-squared** / test de chi-cuadrado · **sample size** / tamaño de muestra

significancia estadística

Frecuencia y estadística

Definición

Una medida que indica que los resultados obtenidos de una muestra son poco probables que hayan ocurrido por azar, lo que permite su generalización a la población más amplia. La significancia estadística se distingue de la importancia teórica, ya que no implica la fuerza o relevancia de la relación observada. Es esencial en la metodología de investigación para asegurar que los hallazgos no son meras ocurrencias aleatorias.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

"La información estadística relativa al contexto en que se encuentra cada forma." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

"Es razonable mantener ciertas precauciones acerca de la conveniencia de proyectar lo que se encuentra en un lema de diccionario sobre la lengua usada realmente en un momento determinado." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

"Los datos contenidos en el DLE son aproximadamente los que figuran en la tabla 5.1." (2021_Rojo, G._Introducción a la lingüística de corpus en español)

stem

Language processing

Definition

A linguistic unit that serves as the base form of a word, from which derivatives can be created through the addition of affixes. The analysis of stems often involves examining their frequency and preference in relation to specific affixes, as demonstrated in studies utilizing various corpora. This term is methodologically significant in morphological analysis, particularly in the context of affixation and word formation.

Frequency (EN corpus)

abs: 40 pmw: 31.49

Corpus evidence (EN)

There are 373 stem types occurring with -ic in the LOB corpus, with a mean length of 7.32 and a sample variance of 5.72; there are 153 stem types occurring with -ical, with a mean length of 6.60 and a sample variance of 4.57. (source)

This case study has demonstrated the use of a relatively simple operationalization to test a hypothesis about phonological length. (source)

Instead of calculating the overall preference of a particular type of stem and comparing it to the overall preference of all stems, let us calculate the preference for each stem individually. (source)

Nota terminológica / Terminological note

The term "stem" is widely used in morphological studies and is crucial for understanding word formation processes. Its application can vary depending on the linguistic framework, with some scholars emphasizing its role in affixation while others focus on its function in semantic analysis. El término "raíz" se utiliza ampliamente en estudios morfológicos y es crucial para comprender los procesos de formación de palabras. Su aplicación puede variar.

Términos relacionados / Related terms

stem / stem · **lemma** / lema · **token** / token · **morphological annotation** / anotación morfológica · **word class** / clase de palabras · **corpus design** / diseño de corpus

stem

Procesamiento del lenguaje

Definición

Una unidad lingüística que actúa como la forma base de una palabra, a partir de la cual se pueden crear derivados mediante la adición de afijos. El análisis de las raíces implica examinar su frecuencia y preferencia en relación con afijos específicos, como se demuestra en estudios que utilizan diversos corpus. Este término es metodológicamente significativo en el análisis morfológico, especialmente en el contexto de la afijación y la formación de palabras.

Frecuencia (corpus ES)

abs: 1 pmw: 1.23

Evidencia en corpus (ES)

Al no precisar de un diccionario específico, en principio se pueden aplicar a cualquier idioma. (fuente)

La intervención humana se reduce a revisar las anotaciones del corpus de entrenamiento. (fuente)

Este término es metodológicamente significativo en el análisis morfológico, especialmente en el contexto de la afijación y la formación de palabras. (fuente)

stopword

Lexicon and phraseology

Definition

A lexical item characterized by its high frequency and low semantic content, often excluded from analyses to enhance the clarity of keyword identification. The methodological use of stopwords is evident in corpus linguistics, where they are filtered out to improve the quality of topic modeling and keyword analysis. This contrasts with content words, which carry significant meaning and are crucial for understanding the text's subject matter.

Frequency (EN corpus)

abs: 4 pmw: 3.15

Corpus evidence (EN)

"Once you've created the keyword list, you should immediately be able to see that some of the words we'd previously only been able to identify through the basic frequency list after repeatedly manipulating the stop word list should now more or less automatically have 'jumped' to the top." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"For stop-words, we employed the smart lexicon... These words were either highly frequent or were required to be present in the texts as a criterion for corpus collection." (2025_Batchelor, J., Lee-Laminack, H._An evaluation of the use of keyword analysis for keyword-assisted topic modelling_Corpora)

"We then filtered out words with only a single character and words appearing in only one text." (2025_Batchelor, J., Lee-Laminack, H._An evaluation of the use of keyword analysis for keyword-assisted topic modelling_Corpora)

Nota terminológica / Terminological note

The term "stopword" is widely used in corpus linguistics to denote words that are often excluded from text analysis due to their lack of significant meaning. This practice is essential for enhancing the precision of keyword extraction and topic modeling. In Spanish linguistics, the equivalent term is "palabra vacía," which carries similar implications regarding the exclusion of non-essential lexical items. El término "palabra vacía" se utiliza am

Términos relacionados / Related terms

keyword / palabra clave · **token** / token · **frequency list** / lista de frecuencias · **corpus compilation** / compilación de corpus · **lemmatisation** / lematización

palabra vacía

Léxico y fraseología

Definición

Unidad léxica caracterizada por su alta frecuencia de aparición y bajo contenido semántico, que habitualmente se excluye de los análisis para mejorar la identificación de palabras clave. Su uso metodológico es habitual en la lingüística de corpus, donde se filtran para mejorar la calidad del modelado de temas y el análisis de palabras clave. Se distinguen de las palabras de contenido, que poseen significado referencial y resultan fundamentales para comprender el tema del texto.

Frecuencia (corpus ES)

abs: 7 pmw: 8.36

subcorpus

Corpus design and compilation

Definition

A subset of a larger corpus, distinguished by specific selection criteria or thematic focus, allowing for targeted linguistic analysis. The creation of subcorpora is a methodological feature that enhances the granularity of corpus studies, enabling researchers to explore variations in language use across different contexts or genres. This contrasts with a general corpus, which encompasses a broader range of texts without such specific delineations.

Frequency (EN corpus)

abs: 84 pmw: 66.12

Corpus evidence (EN)

The occurrence of v. demonstrates that parts of the general subcorpus contain references to legal matters, where the type is one of the two possible abbreviations for versus (the other being vs.). (source)

This exercise is much easier to do than the previous one, so there's relatively little potential for getting anything wrong. Perhaps the only things that could happen here are that you either inadvertently select the wrong display option, or the wrong sub-genre from one of the list boxes. (source)

The ability to create subcorpora, based on different selection criteria, is a significant feature of corpus analysis tools. (source)

Nota terminológica / Terminological note

The term "subcorpus" is widely used in corpus linguistics to denote specific subsets of a larger corpus, allowing for focused analyses that can yield insights into particular linguistic phenomena. Its usage is essential for researchers aiming to explore language variation across different contexts or genres, emphasizing the methodological importance of corpus design. El término "subcorpus" se utiliza ampliamente en la lingüística de corpus para d

Términos relacionados / Related terms

corpus / corpus · **corpus design** / diseño de corpus · **sample** / muestra · **general corpus** / corpus general · **frequency** / frecuencia · **annotated corpus** / corpus anotado · **text type** / tipo de texto

subcorpus

Diseño y compilación de corpus

Definición

Una división dentro de un corpus más amplio, caracterizada por criterios de selección específicos o un enfoque temático, que permite un análisis lingüístico dirigido. La construcción de subcorpus es una característica metodológica que enriquece los estudios de corpus, permitiendo a los investigadores explorar variaciones en el uso del lenguaje a través de diferentes contextos o géneros. Esto contrasta con un corpus general, que abarca una gama más amplia de textos sin tales delimitaciones específicas.

Frecuencia (corpus ES)

abs: 187 pmw: 230.36

Evidencia en corpus (ES)

Los subcorpus son las divisiones que se efectúan dentro del corpus en general; por ejemplo, un corpus denominado Corpus de las Investigaciones del Instituto Caro y Cuervo podría contar tanto con el Subcorpus Oral como con el Subcorpus Escrito. (fuente)

Quiero decir que esos subcorpus no están contruidos previamente ni los resultados han sido "congelados" con anterioridad: como cada texto lleva los valores correspondientes a los distintos parámetros, el subcorpus se construye de forma dinámica. (fuente)

La inclusión de la novela Saturday, de Ian McEwan, cuyo protagonista es un neurocirujano, puede producir consecuencias muy similares en el subcorpus. (fuente)

synchronic

Corpus design and compilation

Definition

A classification of corpora that captures linguistic features at a specific point in time, without considering historical changes. This approach contrasts with diachronic studies, which analyze language evolution over time. The methodological emphasis on synchronic analysis allows for the examination of language use in contemporary contexts, facilitating empirical testing of hypotheses formed at particular temporal snapshots.

Frequency (EN corpus)

abs: 95 pmw: 74.78

Corpus evidence (EN)

A corpus should continue to grow with time to register linguistic changes noted in a language. Since most of the present-day corpora are synchronic in nature, we should try to make them diachronic so that they grow in parallel with the change of time and language. (source)

A synchronic corpus, by regular augmentation of texts across domains, can achieve the status of a diachronic corpus. (source)

The task of expanding the empirical range of hypotheses based on the BNC1994 to be expanded and surprise engaged with. (source)

Nota terminológica / Terminological note

The term "synchronic" is primarily used in linguistic studies to denote analyses that focus on language at a specific moment, which can be crucial for understanding contemporary usage. In contrast, diachronic studies provide insights into language evolution, highlighting the dynamic nature of linguistic systems. El término "sincrónico" se utiliza principalmente en estudios lingüísticos para denotar análisis que se centran en el lenguaje en un mom

Términos relacionados / Related terms

[diachronic corpus](#) / corpus diacrónico · [reference corpus](#) / corpus de referencia · [corpus design](#) / diseño de corpus · [corpus compilation](#) / compilación de corpus · [frequency](#) / frecuencia · [annotation](#) / anotación

sincrónico

Diseño y compilación de corpus

Definición

Una clasificación de los corpus que captura características lingüísticas en un momento específico, sin considerar los cambios históricos. Este enfoque contrasta con los estudios diacrónicos, que analizan la evolución del lenguaje a lo largo del tiempo. El énfasis metodológico en el análisis sincrónico permite examinar el uso del lenguaje en contextos contemporáneos, facilitando la prueba empírica de hipótesis formuladas en momentos temporales particulares.

Frecuencia (corpus ES)

abs: 4 pmw: 4.93

Evidencia en corpus (ES)

El análisis como DEMostrativo (determinante) es más frecuente que el análisis como PRONombre. (fuente)

Los corpus generales permiten, en efecto, extraer datos acerca de las características relevantes de la L2 y hacerlo de forma selectiva en función de los diferentes tipos de texto. (fuente)

Los corpus de aprendientes incorporan los textos tal como han sido producidos originalmente, con el mínimo de codificación necesario para la recuperación adecuada de datos. (fuente)

syntactic annotation

Annotation and markup

Definition

A type of annotation that focuses on the structural aspects of language, specifically identifying and marking syntactic elements such as noun phrases, verbs, and clauses within a text. This method allows for the analysis of referential identity and anaphoric relations, enhancing the understanding of discourse connections. Syntactic annotation is often contrasted with semantic annotation, which deals with meaning rather than structure.

Frequency (EN corpus)

abs: 32 pmw: 25.19

Corpus evidence (EN)

In ANCORA benefits from the existing syntactic annotation and asks annotators to consider as markables the following five syntactic nodes: (i) NPs (including elliptical subjects), (ii) nominal groups in a conjoined NP, (iii) relative pronouns, (iv) possessive determiners, and (v) possessive pronouns. (source: 2016_Poesio, M., Pradhan, S., Recasens, M., Rodríguez, K., Versley, Y._Annotated Corpora and Annotation Tools)

The annotation system has two basic facets: (1) it captures the identity of referents mentioned by different referring expressions, (2) it captures various aspects of the anaphoric relation. (source: 2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

However, I still refer to this as 'Simple XML' because it remains easily readable due to the relatively low number of container elements and the separation of text from nonempty tags. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term is primarily used in the context of corpus linguistics to enhance the analysis of syntactic structures and their functions in discourse. Variations in methodology may arise depending on the specific annotation schemes employed, which can differ in complexity and focus. El término se utiliza principalmente en el contexto de la lingüística de corpus para mejorar el análisis de las estructuras sintácticas y sus funciones en el discurso. Las

Términos relacionados / Related terms

annotation / anotación · **annotated corpus** / corpus anotado · **POS tagging** / etiquetado morfosintáctico · **dependency parsing** / análisis de dependencias · **semantic annotation** / anotación semántica · **treebank** / treebank

anotación sintáctica

Anotación y marcado

Definición

La anotación que se centra en los aspectos estructurales del lenguaje, identificando y marcando elementos sintácticos como frases nominales, verbos y cláusulas dentro de un texto. Este método permite el análisis de la identidad referencial y las relaciones anafóricas, mejorando la comprensión de las conexiones discursivas. La anotación sintáctica se contrasta a menudo con la anotación semántica, que se ocupa del significado en lugar de la estructura.

Frecuencia (corpus ES)

abs: 10 pmw: 11.94

t-score

Frequency and statistics

Definition

A statistical measure used to determine the significance of differences between groups, calculated by comparing the mean of a sample to a known value while accounting for variability. The t-score is particularly relevant in hypothesis testing and is often employed in conjunction with other statistical measures to assess the strength of collocations and their significance in linguistic analysis. This term is methodologically grounded in corpus linguistics, where it aids in identifying significant patterns in language use.

Frequency (EN corpus)

abs: 16 pmw: 12.59

Corpus evidence (EN)

"Therefore, essentially, all the cases of collocations identified through the t-score stat that I've just discussed, strictly speaking, represent cases of colligation." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction)

"In contrast, the majority of words MI identifies are content words... we now need to think about how the t-score results may relate to these." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction)

"The t-score is particularly relevant in hypothesis testing and is often employed in conjunction with other statistical measures to assess the strength of collocations." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction)

Nota terminológica / Terminological note

The t-score is widely used in statistical analyses within corpus linguistics, particularly for hypothesis testing and evaluating collocations. Its application can vary based on the specific linguistic context and the nature of the data being analyzed. La puntuación t se utiliza ampliamente en análisis estadísticos dentro de la lingüística de corpus, especialmente para pruebas de hipótesis y evaluación de colocaciones. Su aplicación puede variar

Términos relacionados / Related terms

collocation / colocación · **statistical significance** / significancia estadística · **probability** / probabilidad · **mean score** / puntuación media · **effect size** / tamaño del efecto

puntuación t

Frecuencia y estadística

Definición

Una medida estadística utilizada para determinar la significación de las diferencias entre grupos, calculada al comparar la media de una muestra con un valor conocido, teniendo en cuenta la variabilidad. La puntuación t es especialmente relevante en las pruebas de hipótesis y se emplea a menudo junto con otras medidas estadísticas para evaluar la fuerza de las colocaciones y su significación en el análisis lingüístico.

Frecuencia (corpus ES)

abs: 6 pmw: 7.39

Evidencia en corpus (ES)

"El análisis de colocaciones a menudo se complementa con la puntuación t para evaluar su significación estadística." (2017_Rojas Curieux, T._A propósito de la lingüística de corpus, fundamentos y discrepancias. A manera de introducción)

"La puntuación t se utiliza para determinar la fuerza de las relaciones entre las palabras en un corpus." (2017_Rojas Curieux, T._A propósito de la lingüística de corpus, fundamentos y discrepancias. A manera de introducción)

"En el análisis lingüístico, la puntuación t es fundamental para evaluar la significación de los patrones observados." (2017_Rojas Curieux, T._A propósito de la lingüística de corpus, fundamentos y discrepancias. A manera de introducción)

tagger

Language processing

Definition

A software tool designed to assign linguistic categories to words in a text, facilitating morphosyntactic annotation. Taggers are essential in natural language processing applications, as they provide a structured way to analyze corpus data, although their accuracy can vary based on the linguistic features of the language being processed. The effectiveness of a tagger may be influenced by the complexity of the linguistic structures it encounters and the training data it was developed on.

Frequency (EN corpus)

abs: 146 pmw: 114.93

Corpus evidence (EN)

"This paper describes the process of providing the Spanish and the German data of the corpus PaGeS with part of speech tags, which includes the selection of the tagger software..." (2017_Doval, I.)

"Having now compared the results produced by two different taggers, you'll hopefully already have developed some basic sense of how reliable such programs in fact are..." (2016_Weisser, M.)

"However, we plan to tag CoCELD using the Multidimensional Analysis Tagger (MAT; Nini 2019)." (2023_Rodríguez-Puente, P., Hernández, D.)

Nota terminológica / Terminological note

The term "tagger" encompasses a variety of software tools that differ in their methodologies and accuracy rates, often requiring adaptation to specific linguistic contexts. In Spanish, "etiquetador" is widely accepted, although variations exist depending on the specific linguistic features being addressed. El término "etiquetador" abarca una variedad de herramientas de software que difieren en sus metodologías y tasas de precisión, a menudo requi

Términos relacionados / Related terms

part-of-speech tagging / etiquetado morfosintáctico · **annotation** / anotación · **corpus annotation** / anotación de corpus · **accuracy** / exactitud · **tagset** / tagset · **morphological annotation** / anotación morfológica

etiquetador

Procesamiento del lenguaje

Definición

Una herramienta de software destinada a asignar categorías lingüísticas a las palabras en un texto, facilitando la anotación morfosintáctica. Los etiquetadores son fundamentales en las aplicaciones de procesamiento del lenguaje natural, ya que proporcionan una forma estructurada de analizar los datos del corpus, aunque su precisión puede variar según las características lingüísticas del idioma que se procesa. La efectividad de un etiquetador puede verse influenciada por la complejidad de las estructuras lingüísticas que encuentra y los datos de entrenamiento en los que se desarrolló.

Frecuencia (corpus ES)

abs: 59 pmw: 72.68

Evidencia en corpus (ES)

"Los tres analizadores más usados (TT, Grampal y FL) tienen un acierto general ligeramente por encima del 90%, pero lejos de los resultados reportados para el inglés." (2022_Moreno Sandoval, A.)

"TreeTagger etiqueta por lengua, esto es, textos monolingües." (2016_Molés-Cases, T.)

"La cuestión de cuál es el conjunto de etiquetas más apropiado siempre ha sido un tema de debate." (2022_Martí, M. A., Taulé, M.)

tagset

Annotation and markup

Definition

A structured set of labels used for annotating linguistic data, providing information about grammatical categories and features of words. The choice of a specific tagset influences the performance of automatic taggers, which rely on these descriptive tags for disambiguation tasks. Different tagsets, such as those from the Penn English Treebank or CLAWS, vary in granularity and detail, impacting the analysis of syntactic and semantic properties.

Frequency (EN corpus)

abs: 158 pmw: 124.37

Corpus evidence (EN)

"The tags used by openNLP come from the tagset of the Penn English Treebank." (source)

"A tagset may also contain tags that are much longer." (source)

"The CLAWS C7 tagset, which is already far more detailed at 152 tags, exceeding the 48 tags observed in the Penn tagset by 104 tags." (source)

Nota terminológica / Terminological note

The term "tagset" is widely used in corpus linguistics to denote the specific labels assigned to linguistic elements, which can vary significantly across different languages and tagging systems. This variation can affect the granularity of linguistic analysis and the effectiveness of computational tools. El término "conjunto de etiquetas" se utiliza ampliamente en la lingüística de corpus para denotar las etiquetas específicas asignadas a los el

Términos relacionados / Related terms

POS tagging / etiquetado morfosintáctico · **annotation scheme** / esquema de anotación · **annotated corpus** / corpus anotado · **tagger** / etiquetador · **morphological annotation** / anotación morfológica · **semantic annotation** / anotación semántica

tagset

Anotación y marcado

Definición

Un conjunto estructurado de etiquetas utilizado para anotar datos lingüísticos, que proporciona información sobre categorías gramaticales y características de las palabras. La elección de un tagset específico influye en el rendimiento de los etiquetadores automáticos, que dependen de estas etiquetas descriptivas para las tareas de desambiguación. Los diferentes tagsets, como los del Penn English Treebank o CLAWS, varían en granularidad y detalle, lo que impacta en el análisis de propiedades sintácticas y semánticas.

Frecuencia (corpus ES)

abs: 15 pmw: 18.48

Evidencia en corpus (ES)

"Desde mediados de los 90 esta relación etiquetadores-corpus se ha explotado en diferentes lenguas y en una tipología muy variada de textos." (fuente)

"La metodología de evaluación es bastante estándar desde hace una década: 1. Unificación del etiquetario, dado que cada etiquetador emplea su propio tagset." (fuente)

"Para el conjunto de etiquetas unificado, se emplea el mencionado del UD3, al que por simplificación se han fusionado las dos clases de conjunciones." (fuente)

TEI

Metadata and formats

Definition

A standardized markup language designed for the representation of texts in digital form, facilitating the encoding of linguistic and structural information. The TEI provides guidelines that emphasize semantic rather than presentational markup, allowing for a more meaningful representation of textual elements. This approach contrasts with simpler markup systems that may prioritize visual formatting over content description.

Frequency (EN corpus)

abs: 61 pmw: 48.02

Corpus evidence (EN)

"The annotation scheme(s) proposed by the TEI are too 'element-heavy', i.e. introduce especially container elements, i.e. those that contain textual content, far too readily..." (2017_Weisser, M.)

"Using separate elements suggest that they are not a part of the flow and somehow interrupt the speaker's turn, which may or may not actually be the case." (2017_Weisser, M.)

"The TEI provides guidelines that emphasize semantic rather than presentational markup..." (2018_Sekhar Dash, N.)

TEI

Metadatos y formatos

Definición

Un lenguaje de marcado estandarizado destinado a la representación de textos en formato digital, que facilita la codificación de información lingüística y estructural. La TEI ofrece directrices que enfatizan el marcado semántico en lugar del marcado presentacional, permitiendo una representación más significativa de los elementos textuales. Este enfoque contrasta con sistemas de marcado más simples que pueden priorizar el formato visual sobre la descripción del contenido.

Frecuencia (corpus ES)

abs: 36 pmw: 44.35

Evidencia en corpus (ES)

"La inserción de estas etiquetas y un mayor número de datos externos registrados facilitan las búsquedas cruzadas..." (2018_Bernal Chávez, J. A.)

"Quizá uno de los niveles más altos y estandarizados a los que ha llegado el etiquetado son las marcas a partir de la TEI..." (2023_Lázaro, J.)

"El marcado de metadatos con la elección del lenguaje de marcado y el estándar, se da comienzo al proceso de etiquetado..." (2018_Bernal Chávez, J. A.)

Nota terminológica / Terminological note

The TEI is widely recognized in digital humanities and linguistics for its robust framework for text encoding, though its complexity can lead to varied interpretations among practitioners. Its emphasis on semantic markup has established it as a critical tool for researchers seeking to analyze textual data beyond mere presentation. La TEI es ampliamente reconocida en las humanidades digitales y la lingüística por su sólido marco para la codificaci

Términos relacionados / Related terms

metadata / metadatos · **annotation** / anotación · **markup language** / lenguaje de marcado · **SGML** / SGML · **HTML** / HTML

text type

Corpus design and compilation

Definition

A category of written or spoken material characterized by specific linguistic features and intended for particular communicative purposes. Text types can vary significantly, as seen in the distinction between general text corpora and specialized categories such as 'Email Corpus' or 'Speech Corpus', which are designed for targeted analysis. The methodological implications of identifying text types are crucial for corpus design, as they influence the representativeness and applicability of the corpus data.

Frequency (EN corpus)

abs: 290 pmw: 228.28

Corpus evidence (EN)

"However, we are highly sensitive in this regard. We argue that texts composed in personal emails should not be included within a general text corpus, since samples derived from these sources possess certain linguistic data and features that are hardly observed in texts composed in regular imaginative and informative texts." (source)

"An important type of speech corpus is an 'experimental corpus', which is assembled for studying the finer details of spoken texts." (source)

"By default, a speech corpus is entitled to contain samples of private and public speech, which are distinct from written text types." (source)

Nota terminológica / Terminological note

The term "text type" encompasses a range of categories that are essential for corpus linguistics, influencing both the design and analysis of corpora. Variations in the definition and application of text types may arise depending on the specific linguistic or methodological context in which they are employed. El término "tipo de texto" abarca una variedad de categorías que son esenciales para la lingüística de corpus, influyendo tanto en el dise

Términos relacionados / Related terms

corpus / corpus · **corpus design** / diseño de corpus · **general corpus** / corpus general · **speech corpus** / corpus oral · **annotation** / anotación · **metadata** / metadatos

tipo de texto

Diseño y compilación de corpus

Definición

Una categoría de material escrito u oral que se caracteriza por rasgos lingüísticos específicos y que está destinada a propósitos comunicativos particulares. Los tipos de texto pueden variar significativamente, como se observa en la distinción entre los corpus de texto generales y categorías especializadas como 'Corpus de Email' o 'Corpus de Habla', que están diseñados para análisis específicos. Las implicaciones metodológicas de identificar tipos de texto son cruciales para el diseño de corpus, ya que influyen en la representatividad y aplicabilidad de los datos del corpus.

Frecuencia (corpus ES)

abs: 73 pmw: 89.93

Evidencia en corpus (ES)

"Es evidente que se trata de una cuestión relacionada con el grado de codificación introducido en cada caso, de modo que no resulta extraño al trabajo habitual con los corpus." (fuente)

"La diferencia está en el carácter general (es decir, común a todos los textos orales) de la primera línea, frente al particular de la segunda, que es lo que hace virtualmente impracticable su incorporación a un corpus de referencia." (fuente)

"Los tipos de texto pueden variar significativamente, como se observa en la distinción entre los corpus de texto generales y categorías especializadas." (fuente)

token

Language processing

Definition

A basic unit of text that is counted in linguistic analysis, representing each occurrence of a word form regardless of its frequency. Tokens are distinguished from types, which refer to unique word forms in a text, highlighting the difference between total occurrences and distinct words. The methodology of counting tokens can vary across corpora, as seen in the treatment of clitic forms in different datasets.

Frequency (EN corpus)

abs: 300 pmw: 236.15

Corpus evidence (EN)

Tokens are all the individual wordforms in a text. There are 145 word tokens in the Obama excerpt above if we take a space as the delimiter (separator) between wordforms. (2016_Barth, D., Schnell, S._Understanding Corpus Linguistics)

Counting word tokens in a text is far from trivial even in a language like English, where the question arises whether forms like It's or aren't should be counted as a single word token... Different corpora follow different procedures here. (2016_Barth, D., Schnell, S._Understanding Corpus Linguistics)

The token definition we're using... most of these forms are probably the results of tokenisation errors in the BNC. (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term "token" is widely used in corpus linguistics to denote individual occurrences of word forms, and its definition can vary based on the specific methodologies employed by different corpora. Variations in tokenisation practices, such as the treatment of clitics, can lead to discrepancies in token counts across datasets. El término "token" se utiliza ampliamente en la lingüística de corpus para denotar ocurrencias individuales de formas léxi

Términos relacionados / Related terms

type-token ratio / relación tipo-token · **corpus** / corpus · **frequency** / frecuencia · **tokenisation** / tokenización · **POS tagging** / etiquetado morfosintáctico · **type-token ratio** / relación tipo-token

token

Procesamiento del lenguaje

Definición

Unidad básica de texto que se cuenta en el análisis lingüístico, representando cada ocurrencia de una forma léxica sin importar su frecuencia. Los tokens se diferencian de los types, que se refieren a las formas de palabras únicas en un texto, destacando la diferencia entre las ocurrencias totales y las palabras distintas. La metodología para contar tokens puede variar entre diferentes corpus, como se observa en el tratamiento de las formas clíticas en distintos conjuntos de datos.

Frecuencia (corpus ES)

abs: 56 pmw: 68.98

Evidencia en corpus (ES)

The total number of tokens will define the size of the corpus. (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

El token o palabra es cada una de las formas que aparecen en el texto, sin importar cuántas veces ocurra cada una. (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

La relación entre los type y token de un texto nos dará su riqueza léxica. (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

tokenisation

Language processing

Definition

The process of segmenting text into individual units, known as tokens, which can include words, phrases, or symbols. This methodological step is crucial in corpus linguistics as it influences the quality of data analysis, particularly in relation to the accuracy of frequency counts and statistical measures. Tokenisation is often contrasted with the treatment of punctuation and numbers, which can skew results if not properly defined.

Frequency (EN corpus)

abs: 62 pmw: 48.80

Corpus evidence (EN)

"the dots don't form part of the general token definition we're using, and most of these forms (apart from the abbreviations) are probably the results of tokenisation errors in the BNC, anyway." (source)

"the creation of large-scale resources may frequently lead to the compilers taking shortcuts when it comes to ensuring the quality of the data in terms of tokenisation and annotation." (source)

"the design of the annotation and interfaces available may sometimes exhibit flaws from a linguistic perspective, as we've, for instance, seen for the CQP architecture behind BNCweb, which treats punctuation tokens in exactly the same way as genuine words, thereby potentially skewing all the statistics produced by the tool." (source)

Nota terminológica / Terminological note

Tokenisation is a foundational concept in corpus linguistics, with implications for data analysis and interpretation. Variations in tokenisation methods can lead to significant differences in research outcomes, highlighting the importance of methodological rigor in corpus studies. La tokenización es un concepto fundamental en la lingüística de corpus, con implicaciones para el análisis y la interpretación de datos. Las variaciones en los métodos

Términos relacionados / Related terms

token / token · **annotation** / anotación · **frequency** / frecuencia · **corpus design** / diseño de corpus · **concordance** / concordancia · **raw frequency** / frecuencia bruta

tokenización

Procesamiento del lenguaje

Definición

La tokenización es el proceso de segmentar un texto en unidades individuales, conocidas como tokens, que pueden incluir palabras, frases o símbolos. Este paso metodológico es fundamental en la lingüística de corpus, ya que influye en la calidad del análisis de datos, especialmente en relación con la precisión de los conteos de frecuencia y las medidas estadísticas. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 13 pmw: 15.52

training corpus

Corpus design and compilation

Definition

A specialized collection of texts used to develop and evaluate language processing models, characterized by its systematic selection of data that reflects the linguistic features relevant to the intended application. This type of corpus is essential in applied linguistics and language technology, serving as a test-bed for training devices and tools. It contrasts with a general corpus, which may not be specifically tailored for such purposes.

Frequency (EN corpus)

abs: 35 pmw: 27.55

Corpus evidence (EN)

"A corpus as a test-bed for the training and testing of devices, tools, techniques and systems of applied linguistics and language technology." (Sekhar Dash & Arulmozi 2018)

"The FGLOCTweet Corpus was built with the aim of capturing as wide a variety of locative references as possible... it was also important to consider consistency in the annotation of data... for the correct training of our model." (Fernández-Martínez 2023)

"The collection of texts also has to be purposeful." (Egbert, Biber & Gray 2022)

Nota terminológica / Terminological note

The term "training corpus" is widely recognized in the fields of applied linguistics and natural language processing, emphasizing its role in developing language models. Its definition may vary slightly depending on the specific application, but it consistently denotes a corpus specifically curated for training purposes. El término "corpus de entrenamiento" es ampliamente reconocido en los campos de la lingüística aplicada y el procesamiento del

Términos relacionados / Related terms

corpus / corpus · **annotated corpus** / corpus anotado · **corpus compilation** / compilación de corpus · **corpus design** / diseño de corpus · **learner corpus** / corpus de aprendices · **corpus-based** / basado en corpus

corpus de entrenamiento

Diseño y compilación de corpus

Definición

Un corpus de entrenamiento es una colección de textos diseñada específicamente para el desarrollo y la evaluación de modelos de procesamiento del lenguaje, seleccionada de manera sistemática para reflejar las características lingüísticas relevantes para la aplicación prevista. Este tipo de corpus es fundamental en la lingüística aplicada y la tecnología del lenguaje, ya que sirve como base para entrenar herramientas y dispositivos. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 15 pmw: 17.91

Evidencia en corpus (ES)

"These include corpus compilation, corpus preprocessing and corpus annotation." (Fernández-Martínez 2023)

"The corpus was built with methodological corpus-based principles in mind in each of the different steps." (Fernández-Martínez 2023)

treebank

Annotation and markup

Definition

A structured corpus that contains syntactically analyzed sequences, allowing for the retrieval of sentences that meet specific structural conditions. Treebanks serve as essential resources in natural language processing, particularly for training parsers, and are characterized by their use of tree structures to represent grammatical relationships. Notably, the Penn Treebank is a widely recognized example, illustrating the methodological significance of treebank annotations in linguistic research.

Frequency (EN corpus)

abs: 106 pmw: 83.44

Corpus evidence (EN)

"Their main implementation is in work within natural language processing and the development of parsers for which manually annotated treebanks serve as training corpora." (2023_Barth, D., Schnell, S._Understanding Corpus Linguistics)

"An example is the NEGRA Corpus, a parsed corpus of German newspaper texts... which are available both in the Penn Treebank format." (2017_Gries, S. T., Berez, A. L._Linguistic Annotation in or for Corpus Linguistics)

"Some parsed corpora are provided in yet different formats. An example is the NEGRA Corpus, a parsed corpus of German newspaper texts." (2017_Gries, S. T., Berez, A. L._Linguistic Annotation in or for Corpus Linguistics)

Nota terminológica / Terminological note

The term "treebank" is widely used in computational linguistics and corpus linguistics, with various examples across languages. While the core concept remains consistent, the specific methodologies and structures can vary significantly between different treebanks, reflecting the diverse linguistic features they aim to analyze. El término "banco de árboles" se utiliza ampliamente en lingüística computacional y lingüística de corpus, con diversos

Términos relacionados / Related terms

annotation / anotación · **corpus** / corpus · **POS tagging** / etiquetado morfosintáctico · **dependency parsing** / análisis de dependencias · **annotated corpus** / corpus anotado · **parsing** / análisis sintáctico

treebank

Anotación y marcado

Definición

Un corpus estructurado que contiene secuencias analizadas sintácticamente, lo que permite recuperar oraciones que cumplen con condiciones estructurales específicas. Los bancos de árboles son recursos esenciales en el procesamiento del lenguaje natural, especialmente para el entrenamiento de analizadores, y se caracterizan por el uso de estructuras arbóreas para representar relaciones gramaticales. Un ejemplo ampliamente reconocido es el RST Spanish Treebank, que ilustra la importancia metodológica de las anotaciones en los bancos de árboles en la investigación lingüística.

Frecuencia (corpus ES)

abs: 48 pmw: 59.13

Evidencia en corpus (ES)

"El RST Spanish Treebank fue creado en colaboración con la Universidad Pompeu Fabra y la Universidad de Aviñón." (2018_Sierra, G. E._Corpus lingüísticos)

"Los treebanks, por ejemplo, son conjuntos de secuencias analizadas sintácticamente en los que es posible recuperar las que reúnen unas determinadas condiciones estructurales." (2016_Rojo, G._Los corpus textuales del español_Enciclopedia de Lingüística hispánica)

"El corpus Araknion-es, construido por el grupo CLIC, contiene algo más de tres millones de oraciones con los análisis sintácticos correspondientes en forma de árboles de dependencias." (2016_Rojo, G._Los corpus textuales del español_Enciclopedia de Lingüística hispánica)

TreeTagger

Tools and software

Definition

A software tool designed for linguistic annotation, specifically for part-of-speech tagging and lemmatization. It operates by processing monolingual texts and requires specific parameter files for different languages to ensure accurate tagging. The tool is noted for its high accuracy rates in POS tagging, which can vary based on the language and corpus used for training.

Frequency (EN corpus)

abs: 61 pmw: 48.02

Corpus evidence (EN)

"Make sure *TreeTagger* handles the language that you are studying." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

"*TreeTagger* has been trained on an English reference corpus." (2017_Desagulier, G._Corpus Linguistics and Statistics with R)

"The final choice will depend on the results obtained once the *TreeTagger* has been trained on a sufficient amount of data from the PaGeS Corpus." (2017_Doval, I._POS-tagging a bilingual parallel corpus. Methods and challenges_Research in Corpus Linguistics)

Nota terminológica / Terminological note

The term "*TreeTagger*" is widely recognized in the field of corpus linguistics for its role in linguistic annotation, particularly in part-of-speech tagging. Its effectiveness can vary based on the language and corpus used, and it is often compared with other tagging tools to assess performance and accuracy. El término "*TreeTagger*" es ampliamente reconocido en el campo de la lingüística de corpus por su papel en la anotación lingüística, especialm

Términos relacionados / Related terms

POS tagging / etiquetado morfosintáctico · **corpus annotation** / anotación de corpus · **tagset** / tagset · **lemmatisation** / lematización · **annotated corpus** / corpus anotado · **accuracy** / exactitud

TreeTagger

Herramientas y software

Definición

Una herramienta de software destinada a la anotación lingüística, específicamente para el etiquetado de partes del habla y la lematización. Funciona procesando textos monolingües y requiere archivos de parámetros específicos para diferentes lenguas para asegurar una etiquetación precisa. Se destaca por sus altas tasas de precisión en el etiquetado de partes del habla, que pueden variar según el idioma y el corpus utilizado para el entrenamiento.

Frecuencia (corpus ES)

abs: 59 pmw: 72.68

Evidencia en corpus (ES)

"*TreeTagger* is compatible with the following languages: English, French, German, Spanish, Italian, Bulgarian, Dutch, Russian, Greek, Portuguese, and Chinese." (2016_Molés-Cases, T._Compilación y análisis de un corpus paralelo para la investigación en traducción_Revista de Lingüística teórica y aplicada)

"*TreeTagger* etiqueta por lengua, esto es, textos monolingües." (2016_Molés-Cases, T._Compilación y análisis de un corpus paralelo para la investigación en traducción_Revista de Lingüística teórica y aplicada)

"*TreeTagger* dispone de versiones para Linux, Mac y Windows." (2016_Molés-Cases, T._Compilación y análisis de un corpus paralelo para la investigación en traducción_Revista de Lingüística teórica y aplicada)

type-token ratio

Lexicon and phraseology

Definition

A quantitative measure in corpus linguistics that expresses the diversity of vocabulary within a sample, calculated by dividing the number of unique types by the total number of tokens. This ratio indicates the proportion of distinct words relative to the total word count, reflecting lexical richness and variation in the text. Methodologically, it is essential for comparing linguistic phenomena across different samples, as it accounts for sample size variability.

Frequency (EN corpus)

abs: 27 pmw: 21.25

Corpus evidence (EN)

The resulting measure is referred to very transparently as the type/token ratio (or TTR): (3) $TTR = \frac{\text{types}}{\text{tokens}}$ (source)

The TTR is the percentage of types in a sample are different from each other; or, put differently, it is the mean probability that we will encounter a new type if we go through the sample item by item. (source)

In order to compare type frequencies, we have to correct for the size of the sample: all else being equal, a larger sample will contain more types than a smaller one simply because it offers more opportunities for different types to occur. (source)

Nota terminológica / Terminological note

The type-token ratio is a crucial metric in corpus linguistics, often used to assess lexical diversity and richness in texts. Variations in its application can arise depending on the size of the corpus and the specific linguistic phenomena being analyzed. La relación tipo-token es un índice fundamental en la lingüística de corpus, utilizado para evaluar la diversidad léxica y la riqueza en los textos. Las variaciones en su aplicación pueden surgir

Términos relacionados / Related terms

token / token · **hapax legomena** / hapax legómeno · **frequency** / frecuencia · **corpus** / corpus · **sample** / muestra · **normalized frequency** / frecuencia normalizada

relación tipo-token

Léxico y fraseología

Definición

Medida cuantitativa en lingüística de corpus que expresa la diversidad léxica de una muestra, calculada dividiendo el número de tipos únicos entre el total de tokens. Este índice refleja la proporción de palabras distintas en relación con el recuento total de palabras, dando cuenta de la riqueza léxica y la variación textual. Metodológicamente, resulta esencial para comparar fenómenos lingüísticos entre distintas muestras, ya que contempla la variabilidad en el tamaño de la muestra.

Frecuencia (corpus ES)

abs: 31 pmw: 37.01

unicode

Metadata and formats

Definition

A standardized system for character encoding that ensures consistent representation and manipulation of text across different languages and scripts. It allows for the inclusion of a vast array of characters, facilitating the creation of multilingual corpora and ensuring interoperability among various software applications. Unicode is essential in contemporary corpus linguistics, as it enables researchers to utilize diverse textual data without encoding discrepancies.

Frequency (EN corpus)

abs: 59 pmw: 46.44

Corpus evidence (EN)

Because modern corpus linguistics involves electronic data interchange in an increasingly globalizing environment, ASCII is being replaced by Unicode ("Uni■cation Code"). (source)

Unicode has three main assets. First, it is platform-independent, which means it is usable on all computers, regardless of the operating system or locale. (source)

Unicode is a font-independent system for character encoding to ensure readability across languages and scripts. (source)

Nota terminológica / Terminological note

The term "Unicode" is widely accepted in both English and Spanish contexts, reflecting its critical role in modern text processing and corpus linguistics. Variations in its implementation, such as different UTF formats, highlight the ongoing evolution of character encoding standards. El término "Unicode" es ampliamente aceptado tanto en contextos en inglés como en español, reflejando su papel crítico en el procesamiento de texto moderno y la lin

Términos relacionados / Related terms

[metadata](#) / *metadatos* · [XML](#) / *XML* · [encoding](#) / *codificación* · [annotation](#) / *anotación* · [plain text](#) / *texto plano* · [corpus design](#) / *diseño de corpus*

unicode

Metadatos y formatos

Definición

Sistema estandarizado de codificación de caracteres que garantiza la representación y manipulación coherente de texto en diferentes lenguas y escrituras. Permite la inclusión de una amplia variedad de caracteres, facilitando la creación de corpora multilingües y asegurando la interoperabilidad entre diversas aplicaciones informáticas. Su uso es fundamental en la lingüística de corpus contemporánea, ya que permite a los investigadores utilizar datos textuales diversos sin discrepancias de codificación.

Frecuencia (corpus ES)

abs: 9 pmw: 11.09

Evidencia en corpus (ES)

Los corpus generales permiten, en efecto, extraer datos acerca de las características relevantes de la L2 y hacerlo de forma selectiva en función de los diferentes tipos de texto. (fuente)

Para que ese conjunto de textos comience a resultar verdaderamente útil en estudios sobre la adquisición de una segunda lengua es necesario ir añadiendo capas con información referente a las características externas o internas de esos textos. (fuente)

La inclusión de estos metadatos en el lugar adecuado permite hacer luego la recuperación selectiva de los casos que interesen. (fuente)

UTF-8

Metadata and formats

Definition

A character encoding that uses a variable number of bytes to represent characters, allowing for the inclusion of a vast array of symbols from multiple languages. This format is particularly significant in corpus linguistics as it maintains compatibility with ASCII while enabling the processing of multilingual texts, thus facilitating the creation of diverse corpora. Its adoption is increasingly becoming the standard for text processing in various computational applications.

Frequency (EN corpus)

abs: 90 pmw: 70.84

Corpus evidence (EN)

Because modern corpus linguistics involves electronic data interchange in an increasingly globalizing environment, ASCII is being replaced by Unicode ("Unification Code"). Among the three formats that have been proposed—UTF-32, UTF-16, and UTF-8—the latter is becoming the norm in corpus linguistics. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

One reason for this is that UTF-8 maximizes backward compatibility with ASCII. (source: 2017_Desagulier, G._Corpus Linguistics and Statistics with R)

This character set is also well supported by many different programs, including browsers, so that it makes information exchange including characters from many different languages, as well as special characters, such as phonetic symbols, etc., much easier. (source: 2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

Nota terminológica / Terminological note

The term UTF-8 is widely recognized in computational linguistics and is often contrasted with other encoding formats such as UTF-16 and UTF-32. Its significance lies in its ability to support a wide range of characters while maintaining compatibility with older systems, making it a preferred choice for modern text processing applications. El término UTF-8 es ampliamente reconocido en la lingüística computacional y a menudo se contrasta con otros

Términos relacionados / Related terms

metadata / metadatos · **encoding** / codificación · **plain text** / texto plano · **XML** / XML · **tokenisation** / tokenización · **corpus design** / diseño de corpus · **HTML** / HTML

UTF-8

Metadatos y formatos

Definición

Un formato de codificación de caracteres que utiliza un número variable de bytes para representar caracteres, permitiendo la inclusión de una amplia gama de símbolos de múltiples lenguas. Este formato es especialmente relevante en la lingüística de corpus, ya que mantiene la compatibilidad con ASCII y permite el procesamiento de textos multilingües, facilitando así la creación de corpora diversos. Su adopción se está convirtiendo en el estándar para el procesamiento de texto en diversas aplicaciones computacionales.

Frecuencia (corpus ES)

abs: 16 pmw: 19.71

Evidencia en corpus (ES)

Para su procesamiento hemos generado ocho etiquetas metatextuales que responden a los siguientes parámetros: La primera etiqueta, , hace referencia a las diferentes bibliotecas electrónicas de las que hemos extraído los textos del CLARE. (fuente: 2016_García Ferrer, M._Diseño y construcción de un corpus de referencia de latín_Métodos)

jEdit trabaja tanto con UTF-8 como con otros formatos de codificación del texto. (fuente: 2016_García Ferrer, M._Diseño y construcción de un corpus de referencia de latín_Métodos)

La inclusión de estos metadatos en el lugar adecuado (habitualmente la cabecera de un documento XML) permite hacer luego la recuperación selectiva de los casos que interesen. (fuente: 2022_Rojo, G., Palacios, I._Los corpus de aprendientes de español como L2)

web corpus

Corpus design and compilation

Definition

A collection of texts exclusively derived from the World Wide Web, distinguished by its digital nature and the absence of printed text samples. This type of corpus is characterized by its enormous size, variety of content, and the inclusion of diverse text types, making it a valuable resource for linguistic research and language technology. Unlike traditional corpora, which may include both physical and virtual texts, a web corpus focuses solely on data sourced from online platforms.

Frequency (EN corpus)

abs: 45 pmw: 35.42

Corpus evidence (EN)

Although the path is defined and mission is visualized, the actual journey is plagued with many meanders and mirages highlighted in subsequent sections. In this context, it is necessary to have some theoretical knowledge about the form, nature and content of a web corpus, which may help to understand how a web corpus differs from that of a general corpus, both in composition and application. (2018_Sekhar Dash, N., Arulmozi, S.)

A WTC solely and wholly, unless otherwise desired, contains texts from the virtual world. That means that the language data that are used to build up a WTC are practically and primarily collected from various websites, homepages, and similar other virtual sources. (2018_Sekhar Dash, N., Arulmozi, S.)

While a normal digital corpus contains text samples from both physical and virtual worlds, a WTC solely and wholly contains texts from the virtual world. (2018_Sekhar Dash, N., Arulmozi, S.)

Nota terminológica / Terminological note

The term "web corpus" reflects an evolving understanding of linguistic data collection, emphasizing the unique challenges and opportunities presented by online sources. Scholars debate its methodological status, with some viewing it as a legitimate corpus type while others argue it lacks the rigor of traditional corpora. El término "corpus web" refleja una comprensión en evolución de la recopilación de datos lingüísticos, enfatizando los desafíos

Términos relacionados / Related terms

general corpus / corpus general · **corpus compilation** / compilación de corpus · **multimodal corpus** / corpus multimodal · **corpus design** / diseño de corpus · **reference corpus** / corpus de referencia

corpus web

Diseño y compilación de corpus

Definición

Una colección de textos obtenidos exclusivamente de la World Wide Web, caracterizada por su naturaleza digital y la ausencia de muestras de texto impresas. Este tipo de corpus se distingue por su enorme tamaño, variedad de contenido y la inclusión de diversos tipos de textos, lo que lo convierte en un recurso valioso para la investigación lingüística y la tecnología del lenguaje. A diferencia de los corpus tradicionales, que pueden incluir textos tanto físicos como virtuales, un corpus web se centra únicamente en datos provenientes de plataformas en línea.

Frecuencia (corpus ES)

abs: 23 pmw: 28.33

Evidencia en corpus (ES)

A pesar de ello, también podemos encontrar algunos problemas en la utilización de la web que tienen que ver con el "ruido" que se genera debido al material no lingüístico. (2017_González Fernández, A.)

En su artículo titulado The Web as corpus, no deja de reconocer los puntos débiles de este nuevo concepto con el que, asume, tenemos que trabajar todos porque "está con nosotros". (2017_González Fernández, A.)

En comparación entre la web y el BNC, denomina a este último como "an English country garden", y admite que "whatever perversities the BNC has, the web has in spades". (2017_González Fernández, A.)

wildcard

Search and retrieval

Definition

A character or symbol that represents one or more unspecified characters in search queries. In corpus linguistics, wildcards allow for flexible querying by enabling the retrieval of variations of a word or phrase, such as different spellings or forms. This feature is essential for exploring linguistic data comprehensively, as it accommodates the variability inherent in language.

Frequency (EN corpus)

abs: 16 pmw: 12.59

Corpus evidence (EN)

"The wildcard syntax in BNCweb also has a number of shorthand expressions that... lowercase indicates the occurrence of single characters and uppercase of multiple (potentially unlimited) ones." (source)

"The wildcard asterisk (*) means 'zero or more characters'." (source)

"A more general wildcard pattern that may only be looking for '+' (or '*') will fail here because it can only identify word tokens that actually consist of the apostrophe followed by any number of characters..." (source)

Nota terminológica / Terminological note

The term "wildcard" is widely used in corpus linguistics to denote flexible search capabilities, allowing researchers to account for linguistic variability. Its application is crucial for effective data retrieval and analysis, particularly in large corpora where variations in spelling and form are common. El término "comodín" se utiliza ampliamente en la lingüística de corpus para denotar capacidades de búsqueda flexibles, permitiendo a los inves

Términos relacionados / Related terms

[query](#) / consulta · [regular expression](#) / expresión regular · [concordance](#) / concordancia · [token](#) / token · [frequency](#) / frecuencia · [corpus queries](#) / consultas de corpus

comodín

Búsqueda y consulta

Definición

Un carácter o símbolo que representa uno o más caracteres no especificados en consultas de búsqueda. En la lingüística de corpus, los comodines permiten realizar consultas flexibles al facilitar la recuperación de variaciones de una palabra o frase, como diferentes grafías o formas. Esta característica es esencial para explorar de manera integral los datos lingüísticos, ya que acomoda la variabilidad inherente al lenguaje.

Frecuencia (corpus ES)

abs: 7 pmw: 8.62

Evidencia en corpus (ES)

"El modo de hacerlo es añadir el operador , vinculado al metacarácter , que hemos utilizado en algunas de las búsquedas de los capítulos 4 y 5 y se emplea también como comodín en algunos sistemas operativos." (fuente)

"Su significado exacto es 'cero o más apariciones del carácter inmediatamente anterior', de modo que la indicación can debe ser leída como 'carácter c seguido de cero o más apariciones del carácter a y luego el carácter n'." (fuente)*

"La misma técnica, usando los puntos como indicación de que vale cualquier carácter que ocupe ese lugar, podríamos recuperar las de tres letras, cinco letras, etc." (fuente)

word class

Annotation and markup

Definition

A category of words that share similar grammatical properties, distinguished by their syntactic and morphological functions within a sentence. This classification is essential for morpho-syntactic annotation, as it influences the meaning and usage of word forms in various contexts. The concept is foundational in corpus linguistics, particularly in the context of Part-of-Speech (PoS) tagging, which relies on identifying the word class to analyze language data effectively.

Frequency (EN corpus)

abs: 52 pmw: 40.93

Corpus evidence (EN)

This kind of linguistic technology makes it possible to enrich data with information that facilitates extracting and analysing specific word forms or constructions in a way that's more advanced than what we've discussed previously. (2016_Weisser, M.)

Very frequently, this polysemy is in fact of a morpho-syntactic nature because these differences in meaning depend on the word class associated with the word form in a particular context, as well as potentially its inflection. (2016_Weisser, M.)

Understanding Part-of-Speech Tagging and Its Uses... This chapter will explore one of the main breakthroughs in corpus linguistics, morpho-syntactic annotation, which is also referred to as Part-of-Speech (or PoS) tagging. (2016_Weisser, M.)

Nota terminológica / Terminological note

The term "word class" is widely accepted in linguistic studies and is foundational for understanding grammatical structures. Its application in corpus linguistics, particularly in PoS tagging, highlights its importance in analyzing language data. Variations in definitions may arise based on different linguistic frameworks or annotation schemes. El término "clase de palabras" es ampliamente aceptado en los estudios lingüísticos y es fundamental pa

Términos relacionados / Related terms

Part-of-speech tagging / etiquetado morfosintáctico · **morphological annotation** / anotación morfológica · **Token** / token · **Lemma** / lema · **Content words** / palabras de contenido

clase de palabras

Anotación y marcado

Definición

Una categoría de palabras que comparten propiedades gramaticales similares, diferenciadas por sus funciones sintácticas y morfológicas dentro de una oración. Esta clasificación es esencial para la anotación morfosintáctica, ya que influye en el significado y el uso de las formas de palabras en diversos contextos. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 87 pmw: 103.86

word frequency

Lexicon and phraseology

Definition

A quantitative measure indicating how often specific word forms appear within a given text or corpus. This metric is essential for generating frequency lists, which can be sorted to reveal patterns in language use, such as identifying the most common or least common words. The methodology for calculating word frequency often involves tokenization and normalization processes to ensure accuracy across different corpora.

Frequency (EN corpus)

abs: 83 pmw: 65.33

Corpus evidence (EN)

"the word types included in the sixth frequency band occur on average in only 14 percent of the texts." (2022_Egbert, J. Biber, D. y Gray, B., *Designing and Evaluating Language Corpora*)

"we can start looking at frequency lists properly." (2016_Weisser, M., *Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis*)

"the most useful output format in many areas of corpus linguistics for such a list is generally to have a list that is first sorted according to the frequency in descending order." (2016_Weisser, M., *Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis*)

Nota terminológica / Terminological note

The term "word frequency" is widely used in corpus linguistics to analyze language patterns and usage. Variations in methodology, such as the inclusion or exclusion of stopwords, can lead to different interpretations of frequency data. In Spanish, "frecuencia de palabras" is the established term, reflecting similar analytical practices in the field. El término "frecuencia de palabras" se utiliza ampliamente en la lingüística de corpus para analiz

Términos relacionados / Related terms

frequency list / lista de frecuencias · **token** / token · **raw frequency** / frecuencia bruta · **normalized frequency** / frecuencia normalizada · **stopword** / palabra vacía · **lemma** / lema

frecuencia de palabras

Léxico y fraseología

Definición

Una medida cuantitativa que indica con qué frecuencia aparecen formas específicas de palabras dentro de un texto o corpus determinado. Este concepto es fundamental para generar listas de frecuencia, que pueden ordenarse para revelar patrones en el uso del lenguaje, como la identificación de las palabras más comunes o menos comunes. La metodología para calcular la frecuencia de palabras a menudo implica procesos de segmentación y normalización para garantizar la precisión en diferentes corpus.

Frecuencia (corpus ES)

abs: 5 pmw: 6.16

Evidencia en corpus (ES)

"la frecuencia de uso y porcentajes de algunas clases de palabras en diferentes corpus textuales." (2021_Rojo, G., *Introducción a la lingüística de corpus en español*)

"se acostumbra indicar la frecuencia absoluta de cada una de los types." (2015_Sierra Martínez, G. E., *Introducción a los corpus lingüísticos*)

"la suma de las frecuencias de todos los types será la suma de todos los tokens de un corpus." (2015_Sierra Martínez, G. E., *Introducción a los corpus lingüísticos*)

word list

Lexicon and phraseology

Definition

A structured compilation of word types ranked by frequency of occurrence within a specific corpus, facilitating the analysis of lexical patterns. This methodological tool is essential for understanding the distribution and usage of vocabulary across different texts, as highlighted by the variability in rank-ordered word lists depending on corpus size and composition. The term contrasts with "frequency list," which may not necessarily imply a rank order.

Frequency (EN corpus)

abs: 100 pmw: 78.72

Corpus evidence (EN)

The primary problem here has nothing to do with the size of the corpus - rather, the problem is that there hundreds of thousands of different word types (ca. 700,000 word types in the BNC alone), and that any individual text will use only a small handful of those different words. (2022_Egbert J. Biber D. y Gray B.)

Therefore, any list of frequent words will fluctuate wildly depending on the particular texts included in a corpus. (2022_Egbert J. Biber D. y Gray B.)

All other things being equal, however, a larger corpus will provide a more complete and more stable rank-ordered word list than a smaller corpus. (2022_Egbert J. Biber D. y Gray B.)

Nota terminológica / Terminological note

The term "word list" is frequently employed in corpus linguistics to denote a specific type of lexical analysis tool, essential for understanding vocabulary usage patterns. Its application may vary depending on the corpus size and the specific linguistic context, leading to different interpretations and methodologies in its construction. El término "lista de palabras" se utiliza con frecuencia en la lingüística de corpus para denotar un tipo espe

Términos relacionados / Related terms

frequency list / lista de frecuencias · **corpus** / corpus · **token** / token · **keyword analysis** / análisis de palabras clave · **concordance** / concordancia

lista de palabras

Léxico y fraseología

Definición

Una recopilación estructurada de tipos de palabras ordenadas por su frecuencia de aparición dentro de un corpus específico, que facilita el análisis de patrones léxicos. Esta herramienta metodológica es esencial para comprender la distribución y el uso del vocabulario en diferentes textos, como se destaca en la variabilidad de las listas de palabras ordenadas según el tamaño y la composición del corpus. El término contrasta con "lista de frecuencia", que puede no implicar necesariamente un orden jerárquico.

Frecuencia (corpus ES)

abs: 3 pmw: 3.70

Evidencia en corpus (ES)

En este sentido, según sea el enfoque, lexicográfico o terminológico, se tendrán unidades léxicas especializadas (ULE, en adelante) o términos, respectivamente. (2022_Martí, M. A., Taulé, M.)

Una ULE o término es un conjunto de una o más palabras que tiene un sentido específico en un dominio de especialidad, el cual representa y transmite el contenido especializado de un dominio específico. (2022_Martí, M. A., Taulé, M.)

Este dominio puede ser más general (como medicina, derecho o ingeniería), o más específico (como cardiología, derecho procesal o ingeniería civil). (2022_Martí, M. A., Taulé, M.)

WordSmith Tools

Tools and software

Definition

A commercial software suite developed for the analysis of word behavior within corpora, offering tools such as Wordlist, KeyWords, and Concord. These tools facilitate quantitative linguistic analysis through statistical techniques, enabling users to generate concordances and identify lexical patterns. The methodological status of WordSmith Tools is grounded in its application for corpus-based research, contrasting with other tools like AntConc, which may have different functionalities or focuses.

Frequency (EN corpus)

abs: 9 pmw: 7.08

Corpus evidence (EN)

"WordSmith Tools is a commercial software developed by Mike Scott from the University of Liverpool and distributed by Oxford University Press." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

"This type of information allows detecting recurrent lexical patterns, characterizing the use of a word or a particular expression in the analyzed texts." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

"The tool offers detailed statistics about the distribution of lexical units and allows comparing texts based on these characteristics." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

Nota terminológica / Terminological note

The term "WordSmith Tools" is widely recognized in the field of corpus linguistics as a robust software suite for linguistic analysis, particularly in English. Its functionalities are often compared to those of other tools, indicating a diverse landscape of software options available for researchers. El término "WordSmith Tools" es ampliamente reconocido en el campo de la lingüística de corpus como un conjunto de software robusto para el análisis

Términos relacionados / Related terms

concordance / concordancia · **keyword analysis** / análisis de palabras clave · **corpus compilation** / compilación de corpus · **frequency list** / lista de frecuencias · **statistical significance** / significancia estadística · **AntConc** / AntConc

WordSmith Tools

Herramientas y software

Definición

Un software comercial desarrollado para el análisis del comportamiento de palabras en corpus, que ofrece herramientas como Wordlist, KeyWords y Concord. Estas herramientas permiten realizar análisis lingüísticos cuantitativos mediante técnicas estadísticas, facilitando la generación de concordancias e identificación de patrones léxicos. Su estatus metodológico se fundamenta en su aplicación en la investigación basada en corpus, en contraste con otras herramientas como AntConc, que pueden tener diferentes funcionalidades o enfoques.

Frecuencia (corpus ES)

abs: 28 pmw: 34.49

Evidencia en corpus (ES)

"The tool provides information about the context of occurrence of words or phrases." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

"The WordList tool generates a list that includes all the words of the corpus ordered alphabetically or by their frequency of occurrence." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

"WordSmith Tools is a set of tools designed to study the behavior of words in the corpus." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

written corpus

Corpus design and compilation

Definition

A collection of texts that are produced in written form, typically used for linguistic analysis and research. This type of corpus is essential for studying language as it allows for the examination of written discourse, contrasting with spoken corpora that require transcription. The methodological approach to compiling a written corpus often involves systematic collection and annotation to ensure representativeness and reliability in linguistic studies.

Frequency (EN corpus)

abs: 37 pmw: 29.12

Corpus evidence (EN)

It is a challenge to compile, manage, process and access speech data in digital form. To achieve success, we need help from expert phoneticians, field linguists, computer experts, language experts and some sophisticated systems for spoken text collection, storage, management, processing, analysis and application. (source)

The corpus should contain both written and spoken text samples produced by the learners. (source)

In order to be machine-readable (and for easier consideration by human analysts), spoken and signed texts are considered in corpus linguistics in a written form. (source)

Nota terminológica / Terminological note

The term "written corpus" is widely accepted in corpus linguistics, emphasizing the importance of written texts for linguistic analysis. Variations in its definition may arise based on the specific focus of the research, such as genre or language variety. El término "corpus escrito" es ampliamente aceptado en la lingüística de corpus, enfatizando la importancia de los textos escritos para el análisis lingüístico. Las variaciones en su definición

Términos relacionados / Related terms

corpus / corpus · **annotation** / anotación · **sample** / muestra · **general corpus** / corpus general · **frequency** / frecuencia · **text type** / tipo de texto · **corpus design** / diseño de corpus

corpus escrito

Diseño y compilación de corpus

Definición

Una colección de textos producidos en forma escrita, utilizada principalmente para el análisis y la investigación lingüística. Este tipo de corpus es fundamental para el estudio del lenguaje, ya que permite examinar el discurso escrito, en contraste con los corpus orales que requieren transcripción. El enfoque metodológico para la elaboración de un corpus escrito implica la recolección y anotación sistemática para garantizar la representatividad y fiabilidad en los estudios lingüísticos.

Frecuencia (corpus ES)

abs: 21 pmw: 25.87

Evidencia en corpus (ES)

Se trata de un corpus sincrónico que consta de 500 muestras, cada una de 2000 palabras, con aproximadamente un millón de palabras del inglés escrito en Estados Unidos. (fuente)

El corpus incluye prosa informativa (prensa, religión, habilidades y pasatiempos, cultura popular, biografía y ciencias) y prosa de ficción. (fuente)

Los textos obtenidos de páginas con extensión .ar corresponden a Argentina, etc. (fuente)

XML

Metadata and formats

Definition

A markup language that allows users to define their own tags, facilitating the creation of structured documents. XML enhances the separation of content from presentation, enabling better organization and retrieval of information within corpora. It is often contrasted with HTML, which is more rigid in its predefined tags and structure.

Frequency (EN corpus)

abs: 567 pmw: 446.32

Corpus evidence (EN)

"XML (eXtensible Markup Language) Version 1.0, was eventually created and released by the W3C (World Wide Web Consortium) in 1998." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"XML allows users to create their own extended markup frameworks, and thereby makes it possible to increase the separation of form from content even further than was already possible by using HTML and CSS." (2016_Weisser, M._Practical Corpus Linguistics. An Introduction to Corpus-Based Language Analysis)

"This paper outlines a modest approach to XPath and XQuery, tools allowing the navigation and exploitation of XML-encoded texts." (2015_Ruhlemann, C., Bagoutdinov, A., O'Donnell, M. B._Modest XPath and XQuery for corpora. Exploiting deep XML annotation_ICAME)

Nota terminológica / Terminological note

The term XML has become a standard in the field of digital text processing and corpus linguistics, allowing for flexible data structuring and annotation. Its use is prevalent in various applications, from web development to linguistic research, reflecting its versatility and adaptability. El término XML se ha convertido en un estándar en el campo del procesamiento de textos digitales y la lingüística de corpus, permitiendo una estructuración y an

Términos relacionados / Related terms

HTML / HTML · SGML / SGML · XML / XML · SGML / SGML · Annotation / anotación · Corpus / corpus

XML

Metadatos y formatos

Definición

Un lenguaje de marcado que permite a los usuarios definir sus propias etiquetas, facilitando la creación de documentos estructurados. XML mejora la separación entre contenido y presentación, lo que permite una mejor organización y recuperación de información dentro de los corpus. A menudo se contrasta con HTML, que es más rígido en sus etiquetas y estructura predefinidas.

Frecuencia (corpus ES)

abs: 212 pmw: 261.15

Evidencia en corpus (ES)

"A document is valid if it complies with the structure predefined in the DTD, that is, if the incoming data has been structured correctly according to the defined norms." (2020_Marín Morales, M. I. y Molina, J._Un método de etiquetado semiautomático de corpus lingüísticos_Investigación e Innovación en Ingeniería de Software)

"El etiquetado en XML crea una estructura bien definida de los textos y presentada en forma de árbol." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

"Un documento bien formado es aquel que es sintácticamente correcto, esto es, que sus etiquetas están escritas conforme a las normas XML." (2015_Sierra Martínez, G. E._Introducción a los corpus lingüísticos)

Z-score

Frequency and statistics

Definition

A statistical measure that describes a value's relation to the mean of a group of values, expressed in terms of standard deviations. This metric is essential in quantitative linguistics for assessing the significance of linguistic features within a corpus. Unlike raw scores, z-scores standardize data, allowing for comparisons across different datasets or distributions.

Frequency (EN corpus)

abs: 2 pmw: 1.57

Corpus evidence (EN)

A statistical measure that describes a value's relation to the mean of a group of values, expressed in terms of standard deviations. (source)

This metric is essential in quantitative linguistics for assessing the significance of linguistic features within a corpus. (source)

Unlike raw scores, z-scores standardize data, allowing for comparisons across different datasets or distributions. (source)

Nota terminológica / Terminological note

The z-score is widely used in various fields, including linguistics, to standardize scores for comparative analysis. Its application in corpus linguistics allows researchers to assess the significance of linguistic features across different corpora. En lingüística, la puntuación z se utiliza para estandarizar resultados y facilitar comparaciones entre diferentes conjuntos de datos, lo que es crucial para el análisis cuantitativo.

Términos relacionados / Related terms

standard deviation / desviación estándar · **probability** / probabilidad · **frequency** / frecuencia · **dataset** / conjunto de datos · **statistical significance** / significancia estadística

Z-score

Frecuencia y estadística

Definición

Una medida estadística que describe la relación de un valor con la media de un grupo de valores, expresada en términos de desviaciones estándar. Este concepto es fundamental en la lingüística cuantitativa para evaluar la significación de características lingüísticas dentro de un corpus. Término no documentado en el subcorpus español.

Frecuencia (corpus ES)

abs: 1 pmw: 1.19

Evidencia en corpus (ES)

Término no documentado en el subcorpus español.